

文章编号: 1671- 637 X (2008) 08 0014 06

用于非线性机动目标跟踪的新型 IMM 算法

孙庆鹏, 孔祥维, 卢聪聪, 邓江安
(大连理工大学信息学院, 辽宁 大连 116024)

摘 要: 针对在非线性机动目标跟踪中存在的滤波器易发散、机动检测有延迟等问题, 把 Unscented Kalman Filter(UKF) 引进到交互多模型算法(IMM) 中, 设计了交互多模型 UKF 滤波器。并利用目标运动模型集概率的相对变化率设计了自适应交互多模型 UKF 滤波器, 最后进行了计算机仿真。蒙特卡罗仿真结果表明, 两种滤波算法都具备 UKF 滤波器精度高、稳定性好、不易发散的优点, 同时不需了解目标机动的先验信息, 适合于实际应用; 并且自适应交互多模型 UKF 滤波器具有更好的跟踪效果。

关 键 词: 机动目标跟踪; 自适应滤波; 交互多模型算法

中图分类号: V271. 4; TN971

文献标识码: A

Two new IMM algorithms for nonlinear maneuvering target tracking

SUN Qing-peng, KONG Xiang-wei, LU Cong-cong, DENG Jiang-an
(Dalian University of Technology, Dalian 116024, China)

Abstract: In nonlinear maneuvering target tracking, the tracking filters are liable to diverge or have detecting delays. To solve the problem, an Interacting Multiple Model(IMM) Unscented Kalman Filter (UKF) is designed by introducing UKF into IMM algorithm. And a new adaptive interacting multiple model UKF algorithm is also designed by using the relative variance ratio of the probability of target motion model set. The Monte Carlo simulation results indicate that both the two proposed IMM filters do not rely on a prior knowledge about the target motion, and have the advantages of high accuracy and good stability. At the same time, they almost do not diverge, which will be effective in real time target tracking. The adaptive interacting multiple model UKF presents better tracking performance.

Key words: maneuvering target tracking; adaptive filter; interacting multiple model algorithm

0 引言

目标跟踪是指对目标的运动状态进行估计和预测。机动目标跟踪系统通常是非线性而且不完全观测的, 因此每一时刻的目标机动性都是高度不确定的。当目标的运动模型简单固定时, 基于均方误差最小准则的 Kalman 滤波器有很好的估计预测效果。但当目标做机动运动时, 模型固定的 Kalman 滤波器就不能对目标状态进行很好的估计。

为了解决这个问题, 常用的方法是采用自适应滤波器。在众多的自适应滤波器当中, Blom 和 Bar-Shalom^[1] 提出的交互多模型跟踪算法(IMM) 是目前性价比最高的机动目标跟踪算法之一。该方法是一种基于“软切换”的机动目标跟踪算法, 对于不同的目标运动状态或同一个目标的不同运动阶段应用不同的模型滤波。各模型滤波器通过估计状态的组合实现相互作用, 模型之间采用马尔科夫链进行切换, 各模型滤波器估计的加权作为最后的滤波状态估计。根据 IMM 算法的思想, 若想使算法对目标跟踪有效, 所选模型集合应该覆盖现实环境中大范围的可能机动, 即模型集合应尽可能大。但是过多模型的使用可能引起模型之间不必要的竞争, 延迟正

收稿日期: 2007-06-29

修回日期: 2007-07-09

作者简介: 孙庆鹏(1982-), 男, 吉林通化人, 硕士生, 主要研究方向为传感器目标跟踪。

确模式的切换,反而可能会降低估计器的性能^[2-3]。目前,大多数应用于非线性系统中的 IMM 算法采用扩展 Kalman 滤波器,该滤波器对非线性函数的 Taylor 展开式进行一阶线性化截断,使其对非线性分布统计量的计算仅具有一阶精度,在跟踪高机动目标时存在着跟踪精度不够高、滤波器易发散等问题。为了改善机动目标跟踪滤波器的性能及稳定性,本文将 Unscented Kalman Filter(UKF)引入到 IMM 算法中,设计了交互多模型 UKF 滤波算法,并利用目标运动模型集概率的相对变化率设计了一种自适应交互多模型 UKF 滤波算法,此自适应滤波算法在跟踪目标过程中能够自动修正模型参数,实时匹配目标运动模式。经 Monte Carlo 仿真,上述两种算法都可以很好地对机动目标进行跟踪,且自适应交互多模型 UKF 滤波算法具有更好的跟踪效果。

1 问题描述及模型选择

目标的机动可以假定为目标在不同的阶段用不同的运动模式,因而机动目标的运动模型可以通过一类具有加性高斯噪声的统计混合系统来描述,这类系统是一个非线性系统,其数学描述如下。

$$X(k) = F(k-1)X(k-1) + G(k-1)$$

$$Z(k) = H(X(k)) + V(k)$$

其中: $X(k)$ 是 k 时刻系统状态变量; $Z(k)$ 是 k 时刻的系统量测变量; $F(k)$ 是系统状态转移矩阵; k 时刻测量方程为 $H(X(k))$; $G(k)$ 是高斯型模型过程白噪声,方差为 $Q(k)$; $V(k)$ 是高斯型量测白噪声,方差为 $R(k)$ 。

当目标机动时,其运动模式不断发生变化。本文选用考虑目标加速及转弯影响的协同转弯模型(CT)^[4],匀速直线运动模型(CV)。目标状态向量由目标在 x 、 y 和 z 方向上的位置和速度分量组成。传感器的量测向量由目标的距离、方位角和俯仰角组成。本文采用实际系统中广泛应用的坐标系设置,即正北方向为 x 轴,正东方向为 z 轴,竖直向上为 y 轴。目标与正北方向的夹角为方位角。系统状态向量、量测向量及 CV 模型和 CT 模型的状态转移矩阵如下所示:

$$X(k) = (x \quad y \quad z \quad \dot{x} \quad \dot{y} \quad \dot{z})$$

$$Z(k) = H(X(k)) = \begin{pmatrix} \sqrt{x^2 + y^2 + z^2} \\ \arccos \frac{x}{\sqrt{x^2 + z^2}} \\ \arcsin \frac{y}{\sqrt{x^2 + y^2 + z^2}} \end{pmatrix}$$

$$F_{cv}(k) = \begin{pmatrix} 1 & 0 & 0 & t & 0 & 0 \\ 0 & 1 & 0 & 0 & t & 0 \\ 0 & 0 & 1 & 0 & 0 & t \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{pmatrix}$$

$$F_{ct}(k) = \begin{pmatrix} 1 & 0 & 0 & \frac{\sin wt}{w} & 0 & \frac{\cos wt - 1}{w} \\ 0 & 1 & 0 & 0 & t & 0 \\ 0 & 0 & 1 & \frac{1 - \cos wt}{w} & 0 & \frac{\sin wt}{w} \\ 0 & 0 & 0 & \cos wt & 0 & -\sin wt \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & \sin wt & 0 & \cos wt \end{pmatrix}$$

利用水平方向的 CT 模型与竖直方向的 CV 模型相结合构成机动模型可以表示空间绝大部分目标(高机动军事目标除外)的机动要求^[5],且计算量适中,具有实用性。

2 UKF 的基本原理

UKF 滤波器是解决非线性滤波问题的一种性能优于 EKF 的滤波器,它不要求求导计算 Jacobian 矩阵,可以处理非可导的非线性函数,对非线性函数统计量的精度至少达到二阶,对于采用特殊的采样策略,如高斯分布四阶采样和偏度采样等可达到更高阶精度^[6],并且不像粒子滤波器存在计算量大及粒子衰退问题^[7],在非线性估计问题中得到了非常广泛应用。UKF 的主要思想是以 UT 变换为基础,利用 UT 变换计算采样点非线性变换之后的均值和方差,利用采样策略近似非线性函数的概率密度分布,在卡尔曼线性滤波框架内,利用确定性采样实现状态滤波。下面先介绍一下 UT 变换,再介绍一下 UKF 的基本滤波过程。

2.1 UT 变换^[8]

无迹变换是解决二阶统计特性非线性转换的一种有效途径,它是基于这样的思想:一个高斯分布可以用一些固定数量的采样点来近似。它的实现原理是:在状态分布中选取一些采样点,使这些点的均值和协方差等于状态分布的均值和协方差;将这些点代入非线性函数中,相应得到非线性函数点集,通过这些点集求取变换后的均值和协方差。这样得到的非线性变换后的均值和协方差精度最少具有二阶精度(Taylor 序列展开)。对于高斯分布,达到三阶精度。

假定状态向量 $x(L$ 维),经过非线性转换到向量 $y, y = g(x)$,假定 x 的均值为 \bar{x} ,协方差矩阵为

P_x 。为了获取 y 的统计量, 选取 $2L+1$ 个采样点 $x_i, i=0, \dots, 2L$, 各点的采样规则如下:

$$\begin{cases} x_0 = \bar{x} \\ x_i = \bar{x} + (\sqrt{(L+\lambda)P_x})_i \quad i=1, \dots, L \\ x_i = \bar{x} - (\sqrt{(L+\lambda)P_x})_i \quad i=L+1, \dots, 2L \end{cases} \quad (1)$$

其中, $(\sqrt{(L+\lambda)P_x})_i$ 为矩阵方根的第 i 列。

由非线性函数 $y_i = g(x_i)$, 可得状态 Y 的点集 $y_i, i=0, \dots, 2L$ 。

Y 的均值和协方差矩阵近似为

$$\begin{cases} \bar{y} \approx \sum_{i=0}^{2L} W_i^{(m)} y_i \\ P_y \approx \sum_{i=0}^{2L} W_i^{(c)} \{y_i - \bar{y}\} \{y_i - \bar{y}\}^T \end{cases} \quad (2)$$

其中

$$\begin{cases} W_0^{(m)} = \lambda / (L+\lambda) \\ W_0^{(c)} = \lambda / (L+\lambda) + (1-\alpha^2 + \beta) \\ W_i^{(m)} = W_i^{(c)} = 1 / \{2(L+\lambda)\} \quad i=1, \dots, 2L \end{cases} \quad (3)$$

为对应的加权系数。

公式(1)、(2)、(3)中 $\lambda = a^2(L+\kappa) - L$ 为一个比例参数, a 决定采样点在 \bar{x} 附近的扩展, 一般置为比较小的正数, κ 为二阶比例参数, 一般置为 0, β 根据 x 的先验分布而设值, 如果 x 服从高斯分布则 β 设为 2。在计算协方差矩阵的平方根时可以利用矩阵的 Cholesky 分解, 即 $A = LL^T$ 。

2.2 UKF 滤波过程^[9]

UKF 以上述的 UT 变换为基础, 采用 Kalman 滤波框架实现状态滤波。在 Kalman 滤波算法中, 对于一步预测方程, 使用无迹变换来处理均值和协方差的非线性传递, 就成为 UKF 算法。

此处为方便描述利用 \hat{x}_k 表示 k 时刻目标状态向量, X_{k-1} 为 $k-1$ 时刻由状态向量和采样点构成的状态矩阵, $X_{i,k|k-1}$ 为矩阵 $X_{k|k-1}$ 的第 i 列向量, W_i 为加权系数。

初始值为

$$\hat{x}_0 = E[x_0], P_0 = E[(x_0 - \hat{x}_0)(x_0 - \hat{x}_0)^T] \quad (4)$$

对于 $k \in \{1, \dots, \infty\}$, 进行 Sigma 采样, 采样点数为 $2L+1$, L 为状态维数:

$$X_{k-1} = [\hat{x}_{k-1} \quad \hat{x}_{k-1} \pm \sqrt{(L+\lambda)P_{k-1}}] \quad (5)$$

状态预测:

$$X_{k|k-1} = F[x_{k-1}, w_{k-1}] \quad (6)$$

$$\hat{x}_k^- = \sum_{i=0}^{2L} W_i^{(m)} X_{i,k|k-1} \quad (7)$$

状态预测协方差矩阵:

$$P_k^- = \sum_{i=0}^{2L} W_i^{(c)} [X_{i,k|k-1} - \hat{x}_k^-] [X_{i,k|k-1} - \hat{x}_k^-]^T + Q \quad (8)$$

量测预测更新:

$$Y_{k|k-1} = H[X_{k|k-1}] \quad (9)$$

$$\hat{y}_k^- = \sum_{i=0}^{2L} W_i^{(m)} Y_{i,k|k-1} \quad (10)$$

其中: $Y_{i,k|k-1}$ 为矩阵 $Y_{k|k-1}$ 的第 i 列向量。

量测残差协方差矩阵:

$$P_{y_k, \hat{y}_k^-} = \sum_{i=0}^{2L} W_i^{(c)} [Y_{i,k|k-1} - \hat{y}_k^-] [Y_{i,k|k-1} - \hat{y}_k^-]^T + R \quad (11)$$

状态量测互协方差矩阵:

$$P_{x_k, \hat{y}_k^-} = \sum_{i=0}^{2L} W_i^{(c)} [X_{i,k|k-1} - \hat{x}_k^-] [Y_{i,k|k-1} - \hat{y}_k^-]^T \quad (12)$$

滤波增益:

$$K_k = P_{x_k, \hat{y}_k^-} P_{y_k, \hat{y}_k^-}^{-1} \quad (13)$$

状态更新:

$$\hat{x}_k = \hat{x}_k^- + K_k(y_k - \hat{y}_k^-) \quad (14)$$

状态误差协方差矩阵更新:

$$P_k = P_k^- - K_k P_{y_k, \hat{y}_k^-} K_k^T \quad (15)$$

3 交互多模型 UKF 滤波器及自适应交互多模型 UKF 滤波器设计

IMM 算法是一种多模型并行算法, 是现阶段口碑最好的机动目标跟踪问题的处理方法之一。以往的 IMM 算法在各系统模型中采用 Kalman 滤波器或扩展 Kalman 滤波器。考虑到现实目标跟踪系统大多数为非线性系统, 以及 UKF 在非线性和跟踪中的高精度且不易发散的特点, 本文将 UKF 引入到 IMM 算法中, 设计了交互多模型 UKF 滤波器和自适应交互多模型 UKF 滤波器。

3.1 交互多模型 UKF 滤波器

IMM 算法可以分为交互输出, 各模型滤波, 输出交互 3 个阶段, 各模型间采用并行计算, 最后加权输出。下面介绍设计的交互多模型 UKF 滤波器的循环滤波过程, 而具体模型的选取将在 3.2 节中的自适应交互多模型算法中一同给出。

假设系统模型集合数为 M , 对 $(\forall j \in M)$:

1) 交互输出:

$$\mu_j \triangleq P\{M_j(k) | Z^{k-1}\} = \sum_i \pi_j \mu_i(k-1) \quad (16)$$

$$\mu_{ij} \triangleq P\left\{M_i(k-1) \mid M_j(k), Z^{k-1}\right\} = \frac{1}{\mu_j} \pi_{ij} \mu(k-1) \quad (17)$$

$$\hat{x}_G(k-1 \mid k-1) \triangleq E\left\{x(k-1) \mid M_j(k), Z^{k-1}\right\} = \sum_i \hat{x}_i(k-1 \mid k-1) \mu_{ij} \quad (18)$$

$$P_G(k-1 \mid k-1) = \sum_i P_i(k-1 \mid k-1) \mu_{ij} + \sum_{\{i,l\}} X_{ilj} \quad (19)$$

式(19)中

$$X_{ilj} \triangleq [\hat{x}_l(k-1 \mid k-1) - \hat{x}_i(k-1 \mid k-1)] [\hat{x}_i(k-1 \mid k-1) - \hat{x}_i(k-1 \mid k-1)]' \mu_{ilj} \mu_{lj} \quad (20)$$

2) 各模型滤波($\forall j \in M$): 将模型 j 的 $\hat{x}_{k-1,j}$ 按式(4)、式(5)进行采样,并按式(6)、式(7)得到状态估计值:

$$\hat{x}_j(k \mid k-1) = \sum_{i=0}^{2L} W_i^{(m)} X_{i,k|k-1,j} \quad (21)$$

按式(8)计算预测协方差矩阵:

$$P(k \mid k-1) = \sum_{i=0}^{2L} W_i^{(c)} \left[X_{i,k|k-1,j} - \hat{x}_{k,j} \right] \times \left[X_{i,k|k-1,j} - \hat{x}_{k,j} \right]^T + Q_j \quad (22)$$

按式(9)、式(10)计算预测量测得残差: $v_j \triangleq z - \hat{y}_{k,j}$ 。

按式(11)、式(12)计算预测误差协方差 S_j , $P_{x_k y_k}$:

$$S_j \triangleq \sum_{i=0}^{2L} W_i^{(c)} \left[Y_{i,k|k-1,j} - \hat{y}_{k,j} \right] \left[Y_{i,k|k-1,j} - \hat{y}_{k,j} \right]^T + R_j \quad (23)$$

各模型滤波器增益:

$$W_j \triangleq P_{x_k y_k, j} P_{y_k y_k, j}^{-1} \quad (24)$$

状态更新:

$$\hat{x}_j(k \mid k) = \hat{x}_{k,j} + W_j (y_{k,j} - \hat{y}_{k,j}) \quad (25)$$

$$P_j(k \mid k) = P_{k,j} - W_j P_{y_k y_k, j} W_j^T \quad (26)$$

似然函数及更新后的模型概率:

$$\Lambda_j = N[v_j; 0, S_j] \quad (27)$$

$$\mu_j = \mu_j^- \Lambda_j / \sum_i \mu_i^- \Lambda_i \quad (28)$$

3) 输出交互:

$$\hat{x}(k \mid k) \triangleq E[x(k) \mid Z^k] = \sum_j \hat{x}_j(k \mid k) \mu_j \quad (29)$$

$$P(k \mid k) \triangleq E\left\{[x(k) - \hat{x}(k \mid k)][x(k) - \hat{x}(k \mid k)]' \mid Z^k\right\} = \sum_j P_j(k \mid k) \mu_j + \sum_{\{i,j\}} X_{ij} \quad (30)$$

式(30)中:

$$X_{ij} \triangleq [\hat{x}_i(k \mid k) - \hat{x}_j(k \mid k)] [\hat{x}_i(k \mid k) - \hat{x}_j(k \mid k)]' \mu_i \mu_j \quad (31)$$

滤波器的目标跟踪过程实质上是利用目标的运动模型方程和量测方程对目标运动的预测和估计过程,所以模型结构与目标真实运动情况的接近程度影响了滤波器的跟踪效果。IMM 算法假设目标有多种运动状态,每一种运动状态对应一种模型,目标在任意时刻的运动状态都可以用给定的模型中的一种或几种来表示,最后加权输出。此种多模型并行估计结构与单模型自适应算法相比,避免了使用机动检测时可能出现的延时现象。再者目标的机动可以假定为目标在不同的阶段适用不同的运动模型,因此可以用 IMM 算法解决机动目标跟踪的问题。

3.2 自适应交互多模型 UKF 滤波器

根据 IMM 算法的思想,为了使 IMM 滤波器具有更好的性能,模型集合的选取应顾及到目标运动状态所有可能的变化情况,即模型集应覆盖目标的所有运动特征。但实际上,由于受计算负荷、滤波性能的制约,过细的模型选取反而可能影响到滤波器性能。上述的交互多模型 UKF 滤波算法虽然在跟踪中使用了 UKF 滤波改善了各模型滤波器的跟踪性能及稳定性,但并没有解决 IMM 算法在模型选取及计算消耗上的矛盾问题。故本文利用运动模型集概率的相对变化率又设计了自适应交互多模型 UKF 滤波器,完成后的滤波器比交互多模型 UKF 滤波器具有更好的跟踪效果。

3.2.1 滤波器系统模型

本文设计的自适应交互多模型 UKF 滤波器是在 3.1 节中介绍的交互多模型 UKF 滤波器的基础上实现的,为方便起见交互多模型 UKF 滤波器在下面也称作 IMM,自适应交互多模型 UKF 滤波器称作 AIMM。二者均采用 3 个系统模型, CV 模型(匀速直线运动模型), CTL 模型(协同左旋转模型), CTR 模型(协同右旋转模型),后两种模型可以通过设定转弯率来得到,即 $w_k^{\text{left}} \in [w_{\min}^{\text{left}}, w_{\max}^{\text{left}}]$, $w_k^{\text{right}} \in [w_{\min}^{\text{right}}, w_{\max}^{\text{right}}]$, 其中, w_{\max}^{left} 和 w_{\max}^{right} 的大小为目标实际最大转弯率, w_{\min}^{left} 和 w_{\min}^{right} 的大小为区别于匀速模型的最小转弯率,且有 $w_{\min}^{\text{left}} < w_{\max}^{\text{left}} < 0 < w_{\min}^{\text{right}} < w_{\max}^{\text{right}}$ 。根据第 1 节中状态转移向量的描述可知, $\lim_{w \rightarrow 0} F_{\text{CT}}(k) = F_{\text{CV}}(k)$ 。所以 3 个模型系统可以将目标机动的情况划分开。

在 $[w_{\min}^{\text{left}}, w_{\max}^{\text{right}}]$ 中,选取具有代表意义的相互对称的转弯率值 $w_{L1}, w_{L2}, w_{L3}, w_{R3}, w_{R2}, w_{R1}$, 作为自适应交互多模型 UKF 滤波器的待选模型集合,且使其满足 $w_{L1} < w_{L2} < w_{L3} < 0 < w_{R3} < w_{R2} < w_{R1}$ 。在左右协同转弯模型中各仅选取 3 种转弯率是由于在实际目标中目标转弯率区间不会很大,且对转弯率区别

过细容易引起模型竞争及混乱。

3.2.2 自适应交互多模型 UKF 滤波器的自适应转换

经过大量的实验验证,当 IMM 滤波器选取匀速直线运动模型和上述任意一对左右转弯率相同的转弯模型组合成为模型集合时,向左旋转模型和向右旋转模型的模型概率可以出现很好的补偿情况,即向左旋转模型的模型概率增大时,向右旋转模型的模型概率会相应减小。针对此特点,利用模型概率的变化趋势,本文设计的自适应过程如下:

首先设定模型自适应参数为

$$\rho = \frac{|P_{CTL} - P_{CTR}|}{1 - P_{CV}} \tag{32}$$

1) 设定模式初始情况为 $w_k^{left} = w_{L2}, w_k^{right} = w_{R2}$, 在每一次 IMM 滤波器完成一次滤波之后检测滤波器的自适应参数 ρ , 若满足 $\rho > t_1$ 则更换 w_k^{left} 和 w_k^{right} 。如果 $P_{CTL} > P_{CTR}$, 则 $w_k^{left} = w_{L1}, w_k^{right} = w_{R3}$, 反之如果 $P_{CTR} > P_{CTL}$, 则 $w_k^{left} = w_{L3}, w_k^{right} = w_{R1}$, 然后进入 IMM 滤波过程。

2) 每一次 IMM 滤波器完成一次滤波之后, 判断 IMM 滤波器模型集是否为初始模型集, 如果是初始模型集则不处理, 跳转到 1)。若变换了模型集, 则判断另一个模型回归系数

$$\eta = \mu_1 \frac{P_{CTL}}{1 - P_{CV}} w_k^{right} + \mu_2 \frac{P_{CTR}}{1 - P_{CV}} w_k^{left} \tag{33}$$

其中: μ_1, μ_2 是微调系数, 值与转弯率区间划分有关, 通常设为 1, 当转弯率区间划分差距较大时可适当调整其大小。如果此时模型集为 $w_k^{left} = w_{L1}, w_k^{right} = w_{R3}$, 若 $\eta > 0$ 则令模型跳转至初始模型。反之, 若 $\eta < 0$ 则令模型跳转至初始模型。算法具体自适应过程如图 1 所示。

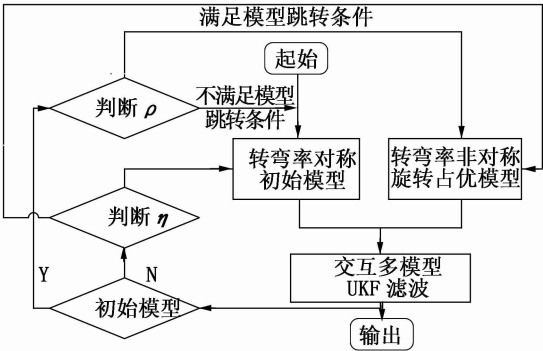


图 1 自适应过程

式(32)和式(33)中采用不同的判别系数是考虑到转弯率小的模型在目标机动发生改变时对模型集的纠正较小; 而设计成两种模型均跳转成初始模式, 是因为目标从一个方向上的机动变到另一个方向上

需要一个转弯率的循序渐变过程, 初始状态为必经历状态。通过实验仿真检验, 此方法合理有效。

4 仿真实验与结果

在三维直角空间中仿真目标, 目标初始位置为 (20 000 m, 2 000 m, 40 000 m), 速度大小为 100 m/s, 运动方向为 x 负方向, 传感器探测到的是距离方位角和俯仰角, 探测误差服从高斯分布, 其标准差分别为(100 m, $1^\circ, 1^\circ$), 采样频率为 1 Hz。目标机动过程见表 1。

表 1 目标机动情况

	水平径向加速度 ($m \cdot s^{-2}$)	转弯率 ($^\circ \cdot s^{-1}$)	竖直速度 (y 负为正方向 ($m \cdot s^{-1}$))
1~ 40 s	0	0	0
40~ 85 s	2	3	0
85~ 100 s	- 2	0	0
100~ 145 s	2	- 3	5
145~ 175 s	0	0	0
175~ 211 s	4	2	4
211~ 230 s	0	0	4
230~ 266 s	- 2	2	0
266~ 300 s	0	0	0

目标运动轨迹的俯视图及空间曲线分别如图 2, 图 3 所示。




图 2 目标 z- x 平面俯视图




图 3 目标三维运动立体图

滤波跟踪性能的评价利用蒙特卡罗仿真常用的评价指标归一化位置误差^[10] (Normalized Position Error, NPE) 来衡量, 其计算方法如下:

$$NPE(n) = \frac{\sqrt{\frac{\sum_{i=1}^N [(x_x^i(n) - \hat{x}_x^i(n))^2 + (x_y^i(n) - \hat{x}_y^i(n))^2 + (x_z^i(n) - \hat{x}_z^i(n))^2]}{N}}}{\sqrt{\frac{\sum_{i=1}^N [(x_x^i(n) - z_x^i(n))^2 + (x_y^i(n) - z_y^i(n))^2 + (x_z^i(n) - z_z^i(n))^2]}{N}}}$$

(34)

其中: $x_x^i(n), x_y^i(n), x_z^i(n)$ 为第 i 次仿真第 n 次采样时目标的笛卡儿空间真实位置, $\hat{x}_x^i(n), \hat{x}_y^i(n), \hat{x}_z^i(n)$ 为第 i 次仿真第 n 次采样时目标经滤波后的笛卡儿空间位置估计值, $z_x^i(n), z_y^i(n), z_z^i(n)$ 为第 i

次仿真第 n 次采样时将目标的观测值转换到笛卡儿空间的值, N 为蒙特卡罗仿真次数, 本文取 100。滤波器对速度的估计效果用速度均方差 VMSE(Velocity Mean Square Error) 表示。

$$VMSE = \frac{\sqrt{\sum_{i=1}^N [(v_x^i(n) - \hat{v}_x^i(n))^2 + (v_y^i(n) - \hat{v}_y^i(n))^2 + (v_z^i(n) - \hat{v}_z^i(n))^2]}}{N}$$

(35)

其中: $v_x^i(n), v_y^i(n), v_z^i(n)$ 为第 i 次仿真第 n 次采样时目标的真实瞬时速度值, $\hat{v}_x^i(n), \hat{v}_y^i(n), \hat{v}_z^i(n)$ 为第 i 次仿真第 n 次采样时目标经滤波后的笛卡儿空间位置估计值。仿真过程中, 模型 1 为 CTL 模型, 模型 2 为 CV 模型, 模型 3 为 CTR 模型。模型转移初始概率设为 p , 它为 IMM 滤波器的初始值, 选取方法为经验值, IMM 算法整体性能对该值的选取并不十分敏感。

$$p = \begin{bmatrix} 0.7 & 0.3 & 0 \\ 0.1 & 0.8 & 0.1 \\ 0 & 0.3 & 0.7 \end{bmatrix}$$

交互多模型 UKF 滤波器的 w_L 和 w_R 分别为 $-2.5(^{\circ})/s$ 和 $2.5(^{\circ})/s$ 。自适应交互多模型 UKF 滤波器的 $w_{L1}, w_{R1}, w_{R2}, w_{L2}, w_{L3}, w_{R3}$ 分别为 $\mp 2(^{\circ})/s$ 、 $\mp 4(^{\circ})/s$ 、 $\mp 6(^{\circ})/s$ 。 $\rho=0.05, \mu_1=\mu_2=1$ 。

实验过程中无发散情况出现。并且从图 4 和图 5 中可以看出, 即使是在图 3 所示的目标高机动情况下, 三模型的交互多模型 UKF 滤波器和自适应交互多模型 UKF 滤波器都可以完成目标跟踪任务, 且自适应交互多模型 UKF 滤波器具有更好的跟踪效果。在速度估计上自适应交互多模型 UKF 滤波器也优于交互多模型 UKF 滤波器。实验数据证明两种方法均有效。




图 4 交互多模型 UKF 滤波器(IMM)和自适应交互多模型滤波器(AIMM)的 NPE 对比

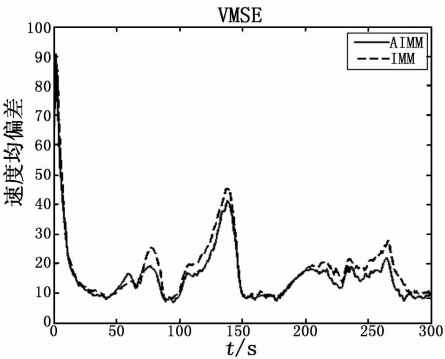


图 5 交互多模型 UKF 滤波器(IMM)和自适应交互多模型滤波器(AIMM)的速度均方值对比

5 结论

本文根据机动目标跟踪的实际应用背景, 分别设计了一种交互多模型 UKF 滤波器, 和自适应交互多模型 UKF 滤波器。通过仿真实验表明, 两种滤波器不仅都具有标准 UKF 的非线性滤波精度高, 稳定度好的优点, 同时能跟踪不同机动类型的目标, 而不需具体了解目标的机动模型。本文算法的设计过程均参照实际情况, 能直接应用到实际非线性系统, 具有很大的实用工程价值。而且通过理论推导过程可以看出, 此两种滤波器与标准 IMM 算法相比都具有同阶计算量。

参考文献:

[1] BLOM H A P, BAR SHALOM Y. The interacting multiple model algorithm for systems with Markovian Switching coefficients[J]. IEEE Trans., 1988, AC233(8): 780-783.

[2] MAZOR E, AVERBUCH A, BAR SHALOM Y, et al. Interacting multiple model methods in targets tracking: a survey[J]. IEEE Trans., on Aerospace and Electronic Systems, 1998, 34(1): 103-123.

(下转第 31 页)

- [2] KAHLIL H K. Nonlinear systems[M]. 2nd ed. Prentice Hall, Upper Saddle River, N J, 1996.
- [3] LIU Y, WU X, ZHU J. Omni directional mobile robot control design by trajectory linearization [C]// Proceedings of the American Control, Denver, 2003: 3423-3428.
- [4] ZHU J J, BANKER D, HALL C E. X-33 ascent flight control design by Trajectory Linearization: a singular perturbation approach[R]. AIAA-2000-4159, 2000.
- [5] BEVACQUA T, BEST E, HUIZENGA A, et al. Improved trajectory linearization flight controller for Reusable Launch Vehicles[R]. AIAA-2004-875, 2004.
- [6] WEI Sun, WANG Yaonan, ZHAI Xiaohua. Adaptive control based on recurrent Fuzzy Wavelet Neural Network and its application on robotic tracking control, advance in neural networks[M]. Springer Berlin Heidelberg, 2006.
- [7] ABIYEV R H. Time series prediction using Fuzzy Wavelet Neural Network model, artificial neural network[M]. Springer Berlin Heidelberg, Greece, 2006.
- [8] 彭金柱, 王耀南, 孙炜. 基于混合学习算法的模糊小波神经网络控制[J]. 湖南大学学报(自然科学版), 2006, 33(2): 51-54.
- [9] 王立新. 自适应模糊系统与控制—设计与稳定性分析[M]. 北京: 国防工业出版社, 1995.
- [10] 郑大钟. 线性系统理论[M]. 2版. 北京: 清华大学出版社, 2002.
- [11] 张春雨. 空天飞行器建模及其自适应轨迹线性化控制研究[D]. 南京: 南京航空航天大学, 2006.
- [12] 朱亮. 空天飞行器不确定非线性鲁棒自适应控制[D]. 南京: 南京航空航天大学, 2006.

(上接第 19 页)

- [3] LI X R, BAR-SHALOM Y. Multiple model estimation with variable structure[J]. IEEE Trans. AC, 1996, 41(4): 478-493.
- [4] LI X R, BAR-SHALOM Y. Design of an interacting multiple model algorithm for tracking in air traffic control systems [J]. IEEE Transactions on Control Systems Technology, 1993, 1(3): 184-194.
- [5] 韩崇昭, 朱红艳, 段战胜, 等. 多源信息融合及应用[M]. 北京: 清华大学出版社, 2006: 135-137.
- [6] JULIER S J, UHLMANN J K. A consistent, unbiased method for converting between polar and Cartesian coordinate systems [C]// The Proc. of AeroSense: The 11th Int. Symposium on Aerospace/ Defense Sensing, Simulation and Controls, Orlando, 1997: 110-121.
- [7] ARULAMPALAM S, MASKEILL S, GORDON N, et al. A tutorial on particle filters for online nonlinear/non-Gaussian Bayesian tracking [J]. IEEE Trans on Signal Processing, 2002, 50(2): 174-188.
- [8] van der MENVE R, WAN E A. The square root unscented Kalman filter for state and parameter estimation [C]// In proceeding of the International Conference on Acoustics, Speech, and Signal processing, salt lake city, Utah, 2001: 3461-3464.
- [9] WU Yuarxin, HU Derwen, WU Meiping, et al. Unscented Kalman filtering for additive noise case: augmented versus nonaugmented[J]. IEEE Singal processing Letters, 2005, 12(5): 357-360.
- [10] 何衍, 郭智疆, 蒋静坪. 自适应交互多模型跟踪算法的模型集设计[J]. 电光与控制, 2002, 9(2): 26-29.

(上接第 25 页)

- [5] SCHUTZ R, ENGELBERG B, SOPER W, et al. Fusion of IFF and radar reports for AEW applications [J]. SPIE, 2003, 5204: 305-317.
- [6] ROBERT R, CARSON Jr, MEYER M P, et al. Fusion of IFF and radar data [C]//IEEE Digital Avionics Systems Conference, 1997: 5.3-9-5.3-15.
- [7] BLASCH E, CONNARE T. Feature aided JBPDAF group tracking and classification using an IFFN sensor [J]. SPIE, 2002, 4728: 208-217.
- [8] 酆能敬. 预警机系统导论[M]. 北京: 国防工业出版社, 1998.
- [9] 赵春玲, 陈峭东, 蓝伟华. 一种提高目标参数估计精度的雷达、红外数据融合方法[J]. 电光与控制, 2001(增刊): 58-62.
- [10] FARINA A, STUDER F A. Radar data processing [M]. Research Studies Press LTD, 1985.
- [11] 何友, 王国宏, 陆大经, 等. 多传感器信息融合及应用[M]. 北京: 电子工业出版社, 2000.
- [12] 王月星, 周德云, 田涛. 机载多传感器跟踪航迹数据融合研究[J]. 电光与控制, 2007, 14(1): 25-29.
- [13] 何友, 修建娟, 张晶炜, 等. 雷达数据处理及应用[M]. 北京: 电子工业出版社, 2006.