

上海交通大学硕士学位论文

基于随机集的多目标联合检测、跟踪和分类

硕 士 研 究 生：	秦彦源
学 号：	1114139009
导 师：	敬忠良 教授
申 请 学 位：	工学硕士
学 科：	控制科学与工程
所 在 单 位：	航空航天学院
答 辩 日 期：	2014 年 1 月
授予学位单位：	上海交通大学

Thesis Submitted to Shanghai Jiao Tong University for
the Degree of Master

**RANDOM SET STATISTICS BASED
MULTI-TARGET JOINT DETECTION,
TRACKING AND CLASSIFICATION**

Candidate:	Qin Yanyuan
Student ID:	1114139009
Supervisor:	Prof. Zhongliang Jing
Academic Degree Applied for:	Master of Engineering
Specialty:	Control Science and Engineering
Affiliation:	School of Aeronautics and Astronautics
Date of Defense:	January, 2014
Degree-Confering-Institution:	Shanghai Jiao Tong University

上海交通大学

学位论文原创性声明

本人郑重声明：所呈交的学位论文《基于随机集的多目标联合检测、跟踪和分类》，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：秦彦源

日期：2014年 1 月 7 日

上海交通大学

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权上海交通大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

保密☐，在___年解密后适用本授权书。

本学位论文属于

不保密☒.

(请在以上方框内打“√”)

学位论文作者签名：秦彦源

指导教师签名：敬建良

日期：2014年1月7日

日期：2014年1月7日

基于随机集的多目标联合检测、跟踪和分类

摘要

随着现代监视环境日益复杂化,人们对侦察系统态势感知能力的要求不断提高。侦察系统的主要功能包括目标检测、跟踪和分类,由于三者是相互关联的过程,利用其耦合关系对提高侦察系统效能具有重要意义。随机集理论作为一种处理多目标跟踪问题的新方法,为实现多目标联合检测、跟踪和分类(JDTC)提供了有效的理论工具。然而,现有基于随机集的 JDTC 算法只处理单传感器应用问题,无法适用于多传感器系统。此外,该算法没有考虑平滑滤波,因此估计和分类性能有待提高。

本论文主要针对多目标 JDTC 中的多传感器融合问题和平滑滤波问题进行探讨,主要研究成果如下:

1. 针对多机动目标联合检测与跟踪问题,提出一种基于模型交互的粒子 PHD 滤波器。该方法多滤波器并行结构清晰,且具有良好的多目标检测与跟踪性能。
2. 针对线性高斯条件下的多传感器 JDTC 问题,提出了一种基于高斯混合概率假设密度滤波器(GM-PHD)的多传感器 JDTC 算法。该算法在单传感器 GM-PHD JDTC 算法基础上,采用序贯融合方法对目标状态和类别信息进行处理,实现多传感器的多目标联合检测、跟踪和分类。
3. 提出了基于粒子概率假设密度滤波器(PF-PHD)的多传感器 JDTC 算法,处理非线性、非高斯条件下的多传感器 JDTC 问题。针对目标属性量测提取问题,提出了一种基于雷达回波信噪比的属性量测建模方法。

4. 为提高多目标 JDTC 效果, 在 PHD-JDTC 算法基础上, 采用平滑滤波方法, 推导了基于前向-后向平滑 PHD 的多目标 JDTC 算法, 并给出了粒子实现方法。仿真结果验证了该算法在目标检测、跟踪和类别判断方面的优势。

关键词: 随机集, 概率假设密度滤波器, 联合检测、跟踪和分类,
多传感器信息融合, 平滑滤波

RANDOM SET STATISTICS BASED MULTI-TARGET JOINT DETECTION, TRACKING AND CLASSIFICATION

ABSTRACT

As the increasing complexity of the surveillance environment, the requirement for the surveillance system is much higher than before. There are three main functions for surveillance system, which are target detection, state estimation and classification decision, respectively. As these functions are tightly coupled with each other, it is advantageous to combine them to improve the performance of surveillance system. The theory of Random Finite Set (RFS) is a novel method for target tracking, which actually provides an efficient framework for joint detection, tracking and classification (JDTC). However, the RFS-based JDTC algorithms are only suitable for the single sensor application, and the multi-sensor JDTC is still left open. In addition, these algorithms neglect the smoothing procedure, which will definitely improve their overall performance.

In this paper, we focus on the multi-sensor fusion and smoothing problems in JDTC based on RFS. The main contributions of this thesis are summarized as follows:

- 1 The model interaction PFPHD filter are proposed for multiple maneuvering target detection and tracking, which is characterized with explicit multi-model parallel structure and excellent performance in target detection and tracking.
- 2 In order to solve multi-sensor JDTC problem under the linear Gaussian condition, a multi-sensor JDTC algorithm is proposed based on Gaussian mixture Probability Hypothesis Density (GMPHD). The single sensor GMPHD JDTC algorithm is generalized to multisensor scenario with iterated fusion.

- 3 Based on particle filter Probability Hypothesis Density (PFPHD), a multisensory PFPHD JDTC algorithm is proposed, which is applicable to the nonlinear non-Gaussian JDTC problem. For the extracting of feature measurement, a novel method is obtained on the basis of the radar signal's SNR.
- 4 For performance enhancement of JDTC algorithm, the smoothing technique is incorporated. Based on the PHD forward-backward smoother, the PHD-JDTC forward-backward smoothing algorithm is derived and its particle implementation is presented further. Simulation results confirm improved performance of proposed algorithm in multi-target detection, tracking and classification.

KEY WORDS: Random Set, Probability Hypothesis Density Filter, Joint Detection Tracking and Classification, Multi-sensor Fusion, Smoother

目 录

第一章 绪论	1
1.1 研究背景及意义	1
1.2 研究现状及发展趋势	2
1.3 论文的主要内容	5
第二章 基于随机集的贝叶斯滤波理论	7
2.1 引言	7
2.2 最优多目标贝叶斯滤波器	7
2.3 PHD 滤波器	8
2.3.1 高斯混合 PHD 滤波器	9
2.3.2 粒子 PHD 滤波器	11
2.4 PHD 滤波器仿真实验	12
2.4.1 GM-PHD 仿真实验	12
2.4.2 PF-PHD 仿真实验	14
2.5 多目标跟踪滤波器评价指标	16
2.6 本章小结	16
第三章 基于模型交互的粒子 PHD 多目标联合检测与跟踪	18
3.1 引言	18
3.2 多模型 PHD 滤波器	18
3.2.1 多模型 PHD 滤波器原理	18
3.2.2 多模型 PHD 滤波器粒子实现方法	19
3.3 模型交互的粒子 PHD 实现方法	21
3.4 算法仿真	22
3.5 本章小结	25
第四章 基于 GMPHD 的多传感器联合检测、跟踪和分类算法	27
4.1 引言	27
4.2 多传感器联合检测、跟踪和分类问题描述	27
4.3 基于 GMPHD 的单传感器联合检测、跟踪和分类算法	28
4.4 基于序贯 GMPHD 的多传感器联合检测、跟踪和分类算法	29
4.4.1 假设条件	29

4.4.2 算法描述	30
4.5 数值仿真	31
4.6 本章小结	36
第五章 基于 PFPHD 的多传感器联合检测、跟踪和分类算法	37
5.1 引言	37
5.2 基于 PFPHD 的单传感器联合检测、跟踪和分类算法	37
5.3 基于序贯 PFPHD 的多传感器联合检测、跟踪和分类算法	39
5.4 属性量测提取	40
5.5 数值仿真	42
5.6 本章小结	47
第六章 基于前向-后向平滑 PHD 的联合检测、跟踪和分类	48
6.1 引言	48
6.2 PHD 前向-后向平滑器	48
6.3 基于前向-后向平滑 PHD 的联合检测、跟踪和分类	49
6.3.1 跳变马尔科夫 PHD 滤波器	49
6.3.2 跳变马尔科夫 PHD 平滑器	50
6.3.3 PHD-JDTC 滤波器	51
6.3.4 PHD-JDTC 平滑器	52
6.4 类别相关模型集的 PHD-JDTC 前向-后向平滑器	54
6.4.1 算法概述	54
6.4.2 粒子实现方法	54
6.5 数值仿真	56
6.6 本章小结	63
第七章 总结与展望	64
7.1 工作总结与创新点	64
7.2 研究展望	65
参 考 文 献	66
致 谢	70
攻读硕士学位期间已发表或录用的论文	71

图 录

图 1-1 联合估计与决策原理图	3
图 2-1 高斯混合 PHD 目标真实航迹图	13
图 2-2 高斯混合 PHD 滤波器估计结果图	14
图 2-3 杂波数目增加后高斯混合 PHD 滤波器估计结果图	14
图 2-4 粒子 PHD 目标真实航迹图	15
图 2-5 粒子 PHD 滤波器估计结果图	16
图 3-1 模型交互的粒子 PHD 实现流程	21
图 3-2 多模型 PFPHD 目标运动场景	24
图 3-3 不同算法目标数目估计对比图	24
图 3-4 不同算法 OSPA 距离对比图	25
图 4-1 多传感器 GMPHD-JDTC 目标运动场景图	33
图 4-2 LGJMS-GMPHD 算法滤波结果图	33
图 4-3 LGJMS-GMPHD-JDTC 算法滤波结果图	34
图 4-4 Iterated-LGJMS-GMPHD 算法滤波结果图	34
图 4-5 Iterated-LGJMS-GMPHD-JDTC 算法滤波结果图	34
图 4-6 不同算法目标数目估计误差对比图	35
图 4-7 不同算法 OSPA 距离对比图	35
图 5-1 归一化的杂波和目标信号幅值似然函数图	41
图 5-2 多传感器 PFPHD-JDTC 目标运动场景图	42
图 5-3 MM-PFPHD 滤波结果	44
图 5-4 MM-PFPHD-JDTC 滤波结果	44
图 5-5 Iterated-MM-PFPHD 滤波结果	45
图 5-6 Iterated-MM-PFPHD-JDTC 滤波结果	45
图 5-7 不同算法目标数目估计对比图	46
图 5-8 不同算法 OSPA 距离对比图	46
图 6-1 PHD-JDTC 前向-后向平滑流程图	54
图 6-2 PHD-JDTC 前向-后向平滑仿真场景示意图	60
图 6-3 PHD-JDTC 前向-后向平滑滤波结果	60
图 6-4 第一类目标数目估计误差对比图	61

图 6-5 第二类目标数目估计误差对比图	61
图 6-6 第一类目标 OSPA 距离对比图	61
图 6-7 第二类目标 OSPA 距离对比图	62
图 6-8 所有类别目标 OSPA 距离对比图	62

第一章 绪论

1.1 研究背景及意义

在军用和民用领域，监视系统能够利用传感器探测环境信息，实现态势感知^[1-3]。在民用方面，监视系统主要包括空中交通管理系统、海上交通管理系统、安防监控以及智能服务机器人等。而在军用领域，侦察跟踪系统广泛应用于弹道导弹防御、领土防空、空中平台攻击、机载预警系统、地面空袭预警、海上威胁探测和战场态势感知等领域^[4, 5]。

监视跟踪系统主要完成目标检测、目标跟踪和目标识别分类三种工作。具体来说，目标检测步骤主要判断目标是否存在，若存在则进一步对目标个数进行估计；目标跟踪过程基于目标运动模型，采用最优估计的方法对目标方位、距离以及速率等状态信息进行估计，降低由传感器量测引入的随机噪声；最后，目标识别是根据特征量测信息，决策目标所属类别。

传统监视系统设计方法将检测、跟踪和分类各个阶段独立进行研究，但是目标检测问题、跟踪问题和分类问题是相互关联和影响的。首先，目标的类别决定了目标的运动特性，而运动特性又对准确的目标跟踪来说非常重要。其次，通过目标的运动特性可以进一步对目标的类别进行判断，比如机动性较大的目标更有可能是战斗机等军用飞机，而机动性较小的目标可能是民用飞机。最后，如果目标数目的变化，则整个目标跟踪和分类过程都会发生改变。如果能够将检测、跟踪和分类作为一个整体进行考虑，充分利用不同过程间相互作用关系，可以提高监视系统效能。

联合检测、跟踪和分类本质上是联合检测、估计与决策问题。目标的跟踪是一个估计过程，即在连续空间上确定系统的状态；目标的分类属于决策过程，是从离散空间中做出一个选择，而检测过程则是进行估计和决策的基础。

对跟踪问题来说，目标数目可能随着时间变化而发生改变。在每一时刻目标有可能产生、继续存在或者消失。而传感器接收到的信号可能来自于杂波而非真实目标，也可能传感器无法得到目标信号出现漏检的情况。以往的目标跟踪方法对目标航迹和量测数据进行概率匹配，即采用数据关联的方法将多目标跟踪问题进一步简化成单个目标跟踪问题，然后采用经典的方法如卡尔曼滤波器等进行滤波估计。常用的数据关联方法包括最近邻（Nearest Neighbor）、概率数据关联

(Probabilistic Data Association)、全局最近邻 (Global Nearest Neighbor)、联合概率数据关联 (Joint Probabilistic Data Association) 和多假设跟踪 (Multiple Hypothesis Tracking)。这些传统方法都是基于目标和量测关联的思想。但是所谓的数据关联方法在数学基础上存在大量的理论问题, 同时关联假设的数量随着目标和量测数目的增加而急剧增加, 计算量迅速提高^[3]。目前现有监视系统基本上采用这些数据关联的方法, 所以在实际应用中存在许多问题, 具有一定局限性。

近年来, 有学者将随机集理论应用到目标跟踪领域, 提出了以随机集为理论基础的多目标最优 Bayes 滤波器^[6]。这种方法将随机状态向量以及量测向量采用随机有限集进行表示, 从而将杂波和数据关联不确定条件下目标检测和跟踪问题融入到一个贝叶斯滤波框架内^[7]。最优多目标贝叶斯滤波器可以从单目标贝叶斯滤波器推广得到, 该方法避免了量测和航迹数据关联过程, 省去了数据关联所需要的庞大计算量, 降低运算复杂度。

随着现代监视环境复杂程度的提高, 联合检测、跟踪和分类是未来监视系统设计领域发展的主要方向。随机有限集理论为解决这一问题提供了新的理论框架。将类别信息引入到多目标贝叶斯滤波器中, 能够实现估计与决策的双向交互。这种技术方法对于增强监视系统的环境感知能力具有重大的理论和实践意义。

1.2 研究现状及发展趋势

联合检测、估计与决策方法^[10]可以分为三个子课题: 1) 联合检测与估计 (Joint Detection Estimation, JDE); 2) 联合估计与决策 (Joint Estimation Decision, JED); 3) 联合检测、估计与决策 (Joint Detection Estimation and Decision, JDED)。

1) 联合检测与估计

传统的目标联合检测和估计主要是综合经典的滤波技术和数据关联方法。然而, 这类方法存在运算量过大等缺点。随机有限集理论为多目标联合检测与跟踪问题提供了新的理论工具。随机集方法的核心在于目标个数和状态都是随机变量, 因此可以用于建立目标数目和状态同时变化的模型。在随机集的理论框架下, 研究人员提出了概率假设密度 (PHD) 滤波器, 并结合粒子滤波和高斯混合滤波的思想, 得到了 PHD 滤波器的算法实现^[8,9]。此时的 PHD 滤波结果不具有航迹信息, 如果进一步采用航迹标签法^[10]或结合多假设跟踪 (MHT) 等方法^[11]就可以实现 PHD 滤波器的航迹关联。

2) 联合估计与决策

通常情况下，目标通过位置传感器量测对目标的状态进行估计，而目标属性或者类别信息需要通过如电子支援措施、敌我识别器和合成孔径雷达等分类器输出得到。这两个过程通常作为独立的过程进行处理，其原因在于每个传感器的任务不同，数据格式也不相同。另外，状态估计和类别决策涉及到的方法也不一样。如前所述，目标跟踪和目标分类从统计推断上即估计与决策过程^[12]。以往的方法先进行决策过程，然后再对目标进行估计，即估计前先决策的方法。对目标完成分类后，再对目标进行跟踪滤波。传统的估计方法如卡尔曼滤波、扩展卡尔曼滤波和粒子滤波等都需要先进行正确的决策，如果目标的类别能够判断正确，则跟踪也会产生比较好的结果；如果类别的判断错误，则滤波可能发散，不能够有效的跟踪目标。相反，另一种处理方法是先进行跟踪，再进行分类，即先估计决策方法，这种方法在决策影响估计的条件下也容易产生估计不准的问题^[13]。

随着监视系统的不断升级与发展，监视系统不仅要目标的位置、速度和加速度进行有效的估计，而且要具备目标类别决策能力。将两者进行综合考虑的出发点就是跟踪器和分类器间的耦合作用，对目标类别的判断能够传递给滤波器提高对目标的状态估计能力（目标类别决定目标可能采取的机动样式）。与此同时，目标的状态估计结果也能够用来对类别信息进行判断，增强类别决策能力（速度、加速度等轨迹包络，决定了目标的类别）。跟踪与分类之间的这种相互辅助关系已经得到监视系统设计人员的广泛认可^[14]，相关的研究也日益活跃。联合估计与决策结构^[15]如图 1-1 所示。

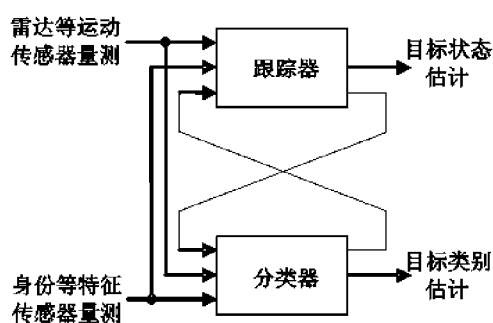


图 1-1 联合估计与决策原理图

Fig.1-1 Diagram of Joint Estimation and Decision principle

根据所使用理论方法的不同，联合估计与决策算法可以划分为贝叶斯方法、Dempster-Shafer (D-S) 推理方法以及贝叶斯风险方法。

贝叶斯联合估计与决策方法^[12]以 Bayes 原理为基础，综合目标状态似然函数和类别似然函数构造联合似然函数。该方法对贝叶斯滤波器与分类器进行整体考

虑, 引入传感器量测后得到目标状态和类别联合概率密度函数。进而通过这一联合概率密度函数能够得到目标类别信息与状态信息。然而, 该方法很难得到联合概率密度函数的最优解, 一般需要通过序贯蒙特卡洛方法来解决这一问题。

基于 D-S 推理的联合估计与决策方法以转移信任模型 (Transfer Belief Model, TBM) [16][23] 为理论框架, 采用 Shafer 信任函数描述目标状态和属性信息分布。基于转移信任模型, 将 Bayes 滤波进行推广从而得到广义滤波器。而目标类别信息的判断主要根据广义的 Bayes 理论与 Pignistic 变换 [17]。

基于贝叶斯风险的方法 [18] 借鉴于模式识别领域的分类方法, 通过最小化跟踪与分类贝叶斯风险实现最优联合决策与估计。

上述几种方法中, 基于贝叶斯推理的联合估计与决策方法已有许多研究成果, 相对而言, 基于证据推理与贝叶斯风险的联合估计与决策方法则尚未完善, 需要进一步研究和丰富。

3) 联合检测、估计与决策

联合检测、估计与决策 [19][25] 将目标检测、跟踪和识别三个方面统一进行考虑。三者的综合化是未来侦察监视系统研究的重点领域。通过将连续分量和离散分量组合成统一的向量, Driessen [20] 给出了混合估计的理论方法, 在该方法中目标的综合状态向量包括连续分量和离散分量, 分别对应于目标运动状态和属性信息。在系统满足一定条件下, 该方法可以实现目标联合检测、跟踪与识别。

随机集理论为目标联合检测、跟踪和分类提供了一种有效的理论工具。即在 PHD 滤波器基础上引入决策信息, 可以实现目标联合检测、估计与决策 [21]。Zajic [22] 基于有限随机集理论提出了一种目标联合检测、估计与决策方法, 将目标特征信息扩充到 PHD 滤波器中, 实现了检测、跟踪和分类一体化。Peter Willett [23] 等提出了类别辅助的多模型基数 PHD 滤波器 (CA-MM-CPHD) 实现了对多机动目标检测、估计与决策。杨威等 [21] 同样将随机集的方法应用到单传感器联合检测与估计、联合估计与决策、联合检测、估计与决策中, 展现了随机集理论的潜在优势。

联合检测、估计和决策必然涉及到多传感器问题 [24], 而随机集理论在多传感器领域也在迅速发展, 将随机集方法在多传感器背景下进行联合检测、估计和决策, 是未来该领域发展的重要技术路线。尽管目前多传感器 PHD 没有严格的解决方法, 但是序贯融合是比较有效的近似途径。序贯 PHD 滤波器已经应用到雷达与红外联合检测与跟踪领域。张洪建 [25] 利用 GM-PHD 滤波器的矩阵表达形式, 得到了能够处理观测区域不一致时的多传感器跟踪问题。王洋 [26] 基于随机集 IPDA 滤波器推导出了适用于多传感器序贯 IPDA 滤波器算法。并且在多传感器序贯 IPDA

滤波器基础上研究了不同性能的多传感器处理序列问题，得到了不同性能的多传感器的最优处理序列。在随机集框架下，利用不同传感器得到的类别信息，将多传感器融合与估计决策联合考虑，可以进一步提升系统的整体效果。另外，多传感器融合技术还包括分布式、混合式融合等处理方法^[3]。分布式方法能够进行独立滤波，实现更为准确、全面的估计与决策，在总体性能上具有优势。如果将基于随机集的联合估计与决策推广到分布式多传感器领域，可能得到更好的效果。

目前在基于随机集的目标跟踪领域的研究热点包括群目标（Group target）跟踪^[27]，扩展目标（Extended target）跟踪^[28]、PHD 滤波器的新生目标检测技术^[29]，噪声统计特性不确定的 PHD 滤波器^[30]、带平滑的 PHD 滤波器^[31]以及非高斯情况下的粒子 PHD 的状态提取的优化^[32]等。这些研究方向不断涌现的理论成果对多目标联合检测、估计与决策算法具有重要的借鉴意义。

1.3 论文的主要内容

本文主要以随机有限集理论为研究基础，解决多传感器背景下的联合检测、跟踪和分类问题和平滑优化的联合检测、跟踪和分类问题，进一步提高联合算法效果。本文研究内容如下：

第一章，绪论。简要介绍了联合检测、估计（跟踪）与决策（分类）的基本概念和目前研究进展情况。然后对随机集理论在多目标跟踪领域的应用进行了分析。为后文在随机集基础上对目标进行联合检测、跟踪和分类奠定了基础。

第二章，介绍随机集的基本理论。在介绍多目标贝叶斯滤波器的基础上，得到概率假设密度滤波器。然后给出概率假设密度滤波器的两种实现方法，即满足线性高斯假设的高斯混合 PHD（GMPHD）以及适用范围更广的粒子滤波 PHD（PFPHD）。

第三章，探究模型交互的 PHD 多目标联合检测与跟踪。简化粒子模型跳转步骤，利用粒子交互增加粒子数目，对目标状态进行更准确的估计。

第四章，研究以 GMPHD 为基础的多传感器联合检测、跟踪和分类算法。给出了多传感器联合检测跟踪和分类问题的数学描述，介绍了基于扩维方法的 GMPHD 单传感器 JDTC 算法，结合序贯融合方法实现该方法从单传感器到多平台的推广。

第五章，研究以 PFPHD 为基础的多传感器联合检测、跟踪和分类算法。同样根据多传感器信息融合思想实现 PFPHD 联合检测、估计与决策方法从单传感器到多传感器的扩展。

第六章，考虑加入平滑的 PHD 联合检测、跟踪和分类问题。利用自顶向下的方法对基本的 PHD 前向-后向平滑器进行运动模型和目标类别信息扩展，推导类别模型集相关条件下前向-后向平滑的 PHD-JDTC。

第七章，总结和展望。总结了本文的研究工作，进一步对以后的研究内容和方向进行探讨。

第二章 基于随机集的贝叶斯滤波理论

2.1 引言

单目标跟踪考虑利用杂波量测进行单个目标状态估计，而多目标跟踪涉及到目标数目变化和量测的不确定性，因此更具有挑战性。解决该问题的一种方法是找到量测和目标间的关联关系，然后对关联后的量测对单个目标状态进行估计。多假设跟踪（MHT）为量测序列建立所有可能的关联假设；联合概率数据关联给不同量测赋予不同的权重，进行状态与量测的软关联。然而这些基于数据关联的跟踪方法都要对量测和目标进行组合排列，因此运算时间较长^[4]。

多目标跟踪问题中状态和量测可以采用随机有限集（RFS）进行建模，进一步可以从单目标贝叶斯滤波器推广得到多目标贝叶斯滤波器。但是，多目标贝叶斯滤波器需要进行随机集的集合积分，是不能直接应用的。概率假设密度滤波器通过近似随机有限集的一阶矩，提供了一种计算量上可以实现的多目标贝叶斯滤波方法。目标的状态和目标的数目可以通过 PHD 表面进行提取。概率假设密度滤波器有两种近似方法，一种是高斯混合概率假设密度（GMPHD）滤波器，另一种是粒子概率假设密度（PPFHD）滤波器。

本章首先建立随机集框架下的多目标运动模型得到多目标贝叶斯滤波器，然后分别介绍高斯混合 PHD 滤波器和粒子 PHD 滤波器，最后给出一种多目标滤波器的性能衡量指标。

2.2 最优多目标贝叶斯滤波器

假设在 k 时刻，单目标状态空间 E_s 包含 $M(k)$ 个目标 $x_{k,1}, \dots, x_{k,M(k)}$ ，并进一步表示为随机集合形式 $X_k = \{x_{k,1}, \dots, x_{k,M(k)}\} \in \mathcal{F}(E_s)$ ，其中 $\mathcal{F}(E)$ 由空间 E 内全部有限子集构成。假设单目标量测空间 E_o 包含 $N(k)$ 个量测 $z_{k,1}, \dots, z_{k,N(k)}$ ，相应的多目标量测随机集合表示为 $Z_k = \{z_{k,1}, \dots, z_{k,N(k)}\} \in \mathcal{F}(E_o)$ 。

假设 $k-1$ 时刻多目标运动状态表示为 X_{k-1} ，下一时刻多目标状态随机集包含三种目标，即已存在目标，衍生目标和新生目标。公式形式表示如下：

$$X_k = \left[\bigcup_{x \in X_{k-1}} S_{k|k-1}(x_{k-1}) \right] \cup \left[\bigcup_{x \in X_{k-1}} B_{k|k-1}(x_{k-1}) \right] \cup \Gamma_k \quad (2.1)$$

式中， $S_{k|k-1}(x_{k-1})$ 是已存在目标状态随机集， Γ_k 是新生目标状态随机集， $B_{k|k-1}(x_{k-1})$ 是衍生目标状态随机集。

多目标量测可以表示为随机集形式如下：

$$Z_k = \left[\bigcup_{x \in X_k} \Theta_k(x) \right] \cup K_k \quad (2.2)$$

式中， $\Theta_k(x)$ 表示目标产生的量测对应的随机集，当目标漏检时 $\Theta_k(x)$ 为 \emptyset ，否则取为 $\{z_k\}$ ，杂波对应的随机集为 K_k 。

在随机有限集的基础上，多目标贝叶斯滤波器可以进一步表示为：

$$p_{k|k-1}(X_k | Z_{1:k-1}) = \int f_{k|k-1}(X_k | X) p_{k-1}(X | Z_{1:k-1}) \mu_s(dX) \quad (2.3)$$

$$p_k(X_k | Z_{1:k}) = \frac{g_k(Z_k | X_k) p_{k|k-1}(X_k | Z_{1:k-1})}{\int g_k(Z_k | X) p_{k|k-1}(X_k | Z_{1:k-1}) \mu_s(dX)} \quad (2.4)$$

上述多目标贝叶斯滤波器中包含对随机有限集的积分，所以不能得到封闭解。此外，有时随机有限集的条件期望不存在。因此，最优多目标贝叶斯滤波器不能直接应用。Mahler 将随机点过程中的期望概念应用到随机有限集中，称之为概率假设密度 (PHD)。借助于随机有限集的概率假设密度，可以得到一阶矩 PHD 滤波器。

2.3 PHD 滤波器

k 时刻，多目标密度概率假设密度 $D_{k-1|k-1}$ 为多目标状态随机集的一阶矩，通过在状态空间内进行积分可以得到期望的目标数目。一个完整的滤波过程包括状态预测和状态更新两个步骤。

(1) 状态预测步骤：

在多目标跟踪问题中，单目标状态表示为 x ，目标生存概率记为 $p_{S,k-1}$ 。目标能够在概率假设密度为 $\beta_{k|k-1}(x|\zeta)$ 的条件下，衍生出新的目标。同时，新生目标的概率假设密度为 $\gamma_{k-1}(x)$ 。最后，PHD滤波器的状态预测可以表示为

$$D_{k|k-1}(x) = \int p_{S,k-1}(\zeta) f_{k|k-1}(x|\zeta) d\zeta + \int \beta_{k|k-1}(x|\zeta) D_{k-1|k-1}(\zeta) d\zeta + \gamma_{k-1}(x) \quad (2.5)$$

(2) 状态更新步骤:

$$D_{k|k}(x) = [1 - p_{D,k}(x)] D_{k|k-1}(x) + \sum_{z \in Z_k} \frac{p_{D,k}(x) g_k(z|x) D_{k|k-1}(x)}{\kappa_k(z) + \int p_{D,k}(\zeta) g_k(z|\zeta) D_{k|k-1}(\zeta) d\zeta} \quad (2.6)$$

式中, $g_k(z|x)$ 表示单个目标的量测似然函数, $p_{S,k}(\zeta)$ 表示目标生存概率, $p_{D,k}(\zeta)$ 是传感器检测到目标的概率, $\kappa_k(\cdot)$ 表示量测杂波对应的强度函数。

由于单个目标强度函数与状态空间相同, 概率假设密度的计算需要更小的计算量。然而, 上述迭代滤波过程涉及到多重积分, 也没有封闭形式。所以需要采用近似方法进行表示, 近似方法包括高斯混合方法和粒子滤波方法。

2.3.1 高斯混合 PHD 滤波器

高斯混合概率假设密度滤波器通过高斯混合元近似代替目标的概率假设密度, 是一种概率假设密度滤波器的封闭解^[9]。概率假设密度滤波器的高斯混合近似形式需要满足以下三个限定条件:

(1) 状态预测方程与传感器量测方程都满足线性高斯条件

$$f_{k|k-1}(x|\zeta) = \mathcal{N}(x; F_{k-1}\zeta, Q_{k-1}) \quad (2.7)$$

$$g_k(z|x) = \mathcal{N}(z; H_k x, R_k) \quad (2.8)$$

式中, $\mathcal{N}(\cdot; m, P)$ 表示均值为 m , 方差为 P 的正态分布, F_{k-1} 表示目标状态转移矩阵, Q_{k-1} 表示目标状态方程的过程噪声协方差, H_k 表示传感器的量测矩阵, R_k 为量测噪声协方差。

(2) 目标状态与目标的生存以及检测概率不相关, 即:

$$p_{S,k}(x) = p_{S,k} \quad (2.9)$$

$$p_{D,k}(x) = p_{D,k} \quad (2.10)$$

(3) 采用高斯元近似的新生、衍生目标的概率假设密度的强度

$$\gamma_k(x) = \sum_{i=1}^{J_{\gamma,k}} w_{\gamma,k}^{(i)} \mathcal{N}(x; m_{\gamma,k}^{(i)}, P_{\gamma,k}^{(i)}) \quad (2.11)$$

$$\beta_{k|k-1}(x|\zeta) = \sum_{j=1}^{J_{\beta,k}} w_{\beta,k}^{(j)} \mathcal{N}(x; F_{k-1}\zeta + m_{\beta,k}^{(j)}, P_{\beta,k}^{(j)}) \quad (2.12)$$

式中, $J_{\gamma,k}$, $w_{\gamma,k}^{(i)}$, $m_{\gamma,k}^{(i)}$ 以及 $P_{\gamma,k}^{(i)}$, $i=1, \dots, J_{\gamma,k}$ 为新生目标强度的相关参数; 而 $J_{\beta,k}$, $w_{\beta,k}^{(j)}$, $m_{\beta,k}^{(j)}$ 以及 $P_{\beta,k}^{(j)}$, $j=1, \dots, J_{\beta,k}$ 为衍生目标强度函数的相关参数。

满足以上三个前提条件后, 高斯混合概率假设密度滤波器的迭代方程可以表示如下:

(1) 概率假设密度预测

在 $k-1$ 时刻, 目标状态后验 PHD 可以表示为

$$v_{k-1}(x) = \sum_{i=1}^{J_{k-1}} w_{k-1}^{(i)} \mathcal{N}(x; m_{k-1}^{(i)}, P_{k-1}^{(i)}) \quad (2.13)$$

进而, 下一时刻目标预测的 PHD 同样可以采用高斯元进行近似:

$$v_{k|k-1}(x) = v_{S,k|k-1} + v_{\beta,k|k-1} + \gamma_k(x) \quad (2.14)$$

式中,

$$v_{S,k|k-1}(x) = p_{S,k} \sum_{i=1}^{J_{k-1}} w_{k-1}^{(i)} \mathcal{N}(x; m_{S,k|k-1}^{(i)}, P_{S,k|k-1}^{(i)}) \quad (2.15)$$

$$m_{S,k|k-1}^{(i)} = F_{k-1} m_{k-1}^{(i)} \quad (2.16)$$

$$P_{S,k|k-1}^{(i)} = Q_{k-1} + F_{k-1} P_{k-1}^{(i)} F_{k-1}^T \quad (2.17)$$

$$v_{\beta,k|k-1}(x) = \sum_{i=1}^{J_{k-1}} \sum_{j=1}^{J_{\beta,k}} w_{k-1}^{(i)} w_{\beta,k}^{(j)} \mathcal{N}(x; m_{\beta,k|k-1}^{(i,j)}, P_{\beta,k|k-1}^{(i,j)}) \quad (2.18)$$

$$m_{\beta,k|k-1}^{(i,j)} = F_{\beta,k-1}^{(j)} m_{k-1}^{(i)} + m_{\beta,k-1}^{(j)} \quad (2.19)$$

$$P_{\beta,k|k-1}^{(i,j)} = P_{\beta,k-1}^{(j)} + F_{\beta,k-1}^{(j)} P_{k-1}^{(i)} (F_{\beta,k-1}^{(j)})^T \quad (2.20)$$

(2) 概率假设密度更新

在 k 时刻, 预测 PHD 采用高斯混合元近似为

$$v_{k|k-1}(x) = \sum_{i=1}^{J_{k|k-1}} w_{k|k-1}^{(i)} \mathcal{N}(x; m_{k|k-1}^{(i)}, P_{k|k-1}^{(i)}) \quad (2.21)$$

进而, 目标的后验概率假设密度为

$$v_k(x) = (1 - p_D) v_{k|k-1}(x) + \sum_{z \in Z_k} v_{D,k}(x; z) \quad (2.22)$$

式中,

$$v_{D,k}(x; z) = \sum_{i=1}^{J_{k|k-1}} w_k^{(i)} \mathcal{N}(x; m_{k|k}^{(i)}(z), P_{k|k}^{(i)}) \quad (2.23)$$

$$w_k^{(i)} = \frac{p_{D,k} w_{k|k-1}^{(i)} q_k^{(i)}(z)}{\kappa_k(z) + p_{D,k} \sum_{j=1}^{J_{k|k-1}} w_{k|k-1}^{(j)} q_k^{(j)}(z)} \quad (2.24)$$

$$q_k^{(j)}(z) = \mathcal{N}(z; H_k m_{k|k-1}^{(j)}, R_k + H_k P_{k|k-1}^{(j)} H_k^T) \quad (2.25)$$

$$m_k^{(i)}(z) = m_{k|k-1}^{(i)} + K_k^{(i)}(z - H_k m_{k|k-1}^{(i)}) \quad (2.26)$$

$$P_k^{(i)} = [I - K_k^{(i)} H_k] P_{k|k-1}^{(i)} \quad (2.27)$$

$$K_k^{(i)} = P_{k|k-1}^{(i)} H_k^T (H_k P_{k|k-1}^{(i)} H_k^T + R_k)^{-1} \quad (2.28)$$

2.3.2 粒子 PHD 滤波器

概率假设密度 (PHD) 滤波器在传递过程中包含集合的积分, 实际中无法找到最优的解析解。可以将 Sequential Monte Carlo 思想引入到 PHD 滤波中, 即采用粒子集合近似表示强度函数, 能够得到粒子概率假设密度滤波器^[8]。通过具有权值的粒子 $\{x_t^{(i)}, w_t^{(i)}\}_{i=1}^{L_t}$ 来近似概率假设密度滤波器, 根据随机逼近理论处理高维随机变量的集合积分问题。这些粒子通过 PHD 预测步和更新步完成迭代。最后对粒子进行聚类, 可以提取多目标运动状态。下面给出 PF-PHD 的具体实现方法。

(1) 状态预测步

对已存在目标, For $i=1, \dots, L_{t-1}$, 按照建议密度函数采样 $\tilde{x}_t^{(i)} \sim q_t(\cdot | x_{t-1}^{(i)}, Z_t)$ 得到近似概率假设密度的新粒子 $\{\tilde{x}_t^{(i)}\}_{i=1}^{L_{t-1}}$, 而每个粒子的权值利用下式进行计算:

$$\tilde{w}_{t|t-1}^{(i)} = \frac{\phi_{t|t-1}(\tilde{x}_t^{(i)} | x_{t-1}^{(i)})}{q_t(\tilde{x}_t^{(i)} | x_{t-1}^{(i)}, Z_t)} w_{t-1|t-1}^{(i)} \quad (2.29)$$

对新产生的目标, For $i=L_{t-1}+1, \dots, L_{t-1}+J_t$, 根据新生目标的建议密度函数进行采样 $\tilde{x}_t^{(i)} \sim p_t(\cdot | Z_t)$, 采样得到粒子 $\{\tilde{x}_t^{(i)}\}_{i=L_{t-1}+1}^{L_{t-1}+J_t}$, 相应的权值为

$$\tilde{w}_{t|t-1}^{(i)} = \frac{b_t(\tilde{x}_t^{(i)})}{J_t p_t(\tilde{x}_t^{(i)} | Z_t)} \quad (2.30)$$

(2) 状态更新步

For $z \in Z_t$, 计算下式

$$S_t(z) = \sum_{j=1}^{L_{t-1}+J_t} \varphi_{t,z}(\text{ }) \quad (2.31)$$

式中:

$$\varphi_{t,z}(\text{ }) \quad (2.32)$$

然后, For $i=1, \dots, L_{t-1}+J_t$, 依次对每个粒子的权值进行计算,

$$\tilde{w}_{t|t}^{(i)} = \left[1 - P_D(\tilde{x}_t^{(i)}) + \sum_{z \in Z_t} \frac{\varphi_{t,z}(\tilde{x}_t^{(i)})}{\lambda_t C_t(z) + S_t(z)} \right] \tilde{w}_{t|t-1}^{(i)} \quad (2.33)$$

(3) 粒子重采样与状态提取

对所有的粒子进行求和, 得到目标个数为

$$N_{t|t} = \sum_{j=1}^{L_{t-1}+J_t} \tilde{w}_{t|t}^{(j)} \quad (2.34)$$

对所有粒子进行重采样 $\left\{ \frac{\tilde{w}_{t|t}^{(j)}}{N_{t|t}}, \tilde{x}_t^{(j)} \right\}_{j=1}^{L_{t-1}+J_t}$ 并得到新粒子为 $\left\{ \frac{w_{t|t}^{(j)}}{N_{t|t}}, x_t^{(j)} \right\}_{j=1}^{L_t}$ 。

经过上述步骤, 可以得到 PFPHD 的完整实现过程。其中, 重要性函数 $q(\tilde{x}_t^{(j)} | x_{t-1}^{(j)}, Z_t)$ 和 $p(\tilde{x}_t^{(i)} | Z_t)$ 的设计非常关键, 一般按照状态转移密度函数和新生目标密度函数作为重要性函数, 即: $q(\tilde{x}_t^{(j)} | x_{t-1}^{(j)}, Z_t) = f_{t|t-1}(\tilde{x}_t^{(j)} | x_{t-1}^{(j)})$, $p(\tilde{x}_t^{(j)} | Z_t) = b_t(\tilde{x}_t^{(j)})$ 。

2.4 PHD 滤波器仿真实验

2.4.1 GM-PHD 仿真实验

构建仿真场景, 对 GM-PHD 滤波器进行验证。传感器监视区域为 $[-400, 1000]m \times [-1000, 400]m$ 。目标状态向量 $x_k = [p_{x,k}, p_{y,k}, \dot{p}_{x,k}, \dot{p}_{y,k}]^T$, $(p_{x,k}, p_{y,k})$ 与 $(\dot{p}_{x,k}, \dot{p}_{y,k})$ 分别定义为目标的位置与速度。目标的生存概率为 0.99, 传感器量测得到目标的位置信息。目标状态方程和量测方程服从线性高斯形式, 目标状态转移矩阵与相应的过程噪声协方差分别为

$$F_k = \begin{bmatrix} I_2 & \Delta I_2 \\ 0_2 & I_2 \end{bmatrix} \quad (2.35)$$

$$Q_k = \sigma_v^2 \begin{bmatrix} \Delta^4 I_2 / 4 & \Delta^3 I_2 / 2 \\ \Delta^3 I_2 / 2 & \Delta^2 I_2 \end{bmatrix} \quad (2.36)$$

式中, I_2 与 0_2 分别为是两维单位方阵以及全零矩阵, 传感器数据采样时间间隔为 $\Delta = 1s$, 状态方程过程噪声标准差为 $\sigma_v = 5m/s^2$ 。新生目标对应的概率假设密度

为 $\gamma_k(x) = 0.1\mathcal{N}(x; m_\gamma^1, P_\gamma) + 0.1\mathcal{N}(x; m_\gamma^2, P_\gamma)$ 。其中 $m_\gamma^1 = [2 \ 5 \ 0 \ , \ 2]^T$ ， $m_\gamma^2 = [-250, -250, 0, 0]^T$ ， $P_\gamma = \text{diag}([100, 100, 25, 25]^T)$ 。衍生目标对应的概率假设密度表示为高斯混合 $\beta_{k|k-1}(x|\zeta) = 0.05\mathcal{N}(x; \zeta, Q_\beta)$ ，其中，相应的协方差矩阵满足 $Q_\beta = \text{diag}([100, 100, 400, 400]^T)$ 。

传感器对目标的检测概率为 $p_{D,k} = 0.98$ 。传感器量测矩阵为 $H_k = [I_2 \ 0_2]$ ，量测噪声协方差为 $R_k = \sigma_\varepsilon^2 I_2$ ，其中 $\sigma_\varepsilon = 10m$ 。空间中杂波的出现满足泊松分布，相应的参数为 $\kappa_k(z) = \lambda_c V u(z)$ ， $u(\cdot)$ 表示概率密度服从均匀分布，传感器观测面积 V ， $\lambda_c = 5 \times 10^{-6} m^{-2}$ 表示单位面积中杂波的平均个数。

场景中总共存在 3 个目标。其中目标 1、2 产生于 $k=1s$ 时刻， $k=100s$ 消失，衍生目标 3 产生于 $k=31s$ ，消失于 $k=80s$ 。目标的真实航迹如图 2-1。




图 2-1 高斯混合 PHD 目标真实航迹图
Fig.2-1 Target trajectories for GMPHD filter

图 2-2 是由 GMPHD 滤波器得到的位置估计结果。滤波结果可知，GM-PHD 滤波器能够去除大量杂波，提供较准确的目标位置信息。

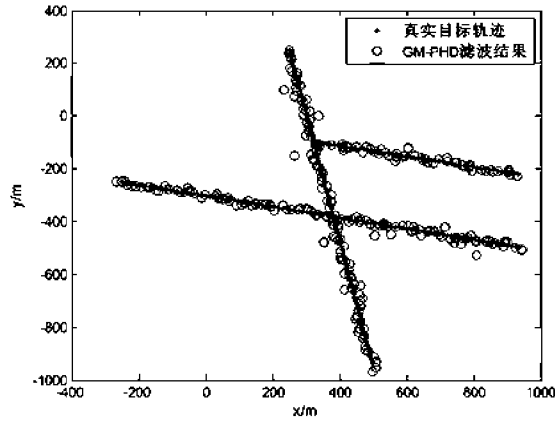


图 2-2 高斯混合 PHD 滤波器估计结果图
Fig.2-2 Estimated trajectories of GMPHD

假如加大杂波数目，令 $\lambda_c = 12.5 \times 10^{-6} m^{-2}$ ，可以进一步得到 GM-PHD 滤波器的滤波结果如图 2-3 所示。




图 2-3 杂波数目增加后高斯混合 PHD 滤波器估计结果图
Figure 2-3 Estimated Trajectories of the GMPHD with increased clutters

对比图 2-2 和图 2-3 可知，杂波数目增加后，概率假设密度滤波器对目标的估计效果变差，即滤波器受杂波影响较大，滤波结果中出现更多的伪目标。

2.4.2 PF-PHD 仿真实验

为验证 PF-PHD 算法的多目标跟踪性能，设置以下仿真场景：传感器监视区域为 $[-10000, 10000]m \times [-10000, 10000]m$ 。目标状态的向量表示形式为 $x_k = [p_{x,k}, p_{y,k}, \dot{p}_{x,k}, \dot{p}_{y,k}]^T$ ，目标的生存概率为 0.99，传感器量测得到目标的位置信

息。目标状态方程和量测方程都服从线性高斯形式，目标状态转移矩阵与相应的过程噪声协方差为

$$F_k = \begin{bmatrix} I_2 & \Delta I_2 \\ 0_2 & I_2 \end{bmatrix} \quad (2.37)$$

$$Q_k = \sigma_v^2 \begin{bmatrix} \Delta^4 I_2 / 4 & \Delta^3 I_2 / 2 \\ \Delta^3 I_2 / 2 & \Delta^2 I_2 \end{bmatrix} \quad (2.38)$$

式中， I_2 与 0_2 分别是 2×2 的单位阵以及全零矩阵，传感器数据采样时间间隔为 $\Delta = 8s$ ，状态方程过程噪声标准差为 $\sigma_v = 3 m/s^2$ 。新生目标对应的概率假设密度表示为 $\gamma_k(x) = 0.1 \mathcal{N}(5x, m_\gamma)$ 。其中 $m_\gamma = [-9000, 5000, 25, -25]^T$ ， $P_\gamma = \text{diag}([40000, 40000, 100, 100]^T)$ 。仿真中不考虑衍生目标。

传感器检测概率 $p_{D,k} = 0.95$ 。量测矩阵为 $H_k = [I_2 \ 0_2]$ ，噪声协方差为 $R_k = \sigma_\varepsilon^2 I_2$ ，其中， $\sigma_\varepsilon = 50m$ 。空间中杂波的出现满足泊松分布，相应的参数为 $\kappa_k(z) = \lambda_c V u(z)$ ， $u(\cdot)$ 表示概率密度服从均匀分布， V 为传感器观测面积， $\lambda_c = 1.25 \times 10^{-7} m^{-2}$ 表示单位面积中的杂波个数。

场景中总共存在两个目标。其中目标1产生于 $k=1s$ 时刻， $k=60s$ 时消失，新生目标2产生于 $k=20s$ ，消失于 $k=80s$ 。目标的真实航迹如图2-4。




图 2-4 粒子 PHD 目标真实航迹图
Fig.2-4 Target trajectories for PFPHD




图 2-5 粒子 PHD 滤波器估计结果图
Fig.2-5 Estimated result of PFPHD

图 2-5 是 PF-PHD 滤波器的位置估计图，仿真结果可知 PF-PHD 滤波器能够准确估计出已存在目标和新生目标的运动状态。

2.5 多目标跟踪滤波器评价指标

由于概率假设密度滤波器不进行数据关联，所以无法采用传统的最小均方根误差等指标进行衡量，因此需要采用集合方法来评估概率假设密度滤波器的性能。最优次分配距离^[33]（OSPA 距离）通过定义集合间的距离来对滤波器性能进行衡量。令 $d^{(c)}(x, \hat{x}) = \min\{c, d(x, \hat{x})\}$ ，其中， c 表示截断距离。假设真实目标状态和估计状态可以用集合 $X = \{x_{1:N}\}$ 以及 $\hat{X} = \{\hat{x}_{1:\hat{N}}\}$ 表示。则两个集合间的 OSPA 距离定义为：

$$d_p^{(c)}(X, \hat{X}) = \left[\frac{1}{N} \left(\min_{\pi \in \Pi_{\hat{N}}} \sum_{i=1}^{\hat{N}} d^{(c)}(x_i, \hat{x}_{\pi(i)})^p + c^p (N - \hat{N}) \right) \right]^{p^{-1}} \quad (2.39)$$

其中， p 为阶次， $\Pi_{\hat{N}}$ 表示 $\{1, \dots, \hat{N}\}$ 上的所有排列。

OSPA 距离具有明确的物理意义，被认为是一种有效的多目标贝叶斯滤波器衡量指标。本文将采用这一指标作为多目标贝叶斯滤波器的评价方法。

2.6 本章小结

本章首先基于随机有限集理论建立多目标贝叶斯滤波公式，通过一阶矩近似进一步得到了概率假设密度 PHD 的预测和更新公式，然后分别给出了 GMPHD 以

及 PFPHD 两种实现方法，并通过仿真验证了两种方法在多目标跟踪方面的性能。最后介绍了多目标跟踪滤波器的性能评价指标——OSPA 距离。本章是后续研究工作的理论基础。

第三章 基于模型交互的粒子 PHD 多目标联合检测与跟踪

3.1 引言

PFPHD 滤波器采用大量粒子近似表示 PHD 的强度，能够实现非线性、非高斯噪声条件下的多目标检测与跟踪。针对机动目标跟踪问题，文献[43]在 PFPHD 基础上对粒子扩充模型标签，提出了多模型粒子 PHD (MM-PFPHD) 算法。这种方法在状态预测步骤前进行模型预测，根据模型转移矩阵对粒子进行模型标签跳转。这一过程需要对每个粒子进行函数采样，粒子模型标签需要大量的随机跳转，然后根据跳转结果判断每个粒子进入不同运动模型对应的滤波器，处理过程复杂。文献[21, 44]对 MMPHD 滤波器进行了扩展应用，但都采用与文[43]相同的 MMPHD 粒子实现方法，即对所有粒子进行模型标签采样步骤。文献[47]将交互式多模型 IMM 引入到 PFPHD 滤波器中，对每个粒子采用 IMM 估计粒子状态，增强对大机动目标的跟踪能力。但由于加入多模型条件滤波、模型概率更新和估计融合步骤，计算量成倍增加。

本章提出一种基于模型交互的粒子 PHD 实现方法。该方法是以粒子交互步骤取代原有粒子实现方法中模型标签预测采样过程。与现有方法相比，改进方法具有清晰的多模型结构；对比单模型 PF-PHD 算法，能够更有效的跟踪机动目标。

3.2 多模型 PHD 滤波器

3.2.1 多模型 PHD 滤波器原理

给定 $k-1$ 时刻多目标的先验概率假设分布的强度为 $D_{k-1|k-1}(x_{k-1}, r_k = p | Z_{1:k-1})$ ，则完整的多模型 PHD 滤波器可以分为以下三个步骤^[43]。

(1) 交互步骤：主要完成不同模型 N_r 之间概率假设密度的交互。交互后的模型 q 对应的假设概率密度为

$$D_{k-1|k-1}(x_{k-1}, r_k = q | Z_{1:k-1}) = \sum_{p=1}^{N_r} D_{k-1|k-1}(x_{k-1}, r_k = p | Z_{1:k-1}) \pi_{pq} \quad (3.1)$$

其中， π_{pq} 为模型转移概率矩阵。 r_k 表示目标运动模型， x_{k-1} 为 $k-1$ 时刻目标状态， $Z_{1:k-1}$ 为量测值。

(2) 预测步骤：模型 q 对应的预测概率密度如下：

$$D_{k|k-1}(x_k, r_k = q | Z_{1:k-1}) = \int [P_S(x_{k-1})f_{k|k-1}(x_k | x_{k-1}, r_k = q) + \beta_{k|k-1}(x_k | x_{k-1}, r_k = q)] \\ \times \tilde{D}_{k|k-1}(x_{k-1}, r_k = q | Z_{1:k-1}) dx_{k-1} + \gamma(x_k, r_k = q) \quad (3.2)$$

式中， $f_{k|k-1}(\cdot)$ 为目标状态转移概率密度函数。 $\gamma(\cdot)$ 表示新生目标强度， $\beta_{k|k-1}(\cdot)$ 为衍生目标状态转移概率密度函数。 P_S 为目标生存概率。

(3) 更新步骤：利用 k 时刻传感器量测 Z_k 对预测目标状态进行更新，获得模型 q 对应的后验 PHD 为

$$D_k(x_k, r_k = q | Z_{1:k}) = D_{k|k-1}(x_k, r_k = q | Z_{1:k-1}) \\ \times [(1 - P_D(x_k)) + \sum_{z \in Z_k} \frac{P_D(x_k)g_k(z | x_k, r_k = q)}{\kappa(z) + \psi_k(z_k | Z_{k-1})}] \quad (3.3)$$

其中，

$$\psi_k(z_k | Z_{k-1}) \\ = \sum_p \int P_D(x_k)g_k(z | x_k, r_k = p) \times D_{k|k-1}(x_k, r_k = p | Z_{1:k-1}) dx_k \quad (3.4)$$

P_D 为传感器检测概率， $\kappa(z)$ 为杂波参数， $g_k(\cdot)$ 为量测似然函数。

3.2.2 多模型 PHD 滤波器粒子实现方法

通过在粒子中加入模型标签，可以得到 MMPHD 的粒子实现方法^[43]。

第一步：预测步。主要包括模型转移和状态预测两个步骤。在 k 时刻，对所有模型总共采样 L_{k-1} 个粒子。目标运动模型 r_{k-1} 按照建议分布进行跳转。

$$r_k^{(s)} \sim \begin{cases} \pi_k(\cdot | r_{k-1}), & s = 1, \dots, L_{k-1} \\ \rho_k(\cdot), & s = L_{k-1} + 1, \dots, L_{k-1} + J_k \end{cases} \quad (3.5)$$

其中， $\pi_k(\cdot | r_{k-1})$ 为已存在目标粒子模型标签转换的建议分布函数。 $\rho_k(\cdot)$ 是新生、衍生目标粒子运动模型的建议分布。 L_{k-1} 表示已存在粒子个数， J_k 为 k 时刻衍生目标与新生目标采样粒子数目。

模型跳转后粒子的预测权重为

$$\tilde{w}_{k|k-1}^{(s)} = \begin{cases} \frac{\omega_{k-1}^{(s)} f_{k|k-1}(r_k^{(s)} | r_k^{(s-1)})}{\pi(r_k^{(s)} | r_{k-1}^{(s)})}, s=1, \dots, L_{k-1} \\ \frac{\theta_k(r_k^{(s)})}{J_k \rho(r_k^{(s)})}, s=L_{k-1}+1, \dots, L_{k-1}+J_k \end{cases} \quad (3.6)$$

其中, $f_{k|k-1}(r_k^{(s)} | r_k^{(s-1)})$ 表示已有目标粒子模型转移概率。 $\theta_k(r_k^{(s)})$ 为衍生、新生目标粒子模型转移概率。

完成模型标签跳转后, 所有粒子根据状态方程进行状态预测:

$$x_k^{(s)} \sim \begin{cases} q_k(\cdot | x_{k-1}^{(s)}, r_k^{(s)}), s=1, \dots, L_{k-1} \\ p_k(\cdot | r_k^{(s)}), s=L_{k-1}+1, \dots, L_{k-1}+J_k \end{cases} \quad (3.7)$$

其中, $q_k(\cdot | x_{k-1}^{(s)}, r_k^{(s)})$ 为目标在模型 r_k 条件下的状态采样建议函数, $p_k(\cdot | r_k^{(s)})$ 表示新生目标状态采样建议密度分布。

第二步: 更新步。利用 k 时刻得到的量测值完成粒子的状态更新, 并得到更新后的粒子权重 $w_k^{(s)}$:

$$w_k^{(s)} = w_{k|k-1}^{(s)} \left[1 - p_D(x_k^{(s)}) + \sum_{z \in Z_k} \frac{p_D(x_k^{(s)}) g_k(z_{k,i} | x_k^{(s)}, r_k^{(s)})}{\lambda V g_k(z_{k,i}) + \mathcal{G}(z_{k,i})} \right] \quad (3.8)$$

其中 $\mathcal{G}(z_{k,i}) = \sum_{j=1}^{L_{k-1}+J_k} p_D(x_k^{(j)}) g_k(z_{k,i} | x_k^{(j)}, r_k^{(j)}) w_{k|k-1}^{(j)}$, λ 和 V 为杂波参数, $g_k(\cdot)$ 为正态分布的似然函数, 传感器检测概率为 p_D 。

第三步: 粒子重采样与状态提取。重采样后模型 q 对应的概率假设密度为

$$D_k(x_k, r_k = q | Z_{1:k}) \cong \sum_{s=1}^{L_k} w_k^{(s)} \delta(x_k - x_k^{(s)}, r_k - r_k^{(s)}) \quad (3.9)$$

对所有粒子进行聚类以实现多目标状态提取。目标数目估计为所有粒子权重之和:

$$\hat{N}_{k|k} = \sum_{i=1}^{J_k} w_k^{(i)} \quad (3.10)$$

已有的 MM-PHD 粒子近似方法中, 每个不同运动模型对应的 PHD 滤波器所采样粒子数目不同, 粒子有可能过分集中于单个 PHD 滤波器中。其次, 预测步骤中模型标签跳转需要进行函数随机采样步骤。最后, 模型标签切换的采用建议密度函数抽样方式, 并没有明确的交互结构。

3.3 模型交互的粒子 PHD 实现方法

本文提出对每种运动模型采样相同的粒子，预测阶段进行不同模型的粒子直接进行模型交互，自动实现粒子模型跳转。改进后的多模型 PHD 粒子实现如下：

(1) 初始化：在每一时刻滤波开始时，对每个运动模型 r_{k-1} 各采样 m 个粒子。

(2) 预测步骤：不同模型间粒子进行多模型交互，利用多模型交互取代粒子模型标签跳转步骤。即式(3.5)和(3.6)采用下式替代。

$$D_{k|k-1}(x_k, r_k) = \sum_{r_{k-1}} \sum_{i=1}^m \pi_{k|k-1}(r_k | r_{k-1}) \times w_{k-1}^i(r_{k-1}) \delta(x - x_k(r_{k-1})) \quad (3.11)$$

其中 $\pi_{k|k-1}(\cdot)$ 为目标模型转移概率矩阵。通过对粒子直接交互，不需要对每个粒子分别进行模型标签采样步骤。交互后每个粒子分解为对应不同运动模型的多个粒子，粒子权重按照状态转移概率矩阵直接加权重。粒子状态预测如(3.7)式所示。

(3) 更新步骤：更新步骤采用(3.8)式，结合 k 时刻的量测值对粒子权重进行更新，得到粒子权重更新值 $w_k^{(s)}$ 。

(4) 粒子重采样与状态提取：粒子重采样步骤包括两次重采样过程，即模型内粒子重采样和模型间粒子重采样。模型内重采样在不同模型内，按照粒子的权值重新采样新的粒子，使每个运动模型内粒子个数保持不变，避免单个模型内粒子数目匮乏。而模型间粒子重采样步骤对所有模型内的粒子统一进行重采样，然后采用 K 均值聚类或者高斯混合聚类方法进行多目标状态提取。

本文所提出的模型交互 PHD 粒子实现方法流程框图如图 5-1 所示。

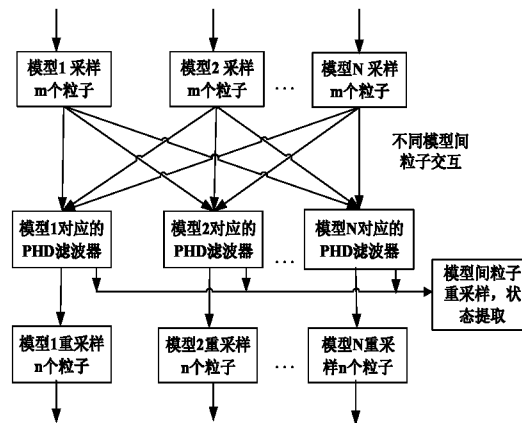


图 3-1 模型交互的粒子 PHD 实现流程

Fig.3-1 Flow diagram of modified MM-PHD particle approximation

改进的粒子实现方法具有以下特点：

- 1) 该方法具有清晰的多模型并行处理结构。
- 2) 没有模型标签采样预测步骤，不同模型间粒子直接进行交互。
- 3) 针对不同运动模型采样相同数目的粒子，避免了模型内粒子匮乏现象。

3.4 算法仿真

本文仿真场景设置如下：假设传感器的检测概率为 0.95，场景中共有两个目标出现，目标的生存概率为 0.99。目标运动模型包括 CT 模型和 CV 模型。目标状态采用向量表示形式为 $X_k = [x(k), \dot{x}(k), y(k), \dot{y}(k)]^T$ ，传感器采样时间间隔 $dT = 6s$ 。仿真步数设定为 80 步。

目标运动方程：

$$X_k = FX_{k-1} + v_k \quad (3.12)$$

其中，过程噪声服从正态分布 $v_k \sim N(\cdot; 0, Q_v)$ ， Q_v 为过程噪声协方差。

模型 $r=1$ 为 CV 模型，相应的状态预测阵为

$$F_{CV} = \begin{bmatrix} 1 & dT & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & dT \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (3.13)$$

过程噪声协方差如下

$$Q_{CV} = \sigma_{CV}^2 \begin{bmatrix} \frac{dT^4}{4} & \frac{dT^3}{2} & 0 & 0 \\ \frac{dT^3}{2} & dT^2 & 0 & 0 \\ 0 & 0 & \frac{dT^4}{4} & \frac{dT^3}{2} \\ 0 & 0 & \frac{dT^3}{2} & dT^2 \end{bmatrix} \quad (3.14)$$

其中，过程噪声标准差为 $\sigma_{CV} = 1m/s$ 。

模型 $r=2$ 为转弯角速度已知匀速转弯模型，方向为逆时针转动，转弯角速度 $\omega = 1.5708$ 。状态转移矩阵以及相应的过程噪声协方差分别为

$$F_{CT} = \begin{bmatrix} 1 & \sin(\omega dT)/\omega & 0 & -(\cos(\omega dT))/\omega \\ 0 & \cos(\omega dT) & 0 & \sin(\omega dT) \\ 0 & -\sin(\omega dT)/\omega & 1 & \cos(\omega dT)/\omega \\ 0 & \sin(\omega dT) & 0 & \cos(\omega dT) \end{bmatrix} \quad (3.15)$$

$$Q_{CT} = \sigma_{CT}^2 \begin{bmatrix} \frac{dT^4}{4} & \frac{dT^3}{2} & 0 & 0 \\ \frac{dT^3}{2} & dT^2 & 0 & 0 \\ 0 & 0 & \frac{dT^4}{4} & \frac{dT^3}{2} \\ 0 & 0 & \frac{dT^3}{2} & dT^2 \end{bmatrix} \quad (3.16)$$

相应的过程噪声标准差为 $\sigma_{CT} = 1m/s$ 。模型 $r = 3$ 与模型 $r = 2$ 转弯角速度大小相等，方向相反，且两者具有相同的过程噪声协方差。

不同运动模型的转化可以通过马尔科夫状态转移矩阵表示：

$$\pi(r|r') = \begin{bmatrix} 0.8 & 0.1 \\ 0.1 & 0.8 \\ 0.1 & 0.1 \end{bmatrix} \quad (3.17)$$

传感器的观测方程如下：

$$Z_k = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} x_k + w_k \quad (3.18)$$

量测噪声服从高斯分布 $w_k \sim N(0, R_w)$ ，量测噪声协方差 $R_w = \text{diag}([(50m)^2, (50m)^2])$ ， diag 表示对角矩阵。仿真量测数据通过数值模拟方法得到。

不考虑衍生目标，并假设新生目标满足泊松分布，且强度函数为

$$\gamma_k(x_k) = 0.05N(x_k; m_{\gamma,k}, P_{\gamma,k}) \quad (3.19)$$

新生目标均值 $m_{\gamma,k} = [-9000 \ 0 \ 5000 \ -50]^T$ ，协方差为 $P_{\gamma,k}^{(i)} = \text{diag}([200^2 \ 100 \ 200^2 \ 100])$ 。监视区域 $[-10000, 10000]m \times [-10000, 10000]m$ ，杂波分布满足泊松分布，参数为 $c_n = 50$ 。

目标 1 和目标 2 起始点分别为 $(-6000, -5000)m$ 和 $(-9000, 5000)m$ 。目标 1 从初始时刻沿 $+x$ 轴以 $50m/s$ 的速度前进 $2min$ ，再以 $\omega = 1.5^\circ/s$ 的旋转速率逆时针旋转 $1min$ ，再匀速直线前进 $2min$ 。最后以 $1.5^\circ/s$ 逆时针转弯 $1min$ 消失。目标 2 从第 $2min$ 开始以 $50m/s$ 的速度朝 y 轴负方向前进 $1min$ ，然后以 $1.5^\circ/s$ 旋转速率逆时针转弯 $1min$ ，再沿 x 轴正方向前进 $3min$ ，最终以 $1.5^\circ/s$ 的旋转角速率逆时针转弯 $1min$ 消失。综上，目标 1 的生存时间为 $0 \sim 6min$ ，目标 2 存在时间为 $2 \sim 8min$ 。本章采用的目标运动场景设置如图 3-2 所示。




图 3-2 多模型 PFPHD 目标运动场景

Fig.3-2 Targets movement scenario for MM-PFPHD

为了评价本文方法的性能,将该方法与单模型 PF-PHD 算法^[8]和文[43]中的多模型粒子 PHD (MM-PFPHD)实现方法进行对比。初始化时为每个目标分配 300 个粒子。经过 100 次蒙特卡洛 (Monte Carlo) 仿真,可得不同方法相应的目标数目估计误差如图 3-3 所示。

从图 3-3 可以看出,从开始时刻到第 20 步,目标 1 做匀速直线运动,此时三种方法都能够对目标数目进行准确的估计。然而从第 20 步开始,目标 1 出现机动,单模型 PF-PHD 在目标机动时目标数目估计逐渐趋于零,说明出现跟丢现象。两种多模型粒子 PHD 方法对目标数目估计基本接近真实值,表明两种多模型 PHD 粒子实现方法都能对机动目标进行有效跟踪。但是,本文方法对目标数目的估计更接近真实值,跟踪准确度提高。




图 3-3 不同算法目标数目估计对比图

Fig.3-3 Compare of estimated target number of different algorithms

仿真采用最优次分配距离^[33]（OSPA 距离）对状态估计误差进行衡量，结果如图 3-4 所示。其中，取 OSPA 截断距离为 500 米。




图 3-4 不同算法 OSPA 距离对比图

Fig.3-4 Compare of OSPA distance of different algorithms

由图 3-4 分析可知：采用单模型 PF-PHD 算法，目标发生机动时，OSPA 距离逐渐达到极限值（截断距离）。由于单模型方法状态方程仅包含单个模型，在目标机动时不能有效近似目标运动模型，跟踪误差大。本章方法与文献[43]中的多模型 PHD 方法在目标数目 OSPA 距离曲线基本收敛，说明二者都能对目标状态进行有效的估计。但是，本文方法 OSPA 距离最小，相比文献[43]方法 OSPA 指标降低约 30%。本文算法性能提升的原因是存在粒子交互步骤，每次交互后粒子数目会扩充 N 倍（ N 为目标运动模型的个数）。通过预测步骤中衍生出更多的粒子近似目标运动状态。根据粒子滤波原理可知，粒子滤波中粒子数目越多，滤波结果越精确。

在算法效率方面对不同方法进行对比。仿真计算环境为：2.80 GHz Intel E7400 处理器，4 GB RAM，Matlab 2010a，通过蒙特卡洛仿真可以得到三种不同方法所需要的平均单步运算时间，分别为 4.1 秒，8.2 秒和 9.0 秒。由于多模型的引入，本文算法运算时间会比单模型 PF-PHD 算法要高。相比文[43]中的实现方法，运算时间提高约 10%。本文方法通过粒子交互作用产生更多的粒子，所以计算量有所增加。

3.5 本章小结

本章提出一种基于模型交互的粒子 PHD 实现方法，以粒子直接交互取代原有的多模型 PHD 粒子实现方法中模型标签预测采样步骤。该方法具有明显的模型间

粒子交互过程，且多个滤波器并行结构清晰。在相同的初始条件下，改进方法在滤波器中进行粒子扩充，能够更准确的近似目标运动状态，目标数目估计更接近真实值，状态估计精度比现有多模型 PHD 粒子实现方法提高 30%。与单模型 PF-PHD 滤波器相比，该方法提升了对机动目标的跟踪能力。

第四章 基于 GMPHD 的多传感器联合检测、跟踪和分类算法

4.1 引言

传统侦察系统中，一般采用雷达等位置传感器对目标进行定位，而目标类别的判断借助类别传感器如敌我识别器、电子辅助设施等。已有的多传感系统方法将跟踪和分类两个过程分离开来，先估计再决策或者先决策再估计，并没有充分利用两者的耦合关系。然而分类器得到的类别信息可以输入到滤波器以跟踪精度，滤波器估计结果可以辅助实现类别判断。充分利用跟踪和分类的耦合关系实现联合目标检测、跟踪和分类，将进一步改进侦察系统性能，提高态势感知能力。

在多目标跟踪方法中，PHD 滤波器为解决杂波背景下的多目标跟踪问题提供了新思路。在满足线性高斯条件下，GM-PHD 滤波器采用高斯混合元近似 PHD 的强度，实现了多目标跟踪。将 GM-PHD 滤波器与多模型思想相结合，文献[34]提出了跳变马尔科夫高斯混合 PHD 滤波器 (LGJMS-GMPHD) 解决多机动目标跟踪问题。在此基础上，文[35]进一步采用属性向量扩展目标状态，得到多目标联合检测、跟踪和分类算法 (LGJMS-GMPHD-JDTC)，目标类别的引入提高了目标状态的估计精度，目标状态估计的提升又改善了目标分类能力。

多传感器系统具有互补性与高可靠性，已经广泛应用于诸多领域，如雷达组网和无源被动跟踪系统等。但是已有的多传感器融合方法^[36-38]只解决目标的检测和跟踪问题，并不考虑检测、跟踪和分类三者的耦合关系。

为了实现多传感器的联合检测、跟踪和分类，本章提出一种基于跳变马尔科夫 GM-PHD 滤波器的多传感器联合检测、跟踪和分类算法。主要思想在高斯混合 PHD 滤波器框架下，采用目标属性向量扩展目标状态得到综合状态，利用多个传感器提供的属性和状态量测对综合状态进行序贯处理。仿真验证该算法能够解决多传感器多目标联合检测、估计与决策问题，实现对目标的状态估计和类别判断。

4.2 多传感器联合检测、跟踪和分类问题描述

假设在 k 时刻，单目标的状态向量与属性向量分别为 x_k 和 μ_k ，目标总数为 N_k 。多目标状态和属性进一步采用随机集形式表述为 $X_k = \{[x_{k,i}^T, \mu_{k,i}^T]^T\}_{i=1}^{N_k}$ ，其中，属性向量 μ_k 中每个分量表示目标属于某一类别目标的概率。由目标或者杂波产生的

量测个数为 M_k^j ，其中 $j (j=1, \dots, n)$ 表示第 j 个传感器得到的量测值，令 z_k^j 表示单目标状态量测， η_k^j 表示属性量测。将两种量测合并得到综合量测 $\tilde{z}_k^j = [\zeta_k^j]^T \eta_k^j$ ，进而第 j 个传感器得到的量测采用随机集表示为 $\tilde{Z}_{k,j} = \{\tilde{z}_{k,m}^j\}_{m=1}^{M_k^j}$ 。假设每一时刻所有状态量测相互独立且状态量测噪声服从高斯分布，杂波数目服从泊松分布。 k 时刻所有 n 个传感器得到的联合状态和属性量测为 $\tilde{Z}_{k,1:n} = \{\tilde{Z}_{k,1}, \dots, \tilde{Z}_{k,j}, \dots, \tilde{Z}_{k,n}\}$ 。

多传感器联合检测、跟踪和分类问题为如何利用多传感器得到的综合量测 $\tilde{Z}_{k,1:n}$ ，同时对多目标的状态和属性向量进行估计。

4.3 基于 GMPHD 的单传感器联合检测、跟踪和分类算法

文献[35]提出了一种基于 LGJMS-GMPHD 的联合检测、跟踪和分类算法 (LGJMS-GMPHD-JDTC 算法)。原理是利用属性向量扩展运动状态，然后采用联合似然函数将类别信息引入到 PHD 滤波过程中。算法描述如下：

假设 $k-1$ 时刻，随机有限集强度 D_{k-1} 可以表示为高斯混合分量的形式

$$D_{k-1} \left(\begin{bmatrix} x_{k-1} \\ \mu_{k-1} \end{bmatrix}, r_{k-1} \right) = \sum_{i=1}^{J_{k-1}(r_{k-1})} w_{k-1}^{(i)}(r_{k-1}) \delta(\mu_k - \mu_{k-1}^{(i)}) N(x_{k-1}; m_{k-1}^{(i)}(r_{k-1}), P_{k-1}^{(i)}(r_{k-1})) \quad (4.1)$$

其中， x_{k-1} 是目标运动状态， μ_{k-1} 是目标类别向量，类别向量中的每个分量代表目标属于不同类别的可能性。 r_{k-1} 是运动模型， $J_{k-1}(r_{k-1})$ 是模型 r_{k-1} 对应的高斯元个数。 $\mu_{k-1}^{(i)}$ 和 $w_{k-1}^{(i)}$ 分别表示第 i 个高斯元的类别向量和权重。 $N(\cdot; m, P)$ 表示均值为 m ，协方差为 P 的正态分布。 δ 表示狄拉克函数。

k 时刻 PHD 预测强度 $D_{k|k-1}$ 为

$$D_{k|k-1} \left(\begin{bmatrix} x_{k|k-1} \\ \mu_{k-1} \end{bmatrix}, r_k \right) = D_{f,k|k-1} \left(\begin{bmatrix} x_{k|k-1} \\ \mu_{k-1} \end{bmatrix}, r_k \right) + \gamma_k \left(\begin{bmatrix} x_{k|k-1} \\ \mu_{k-1} \end{bmatrix}, r_k \right) \quad (4.2)$$

其中， $D_{f,k|k-1}(\cdot)$ 和 $\gamma_k(\cdot)$ 分别表示已存在目标和新生目标的强度， r_k 为 k 时刻目标运动模型。 $x_{k|k-1}$ 为目标预测状态。

利用 k 时刻状态量测 z 和属性量测 ξ 构成综合量测 \tilde{z}_k ，对属性和状态向量进行更新得到目标后验 PHD 强度

$$D_k \left(\begin{bmatrix} x_k \\ \mu_k \end{bmatrix}, r_k \right) = (1 - p_D(r_k)) D_{f,k|k-1} \left(\begin{bmatrix} x_{k|k-1} \\ \mu_{k-1} \end{bmatrix}, r_k \right) + \sum_{\substack{\tilde{z} = \begin{bmatrix} z \\ \xi \end{bmatrix} \in \mathcal{Z}_k}} D_{g_k} \left(\begin{bmatrix} x_k \\ \mu_k \end{bmatrix}, r_k; \tilde{z} \right) \quad (4.3)$$

其中, p_D 为传感器检测概率,

$$D_{g_k} \left(\begin{bmatrix} x_k \\ \mu_k \end{bmatrix}, r_k; \tilde{z} \right) = \sum_{i=1}^{J_{k|k-1}(r_k)} \frac{p_D(r_k) w_{k|k-1}^{(i)}(r_k) q_k^{(i)}(r_k; \tilde{z}) \Theta}{\kappa_k(\tilde{z}) + \sum_r p_D(r) \sum_{j=1}^{J_{k|k-1}(r)} w_{k|k-1}^{(j)}(r) q_k^{(j)}(r; \tilde{z})} \quad (4.4)$$

$$\Theta = \delta(\mu_k - \mu_{k-1}^{(i)} \otimes \xi) N[x_k(r_k); m_k^{(i)}(r_k; \tilde{z}), P_k^{(i)}(r_k; \tilde{z})] \quad (4.5)$$

$$q_k^{(j)}(r_k; \tilde{z}) = g_{a,k}(\xi | \mu_{k|k-1}^{(i)}) N(z; H_k m_{k|k-1}^{(j)}(r_k), R_k(r_k) + H_k P_{k|k-1}^{(j)}(r_k) H_k^T) \quad (4.6)$$

$$\mu_{k-1}^{(i)} \otimes \xi = \frac{\mu_{k-1}^{(i)} \bullet \xi}{\xi^T \mu_{k-1}^{(i)}} \quad (4.7)$$

其中, \bullet 表示 Shur-Hadamard 积。属性量测似然函数 $g_{a,k}(\cdot)$ 为属性向量 $\mu_{k-1}^{(i)}$ 和属性量测 ξ 的乘积 $g_{a,k}(\xi | \mu_{k-1}^{(i)}) = \xi^T \mu_{k-1}^{(i)}$ 。

基于 LGJMS-GMPHD 的单传感器联合检测、跟踪和分类 (JDTC) 算法能够估计得到多个目标的类别信息和状态信息。然而, 对于多传感器问题, 需要进一步考虑如何处理多个传感器得到的属性量测和状态量测, 得到实现多传感器多目标联合检测、跟踪和分类。

4.4 基于序贯 GMPHD 的多传感器联合检测、跟踪和分类算法

为解决多传感器多目标联合检测跟踪分类问题, 在 LGJMS-GMPHD-JDTC 算法基础上采用序贯方法对属性和状态信息进行融合, 本章提出序贯 GMPHD 多传感器联合检测、跟踪和分类算法 (Iterated-LGJMS-GMPHD-JDTC)。由于目标类别信息通过属性向量形式表示, 因此可以通过不同传感器得到的属性量测值对属性向量进行迭代更新。下面首先介绍所提出算法的几个假设条件, 然后给出详细的算法描述。

4.4.1 假设条件

多传感器联合检测、跟踪和分类算法以序贯 PHD 滤波器为基础并且引入属性量测, 因此存在一些特殊问题。首先, 多传感器序贯融合的性能与传感器使用顺序有关。不同性能的传感器进行序贯处理时应先采用较差的传感器以获得更小的

均方根误差^[39]。如果传感器检测性能不同，应首先采用检测概率较低的传感器^[40, 41]。其次，针对多传感器联合、检测和跟踪问题，每个传感器节点同时获得状态和属性量测。而属性量测可以从目标运动状态中进行提取，也可以通过类别传感器得到。最后，当不同传感器观测区域不一致时，多传感器序贯 PHD 滤波器跟踪性能迅速降低^[25]。为简化问题，本章提出三个假设条件：

- (1) 传感器按照位置误差性能和检测概率从大到小进行排列。
- (2) 每个传感器节点状态和属性量测已经进行关联，且完成时空配准。
- (3) 所有传感器观测区域均一致。

4.4.2 算法描述

完整的 Iterated-LGJMS-GMPHD-JDTC 算法描述如下：

假设 $k-1$ 时刻， n 传感器得到的特征和属性综合量测的集合形式为 $\{Z_k^1, \dots, Z_k^n\}$ ，PHD 强度对应的高斯混合形式如下：

$$D_{k-1} \left(\begin{bmatrix} x_{k-1} \\ \mu_{k-1} \end{bmatrix}, r_{k-1} \right) = \sum_{i=1}^{J_{k-1}(r_{k-1})} w_{k-1}^{(i)}(r_{k-1}) \delta(\mu_k - \mu_{k-1}^{(i)}) N(x_{k-1}; m_{k-1}^{(i)}(r_{k-1}), P_{k-1}^{(i)}(r_{k-1})) \quad (4.8)$$

采用传感器 1 得到的综合量测 Z_k^1 对上一时刻的 PHD 强度 D_{k-1} 进行更新，得到

$$D_k^1 \left(\begin{bmatrix} x_{1,k} \\ \mu_{1,k} \end{bmatrix}, r_k \right) = \sum_{i=1}^{J_k^1(r_k)} w_{1,k}^{(i)}(r_k) \delta(\mu_k - \mu_{1,k}^{(i)}) N(x_{1,k}; m_{1,k}^{(i)}(r_k), P_{1,k}^{(i)}(r_k)) \quad (4.9)$$

继续采用第二个传感器的综合量测更新 D_k^1 ，进一步得到

$$D_k^2 \left(\begin{bmatrix} x_{2,k} \\ \mu_{2,k} \end{bmatrix}, r_k \right) = (1 - p_D(r_k)) D_k^1 \left(\begin{bmatrix} x_{1,k} \\ \mu_{1,k} \end{bmatrix}, r_k \right) + \sum_{\tilde{z} = \begin{bmatrix} z \\ \xi \end{bmatrix} \in Z_k^2} D_{g_k} \left(\begin{bmatrix} x_{2,k} \\ \mu_{2,k} \end{bmatrix}, r_k; \tilde{z} \right) \quad (4.10)$$

对所有 n 个传感器进行序贯处理

$$D_k^n \left(\begin{bmatrix} x_{n,k} \\ \mu_{n,k} \end{bmatrix}, r_k \right) = \sum_{i=1}^{J_k^n(r_k)} w_{n,k}^{(i)}(r_k) \delta(\mu_k - \mu_{n,k}^{(i)}) N(x_k; m_{n,k}^{(i)}(r_k), P_{n,k}^{(i)}(r_k)) \quad (4.11)$$

最后，更新后的多目标多传感器后验强度为

$$D_k \left(\begin{bmatrix} x_k \\ \mu_k \end{bmatrix}, r_k \right) = D_k^n \left(\begin{bmatrix} x_{n,k} \\ \mu_{n,k} \end{bmatrix}, r_k \right) \quad (4.12)$$

目标数目可以通过对所有的高斯元权重求和得到

$$\hat{N}_{k|k} = \sum_{i=1}^{J_k^n} w_{n,k}^{(i)} \quad (4.13)$$

与多传感器序贯高斯混合 PHD 滤波器相比,本章算法在对目标状态进行序贯处理同时,充分利用不同传感器提供的多个属性量测,对目标属性向量进行序贯更新。如果忽略类别向量,则上述算法退化为多传感器序贯高斯混合 PHD 滤波器 [37]。

4.5 数值仿真

本章采用仿真场景如下:假设通过两个传感器对目标进行观测,两个传感器的检测概率均为 $p_d = 0.98$, 不同时刻目标有可能出现或者消失,目标的生存概率为 $p_s = 0.99$ 。运动模型利用常速转弯 (CT) 模型和常速直线 (CV) 模型描述。目标状态向量表示为 $X_k = [x(k), \dot{x}(k), y(k), \dot{y}(k)]^T$, 传感器测量时间间隔 $dT = 30s$ 。

目标运动方程:

$$X_k = FX_{k-1} + v_k \quad (4.14)$$

其中,过程噪声服从正态分布 $v_k \sim N(\cdot; 0, Q_v)$, Q_v 为过程噪声协方差。

模型 $r=1$ 为 CV 模型,状态转移矩阵以及相应的过程噪声协方差分别为

$$F_{CV} = \begin{bmatrix} 1 & dT & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & dT \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (4.15)$$

$$Q_{CV} = \sigma_{CV}^2 \begin{bmatrix} \frac{dT^4}{4} & \frac{dT^3}{2} & 0 & 0 \\ \frac{dT^3}{2} & dT^2 & 0 & 0 \\ 0 & 0 & \frac{dT^4}{4} & \frac{dT^3}{2} \\ 0 & 0 & \frac{dT^3}{2} & dT^2 \end{bmatrix} \quad (4.16)$$

式中,过程噪声标准差为 $\sigma_{CV} = 1m/s$ 。

模型 $r=2$ 为转弯速度已知的 CT 模型,为逆时针常速转弯,转弯速度为 $1.5 rad/s$ 。相应的过程噪声标准差为 $\sigma_{CT} = 1m/s$ 。

$$F_{CT} = \begin{bmatrix} 1 & \sin(\omega dT)/\omega & 0 & -(1-\cos(\omega dT))/\omega \\ 0 & \cos(\omega dT) & 0 & -\sin(\omega dT) \\ 0 & (1-\cos(\omega dT))/\omega & 1 & \sin(\omega dT)/\omega \\ 0 & \sin(\omega dT) & 0 & \cos(\omega dT) \end{bmatrix} \quad (4.17)$$

$$Q_{CT} = \sigma_{CT}^2 \begin{bmatrix} \frac{dT^4}{4} & \frac{dT^3}{2} & 0 & 0 \\ \frac{dT^3}{2} & dT^2 & 0 & 0 \\ 0 & 0 & \frac{dT^4}{4} & \frac{dT^3}{2} \\ 0 & 0 & \frac{dT^3}{2} & dT^2 \end{bmatrix} \quad (4.18)$$

模型 $r=3$ 与模型 $r=2$ 转弯速度大小相等，方向相反，且具有相同的过程噪声。三种运动模型的转化可以通过马尔科夫状态转移矩阵表示：

$$\pi(r|r') = \begin{bmatrix} 0.8 & 0.1 & 0.1 \\ 0.1 & 0.8 & 0.1 \\ 0.1 & 0.1 & 0.8 \end{bmatrix} \quad (4.19)$$

直角坐标系下，第 i 个传感器的观测方程如下：

$$Z_k^i = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} X_k + w_k^i \quad (4.20)$$

式中，量测噪声服从高斯分布 $w_k^i \sim N(0, R_w^i)$ ，量测噪声协方差为 $R_w^1 = R_w^2 = \text{diag}([(100\text{m})^2, (100\text{m})^2])$ 。其中， diag 表示对角矩阵。

不考虑衍生目标，并假设新生目标满足正态分布，并且强度函数为

$$\gamma_k \left(\begin{bmatrix} x_k \\ \mu_k \end{bmatrix}, r_k \right) = 0.1 \delta(\mu_k - \mu_0) \left[0.8 N(x_k; m_{\gamma,k}^{(1)}, P_{\gamma,k}^{(1)}) + 0.1 N(x_k; m_{\gamma,k}^{(2)}, P_{\gamma,k}^{(2)}) + 0.1 N(x_k; m_{\gamma,k}^{(3)}, P_{\gamma,k}^{(3)}) \right]$$

其中， $m_{\gamma,k}^{(1)} = 10^4 \times [4 \ 0 \ -5 \ 0]^T$ ， $m_{\gamma,k}^{(2)} = 10^4 \times [-5 \ 0 \ 4 \ 0]^T$ ， $m_{\gamma,k}^{(3)} = 10^4 \times [-1 \ 0 \ 0 \ 0]^T$ ， $P_{\gamma,k}^{(i)} = 10^4 \times \text{diag}([25 \ 0.36 \ 25 \ 0.36])$ 。

监视区域为 $[-60, 60] \text{km} \times [-60, 60] \text{km}$ ，假设每一时刻杂波数目服从参数为 $c_n = 50$ 泊松分布。高斯元修剪门限为 $T_h = 10^{-5}$ ，合并门限为 $U = 4$ 。

实际系统中目标的类别量测可以通过信号强度、雷达反射截面积，机动性等方法获得。本章采用混淆矩阵 C 对传感器类别量测进行建模^[42]。混淆矩阵能够用于表示分类器的性能。在混淆矩阵中 C 中，每个元素为 $c_{ij} = P\{\varepsilon = j | \kappa = i\}$ 。其中 ε 表示分器的输出。而 κ 表示目标实际类别。当分类器输出为 $\varepsilon = j$ 时，类别量测为混淆矩阵的 j 列。不妨假设混淆矩阵如下：

$$C = \begin{bmatrix} 0.9 & 0.05 & 0.05 \\ 0.05 & 0.9 & 0.05 \\ 0.05 & 0.05 & 0.9 \end{bmatrix} \quad (4.21)$$

仿真场景图如图 3-1 所示。场景中共有五个目标，初始时刻，目标 1 和目标 2 起始于 $[-50, 40]^T km$ 并分别向正西和正南运动。在 $k = 20s$ 时刻，目标 3 产生于 $[-10, 0]^T km$ 并向东匀速运动。在 $k = 40s$ 时，目标 4 和 5 出现在 $[40, -50]^T km$ 。




图 4-1 多传感器 GMPHD-JDTC 目标运动场景图

Fig.4-1 Target trajectories for multi-sensor GMPHD-JDTC

为了评价本章提出的多传感器联合检测、跟踪和分类算法，将其与三种算法——跳跃马尔科夫高斯混合 PHD (LGJMS-GMPHD)，跳跃马尔科夫高斯混合 PHD 联合检测跟踪和分类算法 (LGJMS-GMPHD-JDTC) 和序贯跳跃马尔科夫高斯混合 PHD (Iterated-LGJMS-GMPHD) 进行对比。不同算法得到的滤波结果如图 4-2 到图 4-5 所示。




图 4-2 LGJMS-GMPHD 算法滤波结果图

Fig.4-2 Estimated trajectories of LGJMS-GMPHD




图 4-3 LGJMS-GMPHD-JDTC 算法滤波结果图

(*:类别 1, □:类别 2)

Fig.4-3 The estimated trajectory of LGJMS-GMPHD-JDTC

(*: type 1 and □: type 2)




图 4-4 Iterated-LGJMS-GMPHD 算法滤波结果图

Fig.4-4 The estimated trajectory of Iterated-LGJMS-GMPHD




图 4-5 Iterated-LGJMS-GMPHD-JDTC 算法滤波结果图

(*: 类别 1, □: 类别 2)

Fig.4-5 The estimated trajectory of proposed algorithm

(*: type 1 and □: type 2)

经过 100 次蒙特卡洛仿真，可得不同方法相应的目标数目估计误差如图 4-6 所示。

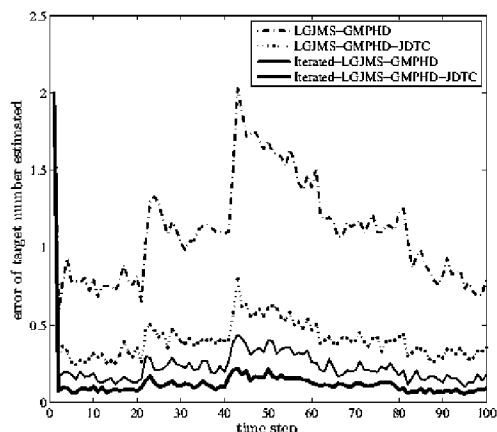


图 4-6 不同算法目标数目估计误差对比图

Fig.4-6 Target number estimation errors for different algorithms

采用最优次分配距离（OSPA 距离）衡量目标状态估计误差。结果如图 4-7 所示。其中取 OSPA 截断距离为 1000 米。




图 4-7 不同算法 OSPA 距离对比图

Fig.4-7 OSPA distances for different methods

通过数值仿真结果可知，相比其他三种方法，所提出的算法对目标数目和目标状态估计性能最好，同时得到目标的类别信息。相比多传感器序贯 PHD 滤波器，由于类别信息的引入，联合检测跟踪和分类算法能够更好的区分不同类别目标并抑制杂波。相比单传感器算法，本章算法可以充分多传感器提供的测量结果，对目标状态和数目进行滤波。

4.6 本章小结

本章提出一种基于 GMPHD 的多传感器联合检测、跟踪和分类方法。在线性高斯条件下，该方法能够处理多传感器联合检测、估计和决策问题。与传统的序贯高斯混合 PHD 算法相比，本章算法不仅可以在滤波的同时对目标进行分类，而且提高了对目标数目和状态的估计精度。

第五章 基于 PFPHD 的多传感器联合检测、跟踪和分类算法

5.1 引言

对于跟踪系统而言，多传感器系统比单传感器具有更广阔的观测区域、更高的鲁棒性、容错性以及定位精度。另一方面，有些跟踪系统不仅能够测量到目标的方位和距离信息，而且能够测量到不同类别目标的特征信息。如在雷达系统中，目标的回波强度要高于杂波的信号。如果能够提取目标的属性信息并利用跟踪和分类间的耦合关系，不仅可以提高目标状态估计能力，而且能够得到目标的类别信息，从而增强态势感知能力。雷达组网等系统需要处理多个传感器的属性和状态量测，是一个多传感器联合检测、跟踪和分类问题。

在非线性、非高斯条件下目标的概率假设密度可以使用粒子集合近似表示，从而得到粒子滤波 PHD。针对机动多目标估计问题，文献[43]进一步推导了多模型粒子 PHD 滤波器（MM-PFPHD）。通过扩充类别信息，PFPHD 滤波器可以实现目标的联合检测、跟踪和分类^[44]（PFPHD-JDTC）。目前已有 PFPHD-JDTC 方法只能处理单传感器的属性量测和状态量测。而已有的多传感器序贯 PFPHD 滤波器仅能够实现多目标状态估计，无法处理目标的属性信息。

为解决非线性非高斯条件下的多传感器联合检测、跟踪和分类问题，本章提出一种基于序贯粒子 PHD 滤波的多传感器联合检测、跟踪和分类算法（Iterated-PFPHD-JDTC）。首先通过对各传感器信号进行建模，提取目标的属性量测，然后引入目标的属性信息对目标状态空间进行重新建模，从而得到目标综合状态，最后利用多个传感器的量测对综合状态进行序贯滤波。

5.2 基于 PFPHD 的单传感器联合检测、跟踪和分类算法

基于多模型粒子 PHD 滤波器，单传感器联合检测跟踪和分类算法^[44]采用类别向量对目标运动状态空间进行扩展，在更新步骤中利用综合量测对目标状态和属性向量同时进行更新。下面给出该算法的具体描述。为简化起见，此处省略多模型分量。

假设 $k-1$ 时刻目标的随机有限集强度 D_{k-1} 可以采用带权重粒子表示如下：

$$D_{k-1} \left(\begin{bmatrix} x_{k-1} \\ \mu_{k-1} \end{bmatrix} \middle| \tilde{Z}_{1:k-1} \right) \cong \sum_{s=1}^{J_{k-1}} w_{k-1}^{(s)} \times \delta(x_{k-1} - x_{k-1}^{(s)}, \mu_{k-1} - \mu_{k-1}^{(s)}) \quad (5.1)$$

其中, x_{k-1} 为 $k-1$ 时刻目标运动状态, μ_{k-1} 为目标属性向量, J_{k-1} 表示粒子个数。 $\mu_{k-1}^{(s)}$ 和 $w_{k-1}^{(s)}$ 分别表示第 s 个粒子对应的属性向量和权重。 δ 表示狄拉克函数。

k 时刻目标的预测强度如下:

$$D_{k|k-1} \left(\begin{bmatrix} x_{k|k-1} \\ \mu_{k-1} \end{bmatrix} \middle| \tilde{Z}_{1:k-1} \right) = \gamma_k \left(\begin{bmatrix} x_{k|k-1} \\ \mu_{k-1} \end{bmatrix} \right) + \int F_{k|k-1} \left(\begin{bmatrix} x_{k-1} \\ \mu_{k-1} \end{bmatrix} \right) D_{k-1} \left(\begin{bmatrix} x_{k-1} \\ \mu_{k-1} \end{bmatrix} \middle| \tilde{Z}_{1:k-1} \right) dx_{k-1} \quad (5.2)$$

其中, γ_k 为新生目标的随机有限集强度。 $x_{k|k-1}$ 为 k 时刻目标预测状态, 已存在目标和衍生目标预测为:

$$F_{k|k-1} \left(\begin{bmatrix} x_{k-1} \\ \mu_{k-1} \end{bmatrix} \right) = P_{S,k}(x_k) f_{k|k-1} \left(\begin{bmatrix} x_{k-1} \\ \mu_{k-1} \end{bmatrix} \right) + \beta_{k|k-1} \left(\begin{bmatrix} x_{k-1} \\ \mu_{k-1} \end{bmatrix} \right) \quad (5.3)$$

其中, $P_{S,k}$ 为已存在目标的生存概率。 $f_{k|k-1}(\cdot)$ 为目标状态方程, $\beta_{k|k-1}(\cdot)$ 为衍生目标状态方程。

进而, k 时刻的后验强度为

$$D_{k|k} \left(\begin{bmatrix} x_k \\ \mu_{k-1} \end{bmatrix} \middle| \tilde{Z}_{1:k} \right) = D_{k|k-1} \left(\begin{bmatrix} x_{k|k-1} \\ \mu_{k-1} \end{bmatrix} \middle| \tilde{Z}_{1:k-1} \right) \left[1 - P_D(x_k) + \sum_{\tilde{z} \in \tilde{Z}_k} \frac{P_D(x_k) \Gamma_k(\tilde{z})}{\kappa_k(\tilde{z}) + \tau_k(\tilde{z})} \right] \quad (5.4)$$

其中,

$$\tau_k(\tilde{z}) = \int P_D(x_k) \Gamma_k(\tilde{z}) D_{k|k-1} \left(\begin{bmatrix} x_{k-1} \\ \mu_{k-1} \end{bmatrix} \middle| \tilde{Z}_{1:k-1} \right) dx_k \quad (5.5)$$

$\kappa_k(\tilde{z})$ 为杂波参数, $P_D(x_k)$ 为传感器检测概率。 \tilde{z} 表示综合量测。联合量测似然函数 $\Gamma_k(\tilde{z})$ 为状态量测似然函数和属性量测似然函数的乘积

$$\Gamma_k(\tilde{z}) = g_k(z_k | x_k, \mu_{k-1}) g_f(\eta_k | \mu_{k-1}) \quad (5.6)$$

最后, 对目标属性向量进行更新:

$$D_{k|k} \left(\begin{bmatrix} x_k \\ \mu_k \end{bmatrix} \middle| \tilde{Z}_{1:k} \right) = D_{k|k} \left(\begin{bmatrix} x_k \\ \mu_{k-1} \end{bmatrix} \middle| \tilde{Z}_{1:k} \right) \left[1 - P_D(x_k) + P_D(x_k) \sum_{\tilde{z} \in \tilde{Z}_k} \alpha(x_k, \tilde{z}) (\mu_{k-1} \odot \eta) \right] \quad (5.7)$$

其中, $\alpha(x_k, \tilde{z}) = \frac{g_k(z_k | x_k, \mu_{k-1}) g_f(\eta_k | \mu_{k-1})}{\kappa_k(\tilde{z}) + \tau_k(\tilde{z})}$, 属性量测似然函数为属性向量 μ_{k-1} 与属性量测 η_k

的乘积, 即: $g_f(\eta_k | \mu_k) = \eta_k^T \mu_{k-1}$ 。 $\mu_{k-1} \odot \eta_k = \frac{\mu_{k-1} \eta_k^T}{\|\mu_{k-1}\| \|\eta_k\|}$, 符号 \odot 表示 Shur-Hadamard 乘积。

状态更新和属性向量更新均采用组合似然函数，表示目标状态和属性估计是紧密耦合的。由于滤波结束后可以采用加权粒子权重的方法得到目标数目，因此利用式(5.1)–(5.7)可以实现单传感器联合检测、跟踪和分类。

5.3 基于序贯 PFPHD 的多传感器联合检测、跟踪和分类算法

为解决多传感器背景下的联合检测、跟踪和分类问题，考虑到目标类别信息通过属性向量形式表示，可以通过不同传感器得到的属性量测值对属性向量进行迭代更新。本节提出序贯多模型 PFPHD 的联合检测、跟踪和分类算法 (Iterated-MM-PF-PHD-JDTC)，基于单传感器联合检测、跟踪和分类方法对不同传感器得到的状态和属性综合量测进行序贯处理。详细算法描述如下：

假设 k 时刻 n 个传感器得到的联合运动状态和属性量测记为 $\{\tilde{Z}_{k,1}, \dots, \tilde{Z}_{k,n}\}$ 。

$k-1$ 时刻 PHD 强度 D_{k-1} 可以采用加入属性向量的粒子近似表示。

$$D_{k-1} \left(\begin{bmatrix} x_{k-1} \\ \mu_{k-1} \end{bmatrix}, r_{1,k-1} \right) \cong \sum_{s=1}^{J_{k-1}} w_{k-1}^{(s)} \times \delta(x_{k-1} - x_{k-1}^{(s)}, \mu_{k-1} - \mu_{k-1}^{(s)}, r_{k-1} - r_{1,k-1}^{(s)}) \quad (5.8)$$

其中， x_{k-1} 为 $k-1$ 时刻目标运动状态， μ_{k-1} 为目标属性向量， r_{k-1} 表示目标运动模型， J_{k-1} 表示粒子个数。 $\mu_{k-1}^{(s)}$ 和 $w_{k-1}^{(s)}$ 分别表示第 s 个粒子对应的属性向量和权重。 δ 表示狄拉克函数。

利用 MM-PFPHD-JDTC 算法^[7]对 PHD 强度 D_{k-1} 预测，再采用第 1 个传感器得到的运动状态量测和属性量测进行更新，可得

$$D_k^1 \left(\begin{bmatrix} x_{1,k} \\ \mu_{1,k} \end{bmatrix}, r_{1,k} \right) = \sum_{s=1}^{J_k^1} w_{1,k}^{(s)} \delta(x_k - x_{1,k}^{(s)}, \mu_k - \mu_{1,k}^{(s)}, r_k - r_{1,k}^{(s)}) \quad (5.9)$$

采用上式得到的更新后的 PHD 分量 D_k^1 作为传感器 2 的预测分量，再利用传感器 2 的综合量测进行更新得到：

$$D_k^2 \left(\begin{bmatrix} x_{2,k} \\ \mu_{2,k} \end{bmatrix}, r_k \right) = [1 - P_D(x_{2,k})] D_k^1 \left(\begin{bmatrix} x_{1,k} \\ \mu_{1,k} \end{bmatrix}, r_k \right) + \sum_{\substack{g_k \\ \tilde{Z}_{k,2} \in \tilde{Z}_{k,2}}} D_{g_k} \left(\begin{bmatrix} x_{2,k} \\ \mu_{2,k} \end{bmatrix}, r_k | \tilde{Z}_{k,2} \right) \quad (5.10)$$

其中， D_{g_k} 为更新后的 PHD 强度。

利用上述序贯融合方法对所有 n 个传感器得到的数据进行处理，得到多目标后验强度 D_k^n 。最后，多传感器场景下的多目标后验强度 D_k 为

$$D_k \left(\begin{bmatrix} x_k \\ \mu_k \end{bmatrix}, r_k \right) = D_k^n \left(\begin{bmatrix} x_{n,k} \\ \mu_{n,k} \end{bmatrix}, r_k \right) \quad (5.11)$$

对所有粒子权重进行求和，可以得到估计的目标个数为

$$\hat{N}_{k|k} = \sum_{i=1}^{J_k^n} w_{n,k}^{(i)} \quad (5.12)$$

对目标状态可以通过 k 均值聚类方法进行提取，而目标类别向量可以通过对聚类后的粒子权重进行取均值得到，目标类别则采用极大后验概率的方法进行判断。

所提出算法与多传感器序贯 PHD 滤波器（Iterated-MM-PFPHD）的区别在于前者进一步对属性信息进行序贯处理。而目标先验强度和后验强度采用扩充属性信息的粒子进行近似。如果该算法忽略其属性向量 μ ，则退化为多传感器序贯 PHD 滤波器。

5.4 属性量测提取

在联合检测、跟踪和分类问题中，属性量测的提取与传感器类型有关。本章采用雷达对目标进行跟踪，并提取信噪比信息进行属性信息提取。传统雷达只采用方位和距离对目标进行跟踪，然而雷达在获取目标状态信息的同时能够得到信噪比信息。由于杂波信噪比较低，而目标的信噪比较高，引入信噪比信息可以提高对杂波和目标的区分能力。另外，不同类别目标信噪比一般也不同，比如目标可以分为高信噪比目标和低信噪比目标。因此通过信噪比信息可以实现对不同目标进行类别判断，进一步提高态势感知能力。文献[45]引入目标信号幅值辅助数据关联，提高对杂波的抑制，但需要假设目标平均信噪比固定并且已知，而目标真实平均信噪比通常未知或者在某一区间内变化。文献[46]通过在目标可能的信噪比区间对区间进行积分得到了未知信噪比目标的似然函数。本文通过划分不同类别目标平均信噪比可能区间实现对不同类别目标进行区分，再利用未知信噪比目标的似然函数得到目标的属性量测。

杂波以及不同类别目标的幅值概率密度分别为：

$$g_0(a) = a \exp\left(\frac{-a^2}{2}\right), a \geq 0 \quad (5.13)$$

$$g_a(a|d_1, d_2) = \frac{2 \left(\exp\left(\frac{-a^2}{2(1+d_2)}\right) - \exp\left(\frac{-a^2}{2(1+d_1)}\right) \right)}{a(\ln(1+d_2) + \ln(1+d_1))}, a \geq 0 \quad (5.14)$$

其中, a 为目标信号幅值, d_1 和 d_2 定义某一类别目标可能的平均信噪比区间。虚警概率为 $p_{FA}^\tau = \int_{\tau}^{+\infty} g_0(a) da$, 目标检测概率 $p_D^\tau(a|d_1, d_2) = \int_{\tau}^{+\infty} g_a(a|d_1, d_2) da$, 其中 τ 为信号检测门限。

对超过信号检测门限 τ 的概率密度函数重新进行归一化,

$$g_0^\tau(a) = g_0(a) / p_{FA}^\tau, a \geq \tau \quad (5.15)$$

$$g_a^\tau(a|d_1, d_2) = g_a(a|d_1, d_2) / p_D^\tau(a|d_1, d_2), a \geq \tau \quad (5.16)$$

通过划分目标平均信噪比可能区间对不同类别目标的进行分类。目标属性量测定义为归一化后不同类别目标的似然函数构成的向量。假设存在两类目标并可以通过平均信噪比区间进行区分, 区间分别为 $[d_1, d_2]$ 和 $[d_3, d_4]$, 则得到目标属性量测:

$$\eta = \frac{[g_0^\tau(a), g_a^\tau(a|d_1, d_2), g_a^\tau(a|d_3, d_4)]^T}{g_0^\tau(a) + g_a^\tau(a|d_1, d_2) + g_a^\tau(a|d_3, d_4)}, a \geq \tau \quad (5.17)$$




图 5-1 归一化的杂波和目标信号幅值似然函数图

Fig. 5-1 Normalized amplitude likelihood probability for clutter and targets

多传感器联合检测、跟踪和分类算法通过对目标信号幅值 a 进行提取, 利用式(5.17)得到属性量测向量 η 。不同类别目标的幅值概率曲线如图 5-1 所示 (定义第一类目标平均信噪比区间 $[10dB, 30dB]$, 第二类目标为 $[30dB, 50dB]$)。由于不同类别目标信号幅值区间不同, 通过提取接受到信号的幅值信息, 可以得到该信号属于不同类别目标的可能性, 即属性量测向量的每个分量。目标信号幅值较低时, 属性向量中杂波分量较大, 代表第一、二类目标的分量较小; 相反, 当目标幅值较高时, 属性向量中代表第二类目标 (高信噪比) 的分量较大, 目标属于杂波的可能性较小。

5.5 数值仿真

本章假设利用两部雷达同时对观测区域内的多个机动目标进行跟踪，两雷达的位置坐标分别为 $[1,0]km$ 和 $[0,0]km$ ，传感器探测区域面积为 $[0,2\pi]rad \times [0,15]km$ 。将目标信噪比区间划分为高信噪比区间 $[30dB, 50dB]$ 和低信噪比区间 $[10dB, 30dB]$ ，用于区分两类目标。仿真场景中存在两类目标：假设第一类目标真实平均信噪比为 $25dB$ ，第二类目标真实平均信噪比为 $45dB$ 。目标 1（第一类）在初始时刻 $k=0s$ 时从位置 $[-10,10]km$ 向东南方向运动，同时目标 2（第二类）和目标 3（第一类）从位置 $[-10,-10]km$ 和 $[-10,-10.5]km$ 开始并行向东北方向运动，而目标 4（第二类）在 $120s$ 出现并从位置 $[1.4,8]km$ 开始向南运动，在 $480s$ 时目标 4 消失，其他目标在 $360s$ 时消失。多目标运动场景如图 5-2 所示。




图 5-2 多传感器 PFPHD-JDTC 目标运动场景图
Fig.5-2 targets movement for multi-sensor PFPHD-JDTC

目标状态向量为 $X_k = [x_k, \dot{x}_k, y_k, \dot{y}_k, \omega_k]^T$ ，状态方程为 $X_k = F_k X_{k-1} + v_k$ ，目标运动模型集包含常速(CV)模型和转弯速率未知的常速转弯(CT)模型。

二维 CV 模型的目标状态转移矩阵为

$$F_{k,CV} = \text{diag}\left(\begin{bmatrix} 1 & dT \\ 0 & 1 \end{bmatrix}, \begin{bmatrix} 1 & dT \\ 0 & 1 \end{bmatrix}, 0\right) \quad (5.18)$$

过程噪声假设为正态分布，即 $X_k = F_k X_{k-1} + v_k$ ，采样周期为 $dT = 6s$ ，过程噪声协方差矩阵为：

$$Q_{k,CV} = \text{diag} \left(\begin{bmatrix} \frac{dT^3 l}{3} & \frac{dT^2 l}{2} \\ \frac{dT^2 l}{2} & dTl \end{bmatrix}, \begin{bmatrix} \frac{dT^3 l}{3} & \frac{dT^2 l}{2} \\ \frac{dT^2 l}{2} & dTl \end{bmatrix}, 0 \right) \quad (5.19)$$

其中 $l = 1m^2 / s^3$ 。

二维 CT 模型的状态转移矩阵为

$$F_{k,CT} = \begin{bmatrix} 1 & \frac{\sin(w_{k-1}dT)}{w_{k-1}} & 0 & -\frac{\cos(w_{k-1}dT)}{w_{k-1}} & 0 \\ 0 & \cos(w_{k-1}dT) & 0 & -\sin(w_{k-1}dT) & 0 \\ 0 & -\frac{\cos(w_{k-1}dT)}{w_{k-1}} & 1 & \frac{\sin(w_{k-1}dT)}{w_{k-1}} & 0 \\ 0 & \sin(w_{k-1}dT) & 0 & \cos(w_{k-1}dT) & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix} \quad (5.20)$$

过程噪声满足高斯分布，即 $v_{k,CT} \sim N(\cdot; 0, Q_{k,CT})$ ，而协方差为

$$Q_{k,CT} = \text{diag} \left(\begin{bmatrix} \frac{dT^3 l_1}{3} & \frac{dT^2 l_1}{2} \\ \frac{dT^2 l_1}{2} & dTl_1 \end{bmatrix}, \begin{bmatrix} \frac{dT^3 l_1}{3} & \frac{dT^2 l_1}{2} \\ \frac{dT^2 l_1}{2} & dTl_1 \end{bmatrix}, dTl_2 \right) \quad (5.21)$$

其中， $l_1 = 1m^2 / s^3$ ， $l_2 = 0.1rad^2 / s^3$ 。交互式多模型中的模型转移概率假设为

$$\pi = \begin{bmatrix} 0.8 & 0.2 \\ 0.2 & 0.8 \end{bmatrix}。$$

在二维情况下第 i 个传感器的量测方程为：

$$z_{k,i} = \begin{bmatrix} \sqrt{(x_{k,i} - p_{x,i})^2 + (y_{k,i} - p_{y,i})^2} \\ \text{atan} \left(\frac{y_{k,i} - p_{y,i}}{x_{k,i} - p_{x,i}} \right) \end{bmatrix} + w_{k,i}, \quad (5.22)$$

量测噪声满足正态分布 $w_k^i \sim N(\cdot; R_w^i)$ ，协方差假设为 $R_w^1 = R_w^2 = \text{diag} \left([(300m)^2, (\pi/180rad)^2] \right)。$

在本仿真中不考虑衍生目标，仅考虑新生目标。在 k 时刻，新生目标强度 $\gamma_k(x_k) = 0.05N(x_k; [0 \ 0 \ 8000 \ 0 \ 0]^T, \text{diag}([40000 \ 1000 \ 40000 \ 1000 \ 0.004]))。$

目标生存概率为 $P_s = 0.99$ 。每个目标采样 500 个粒子，对每个新生目标各采样 500 个粒子。属性量测采用未知平均信噪比目标的信号幅度获得，信号幅度检测门限 $\tau = 3.5$ 。两类目标检测概率分别为 $p_{d,k} = 0.999$ 和 $p_{d,k} = 0.98$ 。杂波个数服从参数为 $c_n = 40$ 的泊松分布且杂波在空间中服从均匀分布。

在下面的仿真中我们采用四种不同的滤波算法，即(a)单传感器多模型粒子 PHD 算法(MM-PFPHD)，(b)单传感器多模型粒子 PHD 联合检测、跟踪和分类算法(MM-PFPHD-JDTC)，(c)序贯多模型粒子 PHD 联合检测、跟踪算法(Iterated-MM-PFPHD)以及(d)序贯多模型粒子 PHD 联合检测、跟踪和分类算法(Iterated-MM-PFPHD-JDTC)。




图 5-3 MM-PFPHD 滤波结果
Fig.5-3 Estimated result of MM-PFPHD




图 5-4 MM-PFPHD-JDTC 滤波结果
Fig.5-4 Estimated result of MM-PFPHD-JDTC




图 5-5 Iterated-MM-PFPHD 滤波结果
Fig.5-5 Estimated result of Iterated MM-PFPHD




图 5-6 Iterated-MM-PFPHD-JDTC 滤波结果
Fig.5-6 Estimated result of Iterated MM-PFPHD-JDTC

图 5-3 到图 5-6 为采用四种不同滤波方法得到的目标位置估计结果。从中可以看出，(a)算法不能够输出类别信息，且在轨迹交叉处存在较多杂波。算法(b)能够滤波得到目标类别，且由于类别信息可以提高不同目标之间和抑制杂波能力，但在目标起始阶段目标类别估计不准，目标出现机动情况下，位置估计误差偏大。采用多传感器序贯融合，算法(c)比单传感器算法(a)在状态估计方面进一步提升，但是同样不能得到类别信息。本文所提出的 Iterated-MM-PFPHD-JDTC 算法充分利用多个传感器提供的状态和属性信息，比单传感器算法更准确判断目标类别，且当目标机动时也能较好的跟踪。

本文采用最优次分配距离（OSPA 距离）对状态估计误差进行衡量。取阶次 $p=2$ ，截断距离 $c=3km$ 。

进行 100 步蒙特卡洛（Monte Carlo）仿真，得到不同算法对目标数目的估计误差，如图 5-7 所示。图 5-8 为不同算法得到的 OSPA 距离对比结果。根据图 5-7

可知，本文算法相比传统算法更准确估计目标数目 N_{error} 。由图 5-8 可以看出，本文算法在 OSPA 距离方面的性能也明显优于已有算法，状态估计误差降低约 20%。本文算法不仅综合了算法(b)和(c)的优势，而且通过多传感器提供的类别信息序贯，进一步提高了目标与杂波之间的区分程度，抑制杂波量测，从而降低多目标数目和状态估计误差。

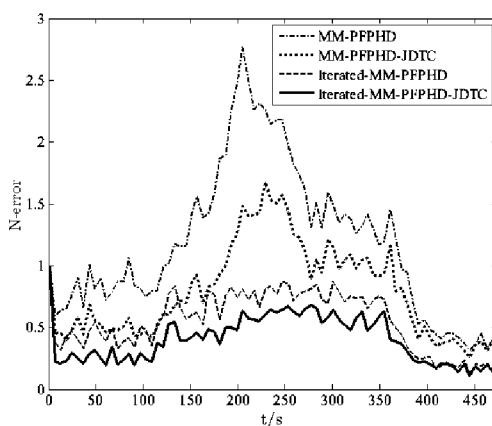


图 5-7 不同算法目标数目估计对比图

Fig.5-7 Absolute error in target number estimation




图 5-8 不同算法 OSPA 距离对比图

Fig.5-8 OSPA distances for different methods

算法仿真环境为：2.80 GHz Intel E7400 处理器，4 GB RAM，在此环境下通过蒙特卡洛仿真可以得到四种不同算法所需要的平均单步运算时间，分别为 0.175 秒，1.321 秒，0.169 秒和 2.382 秒，其中，Iterated-MM-PFPHD 算法比 MM-PFPHD 算法所需运算时间更少，原因在于前者能够有效减少杂波带来的干扰，从而更好

地估计目标数目。同时，我们注意到本章提出的 Iterated-MM-PFPHD-JDTC 算法所需运算时间最长，这是因为在每个序贯迭代采用多传感器量测数据对状态和属性信息进行序贯融合，这增加了相应的计算量。

5.6 本章小结

本章提出一种序贯多模型粒子 PHD 联合检测、跟踪和分类算法 (Iterated-MM-PFPHD-JDTC)，实现了非线性非高斯条件下的多传感器多目标联合检测、跟踪和分类。通过划分信噪比区间进行目标属性量测提取方法，解决了目标平均信噪比未知情况下属性量测建模问题。仿真结果表明，本文所提出的序贯多模型粒子 PHD 联合检测、跟踪和分类算法，相较传统算法，能有效降低多目标状态估计误差和提高目标数目的估计精度。

第六章 基于前向-后向平滑 PHD 的联合检测、跟踪和分类

6.1 引言

在现实情况中, 不同种类的目标运动特性可能不同, 因此在目标类别判断的基础上对不同种类的目标采用不同的运动模型集, 可以对跟踪过程建立更准确的预测方程, 提高滤波精度。从该角度出发, 杨威^[21]提出了一种类别相关模型集的 PHD-JDTC 滤波算法, 并采用粒子近似的思想, 给出了具体的实现方法。

对状态估计问题来说, 如果估计以后时刻的状态, 称为状态预测; 如果估计当前时刻的状态, 称为状态滤波; 如果估计以前时刻的状态, 则称之为平滑^[48]。平滑技术是采用当前时刻的量测, 对过去时刻的状态进行估计, 由于信息量的增加, 可以进一步提高状态估计精度。将平滑的思想引入到多目标贝叶斯滤波器中, 采用物理空间的方法可以得到相应的一阶矩形式即概率假设密度平滑器^[48] (PHD Smoother)。

如何利用平滑技术优化多目标联合检测、跟踪和分类算法, 提升目标状态估计和类别决策效果, 这是一个尚未解决的问题。本章考虑将平滑技术引入到的 PHD-JDTC 算法中, 推导类别相关模型集条件下的 PHD-JDTC 前向-后向平滑器。仿真结果表明, 该方法相比 PHD-JDTC 算法具有更好的状态估计性能。

6.2 PHD 前向-后向平滑器

在多目标贝叶斯滤波器和多目标贝叶斯平滑器的基础上, 采用物理空间的方法可以推导出相应的一阶矩近似形式, 即 PHD 前向滤波器和后向平滑器^[48, 49]。

(1) PHD 前向滤波器:

首先进行状态预测, 根据目标的状态方程对已存在目标的状态进行一步预测:

$$D_{k+1|k}(x) = \gamma_{k+1|k}(x) + \int F_{k+1|k}(x|x') \cdot D_{k|k}(x') dx' \quad (6.1)$$

其中,

$$F_{k+1|k}(x|x') = P_s(x') f_{k+1|k}(x|x') + \beta_{k+1|k}(x|x') \quad (6.2)$$

$\gamma_k(x)$ 表示 k 时刻新生目标的强度, $\beta_{k|k-1}(x|x')$ 是衍生目标的强度, $P_s(x')$ 是已存在目标的生存概率。

完成状态更新后再进行状态更新：

$$D_{k+1|k+1}(x) = D_{k+1|k}(x) \left[1 - P_D(x) + P_D(x) \sum_{z \in Z} \frac{L_z(x)}{\kappa_k(z) + D_{k+1|k}[P_D(x) \cdot L_z(x)]} \right] \quad (6.3)$$

其中，

$$D_{k+1|k}[P_D(x) \cdot L_z(x)] = \int P_D(x) \cdot L_z(x) \cdot D_{k+1|k}(x) dx \quad (6.4)$$

$P_D(x)$ 表示目标的检测概率， $\kappa_k(z)$ 表示杂波强度。

(2) PHD 后向平滑器：

由于能够利用更多的量测值，所以平滑技术能够进一步提高状态估计结果。平滑技术主要分为三种：固定区间平滑，固定点平滑以及固定滞后平滑。其中，固定滞后平滑在 k 时刻估计 $k-L$ 时刻的状态，表示 L 平滑滞后步数。对多目标贝叶斯平滑器采用概率假设密度的方法求取一阶矩形式，可以得到 PHD 平滑方程如下：

$$D_{t|k}(x_t | Z_{1:k}) = D_{t|t}(x_t | Z_{1:t}) \left[P_s(x_t) \int \frac{D_{t+1|k}(x_{t+1} | Z_{1:k}) f_{t+1|t}(x_{t+1} | x_t)}{D_{t+1|t}(x_{t+1} | Z_{1:t})} dx_{t+1} + 1 - P_s(x_t) \right] \quad (6.5)$$

其中，

$$D_{t+1|t}(x_{t+1} | Z_{1:t}) = \gamma(x_{t+1}) + \int [P_s(x_t) \cdot f_{t+1|t}(x_{t+1} | x_t) + \beta_{t+1|t}(x_{t+1} | x_t)] \cdot D_{t|t}(x_t) dx_t \quad (6.6)$$

值得注意的是，平滑过程是用当前的 k 时刻估计结果来初始化 $k-L$ 时刻的目标状态。

6.3 基于前向-后向平滑 PHD 的联合检测、跟踪和分类

6.3.1 跳变马尔科夫 PHD 滤波器

Mahler 提出了一种“top-down”形式的跳跃马尔科夫 PHD 滤波器^[50]。该方法的核心思想是扩展单目标状态空间，即状态空间为 $\tilde{x} = (x, o)$ ，其中 o 为扩展的跳跃分量，为有限多个可能的模型 $o=1, \dots, Q$ 。相应的多目标状态可以表示为 $\{(x_1, o_1), \dots, (x_n, o_n)\}$ 。采用 \tilde{x} 替换 x ，并带入 PHD 预测和更新方程，可得

$$D_{k+1|k}(\tilde{x}) = \dots \quad (6.7)$$

其中，

$$F_{k+1|k}(\tilde{x}) = \dots \quad (6.8)$$

预测步骤:

$$D_{k+1|k+1}(\ddot{x}) = D_{k+1|k}(\ddot{x}) \left[1 - P_D(\ddot{x}) + P_D(\ddot{x}) \sum_{z \in Z_{k+1}} \frac{L_z(\ddot{x})}{\kappa_{k+1}(z) + \tau_{k+1}(z)} \right] \quad (6.9)$$

其中,

$$\tau_{k+1}(z) = \int P_D(\ddot{x}) \cdot L_z(\ddot{x}) \cdot D_{k+1|k}(\ddot{x}) d\ddot{x} \quad (6.10)$$

进一步展开成相应的跳跃变量形式如下:

$$D_{k+1|k}(x, o) = \gamma_{k+1|k}(x, o) + \sum_{o'} \int F_{k+1|k}(x, o | x', o') \cdot D_{k|k}(x', o') dx' \quad (6.11)$$

$$F_{k+1|k}(x, o | x', o') = P_s(x', o') f_{k+1|k}(x, o | x', o') + \beta_{k+1|k}(x, o | x', o') \quad (6.12)$$

$$D_{k+1|k+1}(x, o) = D_{k+1|k}(x, o) \left[1 - P_D(x, o) + P_D(x, o) \sum_{z \in Z_{k+1}} \frac{L_z(x, o)}{\kappa_{k+1}(z) + \tau_{k+1}(z)} \right] \quad (6.13)$$

$$\tau_{k+1}(z) = \sum_o \int P_D(x, o) \cdot L_z(x, o) \cdot D_{k+1|k}(x, o) dx \quad (6.14)$$

对应的多目标状态估计可以通过对变量 o 求和得到:

$$\begin{aligned} D_{k+1|k+1}(x) &= \sum_o D_{k+1|k+1}(x, o) \\ &= 1 - \sum_o P_D(x, o) \cdot D_{k+1|k}(x, o) + \sum_{z \in Z_{k+1}} \frac{\sum_o P_D(x, o) \cdot L_z(x, o) \cdot D_{k+1|k}(x, o)}{\kappa_{k+1}(z) + \tau_{k+1}(z)} \end{aligned} \quad (6.15)$$

目标个数估计为:

$$N_{k+1|k+1}(x) = \int D_{k+1|k+1}(x) dx \quad (6.16)$$

6.3.2 跳变马尔科夫 PHD 平滑器

对于后向平滑, 我们同样采用扩展跳跃分量的方法, 可以得到包含跳跃分量的 PHD 平滑滤波方程。

命题 6.1 (跳变马尔科夫平滑器) 估计得到 k 时刻目标状态后, 可以反向平滑得到 $k-L$ 时刻的状态, L 表示平滑滞后步数。采用跳跃分量 o 扩展单目标状态空间, 即 $\ddot{x} = (x, o)$ 。因此得到跳变马尔科夫平滑方程如下:

$$\begin{aligned} D_{t|k}(x_t, o | Z_{1:k}) &= D_{t|t}(x_t, o | Z_{1:t}) \\ &\times \left[P_s(x_t, o) \sum_{o'} \int \frac{D_{t+1|k}(x_{t+1}, o' | Z_{1:k}) f_{t+1|t}(x_{t+1}, o' | x_t, o)}{D_{t+1|t}(x_{t+1}, o' | Z_{1:t})} dx_{t+1} + 1 - P_s(x_t, o) \right] \end{aligned} \quad (6.17)$$

其中,

$$D_{t+1|t}(x_{t+1}, o' | Z_{1:t}) = \gamma(x_{t+1}, o') + \sum_o \int \left[P_s(x_t, o) \cdot f_{t+1|t}(x_{t+1}, o' | x_t, o) + \beta_{t+1|t}(x_{t+1}, o' | x_t, o) \right] \cdot D_{t|t}(x_t, o) dx_t \quad (6.18)$$

证明：将 x 替换为 \ddot{x} ，代入式(6.5)和式(6.6)，可得

$$D_{t|k}(\ddot{x}_t) = D_{t|t}(\ddot{x}_t) \left[P_s(\ddot{x}_t) \int \frac{D_{t+1|k}(\ddot{x}_{t+1}) f_{t+1|t}(\ddot{x}_{t+1} | \ddot{x}_t)}{D_{t+1|t}(\ddot{x}_{t+1})} d\ddot{x}_{t+1} + 1 - P_s(\ddot{x}_t) \right] \quad (6.19)$$

$$D_{t+1|t}(\ddot{x}_{t+1}) = \gamma(\ddot{x}_{t+1}) + \int \left[P_s(\ddot{x}_t) \cdot f_{t+1|t}(\ddot{x}_{t+1} | \ddot{x}_t) + \beta_{t+1|t}(\ddot{x}_{t+1} | \ddot{x}_t) \right] \cdot D_{t|t}(\ddot{x}_t) d\ddot{x}_t \quad (6.20)$$

将 $\ddot{x} = (x, o)$ 代入式(6.19)和式(6.20)可得跳变马尔科夫平滑器，如式(6.17)和式(6.18)所示。

证毕！

在跳变马尔科夫 PHD 滤波器式(6.11)-式(6.16)和平滑器式(6.17)-式(6.18)中采用目标运动模型 r 替代 o ，可以得到多模型 PHD 滤波器（MM-PHD）和多模型 PHD 平滑器（MM-PHD smoother）相应的表达式。这些表达式与文献[43]和[48]中的公式一致。

6.3.3 PHD-JDTC 滤波器

Mahler 提出的跳变马尔科夫 PHD 滤波器主要针对目标的运动模型发生跳转的情况，然而目标的类别也同样可以看成是一种跳变马尔科夫变量。已存在目标的类别满足时不变，是一种特殊的跳变马尔科夫变量。对衍生目标而言，其类别信息可能不同于母目标，如战机发射导弹武器等，可以用类别转移概率分布函数表示。文献[21]推导了类别条件化的 PHD-JDTC 滤波器，但采用的是标志点过程强度函数叠加的方法。下面我们 Mahler 提出的“top-down”的方法，基于跳变马尔科夫 PHD 滤波器重新推导加入类别信息的 PHD-JDTC。

采用类别信息 c 对状态 x 进行扩展，可得 $\ddot{x} = (x, c)$ ，并代入式(6.7)-(6.10)，并展开可得：

$$D_{k+1|k}(x, c) = \gamma_{k+1|k}(x, c) + \sum_{c'} \int F_{k+1|k}(x, c | x', c') \cdot \text{[redacted]} dx' \quad (6.21)$$

$$D_{k+1|k+1}(x, c) = D_{k+1|k}(x, c) \left[1 - P_D(x, c) + P_D(x, c) \sum_{c'} \frac{L_c(x, c)}{\text{[redacted]}(c')} \right] \quad (6.22)$$

其中，

$$F_{k+1|k}(x, c | x', c') = P_s(x', c') f_{k+1|k}(x, c | x', c') + \beta_{k+1|k}(x, c | x', c') \quad (6.23)$$

$$\tau_{k+1}(\tilde{z}) = \sum_c \int P_D(x, c) \cdot L_{\tilde{z}}(x, c) \cdot D_{k+1|k}(x, c) dx \quad (6.24)$$

根据已存在目标的类别满足时不变, 可得

$$f_{k+1|k}(c|c') = \begin{cases} 0 & c \neq c' \\ 1 & c = c' \end{cases} \quad (6.25)$$

而衍生目标其类别信息可能不同于母目标, 相应的类别跳转可以用类别转移概率分布函数表示。将式(6.25)代入式(6.21)-式(6.24)并重新整理可得

(1) PHD-JDTC 预测步:

$$\begin{aligned} D_{k+1|k}(x, c) &= \gamma_{k+1|k}(x, c) + \sum_{c'} \int \beta_{k+1|k}(x, c | x', c') \cdot D_{k|k}(x', c') dx' \\ &\quad + \int P_s(x', c) f_{k+1|k}(x, c | x', c) dx' \end{aligned} \quad (6.26)$$

(2) PHD-JDTC 更新步:

$$\begin{aligned} D_{k+1|k+1}(x, c) &= D_{k+1|k}(x, c) \\ &\times \left[1 - P_D(x, c) + P_D(x, c) \sum_{\tilde{z} \in \tilde{Z}_{k+1}} \frac{L_{\tilde{z}}(x, c)}{\kappa_{k+1}(\tilde{z}) + \sum_c \int P_D(x, c) \cdot L_{\tilde{z}}(x, c) \cdot D_{k+1|k}(x, c) dx} \right] \end{aligned} \quad (6.27)$$

(3) 多目标状态估计和数目估计:

多目标状态估计将式(6.27)中变量 c 求和得到, 即

$$D_{k+1|k+1}(x) = \sum_c D_{k+1|k+1}(x, c) \quad (6.28)$$

对所得到的 PHD 进行积分可得多目标数目如式(6.16)所示。至此, 可以得到加入类别信息的 PHD-JDTC 滤波器。从式(6.26)和式(6.27)可以看出, 不同类别条件化的概率假设密度函数之间存在信息交互, 表现为预测阶段不同类别衍生目标相互作用和更新阶段所有类别目标的联合似然函数归一化。

6.3.4 PHD-JDTC 平滑器

采用推导加入类别信息的 PHD-JDTC 滤波器类似的方法可以进一步得到类别辅助的 PHD-JDTC 平滑器。

命题 6.2 (PHD-JDTC 平滑器) 估计得到 k 时刻目标状态后, 采用固定滞后区间平滑方法得到 $k-L$ 时刻的状态。采用类别分量 c 扩展单目标状态空间, 进一步得到 PHD-JDTC 平滑器概率假设密度如下:

$$D_{i|k}(x_t, c | Z_{1:k}) = D_{i|l}(x_t, c | Z_{1:l}) \times \left[P_s(x_t, c) \int \frac{D_{i+1|k}(x_{t+1}, c' = c | Z_{1:k}) f_{i+1|l}(x_{t+1} | x_t, c)}{D_{i+1|l}(x_{t+1}, c' = c | Z_{1:l})} dx_{t+1} + 1 - P_s(x_t, c) \right] \quad (6.29)$$

其中,

$$D_{i+1|l}(x_{t+1}, c' = c | Z_{1:l}) = \gamma(x_{t+1}, c') + \int P_s(x_t, c) \cdot f_{i+1|l}(x_{t+1} | x_t, c) \cdot D_{i|l}(x_t, c | Z_{1:l}) dx_t + \sum_{c''} \int \beta_{i+1|l}(x_{t+1}, c' = c | x_t, c'') \cdot D_{i|l}(x_t, c'' | Z_{1:l}) dx_t \quad (6.30)$$

证明: 采用目标类别信息 c 对状态 x 进行扩展, 即 $\ddot{x} = (x, c)$, 并代入式(6.5)和式(6.6)可得

$$D_{i|k}(x_t, c | Z_{1:k}) = D_{i|l}(x_t, c | Z_{1:l}) \times \left[P_s(x_t, c) \sum_c \int \frac{D_{i+1|k}(x_{t+1}, c' | Z_{1:k}) f_{i+1|l}(x_{t+1}, c' | x_t, c)}{D_{i+1|l}(x_{t+1}, c' | Z_{1:l})} dx_{t+1} + 1 - P_s(x_t, c) \right] \quad (6.31)$$

其中,

$$D_{i+1|l}(x_{t+1}, c' | Z_{1:l}) = \gamma(x_{t+1}, c') + \sum_c \int \left[P_s(x_t, c) \cdot f_{i+1|l}(x_{t+1}, c' | x_t, c) + \beta_{i+1|l}(x_{t+1}, c' | x_t, c) \right] \cdot D_{i|l}(x_t, c) dx_t \quad (6.32)$$

考虑已存在目标的类别满足时不变和衍生目标类别信息时变特点, 将式(6.25)代入式(6.31)和式(6.32)可得式(6.29)和式(6.30)。

证毕!

平滑后多目标状态估计将式(6.29)中变量 c 求和得到, 即

$$D_{i|k}(x_t | Z_{1:k}) = \sum_c D_{i|k}(x_t, c | Z_{1:k}) \quad (6.33)$$

进一步对概率假设密度进行积分可得平滑后多目标数目估计为

$$N_{i|k}(x_t) = \int D_{i|k}(x_t | Z_{1:k}) dx_t \quad (6.34)$$

由式(6.29)分析可知, 在 PHD-JDTC 平滑器中, 不同类别目标在不同的 PHD 平滑器中进行后向更新。另外, 由式(6.30)中可以看出, 由于衍生目标的存在, 不同平滑器之间存在信息交互。从本质上说, 衍生目标与母目标的类别可能不相同, 某一类别的子目标可能来自于不同类别的母目标。假如不考虑衍生目标, 则平滑过程中不同类别目标的 PHD 平滑器是独立的。

6.4 类别相关模型集的 PHD-JDTC 前向-后向平滑器

6.4.1 算法概述

文献[21]考虑到不同类别目标机动性能不同, 因此对不同类别目标建立不同的运动模型集。将 $\hat{x} = \{x, (r|c)\}$ 代入式(6.7)-(6.10)和式(6.19)-(6.20)可以得到类别匹配模型集的 PHD-JDTC 前向-后向平滑器。主要方法是滤波阶段为每一类目标分配类别匹配的 PHD 滤波器, 在后向平滑阶段每一类目标分配类别匹配的 PHD 平滑器。而在不同类别匹配的滤波器和平滑器中, 分别采用各自对应的模型集。

6.4.2 粒子实现方法

综合 PHD-JDTC 滤波器和 PHD-JDTC 平滑器, 可以得到 PHD-JDTC 前向-后向平滑算法。该算法的流程如图 6-1 所示。从中可以看出不同类别目标分别对应于不同的 PHD 滤波器和 PHD 平滑器, 而滤波和平滑阶段不同类别目标都存在信息交互过程。

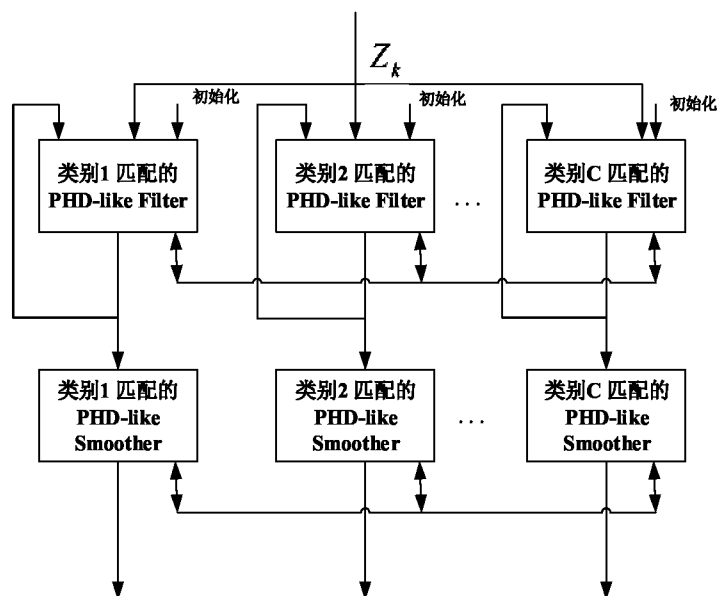


图 6-1 PHD-JDTC 前向-后向平滑流程图

Fig.6-1 Recursive forward-backward PHD-JDTC smoother

下面给出完整的 PHD-JDTC 前向后向平滑粒子实现方法。

(1) 滤波阶段

滤波阶段主要分为三个步骤^[21]: 粒子预测, 粒子更新和粒子重采样。

假设具有类别和模型信息的粒子状态向量为 $\ddot{x} \in \bigcup_{c \in C} (X_c \times c \times M_c)$ 。

Step 1 (粒子预测): 假设 $k-1$ 时刻, 类别条件化的后验概率假设密度为 $D_{k-1,c}$, 对第 c 类目标采样 N_{k-1}^c 个等权重粒子进行近似表示为 $\{w_{k-1,c}^s, \ddot{x}_{k-1,c}^s\}_{s=1}^{N_{k-1}^c}$ 。不同类别目标按照相应的运动模型集进行一步预测。

对于已存在目标, 直接在各自类别 PHD 滤波器中按照标准的 PHD 或者多模型 PHD 进行滤波。而对于衍生目标, 存在不同类别目标间的信息交互。首先进行衍生目标模型预测, 预测得到粒子类别标签

$$c_{\beta,k|k-1}^s \sim \phi(\cdot | c_{k-1}), s=1, \dots, J_{\beta,c_{k-1}} \quad (6.35)$$

其中, c_{k-1} 为母目标类别, $J_{\beta,c_{k-1}}$ 为衍生目标粒子数目。建议分布 $\phi(\cdot | c_{k-1})$ 一般取衍生目标类别转移概率 $p_{\beta,k|k-1}(c | c')$, 衍生目标粒子权重为

$$w_{\beta,k|k-1}^s(c_{\beta,k|k-1}^s) = \frac{p_{\beta,k|k-1}(c_{\beta,k|k-1}^s | c_{k-1}^s)}{\phi(c_{\beta,k|k-1}^s | c_{k-1}^s)}, s=1, \dots, J_{\beta,c_{k-1}} \quad (6.36)$$

对于机动目标, 模型预测 $r_{\beta,k|k-1}^s(c_{\beta,k|k-1}^s)$ 同样采用随机采样的方法。预测粒子 $\{x_{c_{\beta,k|k-1}^s}^s\}_{s=1}^{J_{\beta,c_{k-1}}}$ 通过建议分布 $\phi(x_{c_{\beta,k|k-1}^s}^s | c_{\beta,k|k-1}^s, x_{c_{k-1}^s}^s, c_{k-1}^s)$ 得到, 相应的权重为

$$\tilde{w}_{\beta,k|k-1}^s(c_{\beta,k|k-1}^s) = w_{\beta,k|k-1}^s(c_{\beta,k|k-1}^s) \frac{\beta_{k|k-1}(x_{c_{\beta,k|k-1}^s}^s | x_{c_{k-1}^s}^s)}{\phi(x_{c_{\beta,k|k-1}^s}^s | c_{\beta,k|k-1}^s, x_{c_{k-1}^s}^s, c_{k-1}^s)}, s=1, \dots, J_{\beta,c_{k-1}} \quad (6.37)$$

所有类别目标的粒子经过相应的状态方程预测后, 可以得到各类别 c 对应的粒子群 $\{\tilde{w}_{k|k-1}^s, \ddot{x}_{k|k-1,c}^s\}_{s=1}^{\tilde{N}_{k|k-1,c}}$ 。

Step 2 (状态更新): 采用综合量测值对粒子进行更新, 更新后粒子权重为

$$\hat{w}_{k,c}^s = \tilde{w}_{k|k-1,c}^s \left[(1 - p_{D,c}(\ddot{x}_{k|k-1,c}^s)) + \sum_{j=1}^{M(k)} \frac{p_{D,c}(\ddot{x}_{k|k-1,c}^s) g_{k,c,r}(z_{k,x}^j | \ddot{x}_{k|k-1,c}^s) h_{k,c,r}(z_{k,f}^j | \ddot{x}_{k|k-1,c}^s)}{K(z_{k,x}^j) c_f(z_{k,f}^j) + \Psi(z_k^j)} \right] \quad (6.38)$$

其中,

$$\Psi(z_k^j) = \sum_{c \in C} \sum_{s=1}^{\tilde{N}_{k|k-1,c}} p_{D,c}(\ddot{x}_{k|k-1,c}^s) \quad (6.39)$$

$g_{k,c,r}(z_{k,x}^j | \ddot{x}_{k|k-1,c}^s)$ 为状态量测似然函数, $h_{k,c,r}(z_{k,f}^j | \ddot{x}_{k|k-1,c}^s)$ 为属性量测似然函数。

Step 3 (粒子重采样): 状态更新后的对每个类别相应的粒子进行类别内重采样, 避免粒子匮乏。最终得到更新后的粒子集合 $\{\hat{w}_{k,c}^s, \ddot{x}_{k,c}^s\}_{s=1}^{\hat{N}_{k,c}}$ 。

(2) 平滑阶段

平滑阶段主要分为两个步骤：粒子平滑和平滑后粒子重采样。

Step 4 (粒子平滑)：滤波阶段，概率假设密度 $D_{t|t}(x_t, r_t, c_t | Z_{1:t})$ 的粒子集合重新记为 $\{w_{t|t}^{(s)}, x_{t|t}^{(s)}, r_{t|t}^{(s)}, c_{t|t}^{(s)}\}_{s=1}^{L_t}$, $t = k-L, \dots, k$ ，对于 c 类目标，

$$D_{t|t}(x_t, r_t, c | Z_{1:t}) = \sum_{s=1}^{L_t(c)} w_{c,t|t}^{(s)} \cdot \delta(x_t - x_{t|t}^{(s)}, r_t - r_{t|t}^{(s)}, c - c_{t|t}^{(s)}) \quad (6.40)$$

For $t = k-1, \dots, k-L$

$$w_{c,t|k}^{(s)} = w_{c,t|t}^{(s)} \left[P_s(x_t^{(s)}) \sum_{q=1}^{L_{t+1}(c)} \frac{w_{c,t+1|k}^{(q)} \cdot f_{c,t+1|t}(x_{t+1}^{(q)} | x_t^{(s)}) h_{r_{t+1,c}^{(q)}, r_{t,c}^{(s)}}}{\mu_{c,t+1|t}^{(q)}} + 1 - P_s(x_t^{(s)}) \right], s = 1, \dots, L_t(c) \quad (6.41)$$

其中，

$$\begin{aligned} \mu_{c,t+1|t}^{(q)} &= \gamma_{c,t+1}(x_{t+1}^{(q)}) + \sum_{u=1}^{L_t(c)} w_{c,t|t}^{(u)} h_{r_{t+1,c}^{(q)}, r_{t,c}^{(u)}} \{P_s(x_t^{(u)}) f_{c,t+1|t}(x_{t+1}^{(q)} | x_t^{(u)})\} \\ &+ \sum_{c'} \sum_{u=1}^{L_t(c')} w_{c',t|t}^{(u)} \cdot \beta_{c,t+1|t}(x_{t+1}^{(q)}, r_{t+1,c}, c | x_t^{(u)}, r_{t,c'}, c'') \end{aligned} \quad (6.42)$$

循环结束后得到新的粒子集合 $\{w_{k-L|k-L}^{(s)}, x_{k-L|k-L}^{(s)}, r_{k-L|k-L}^{(s)}, c_{k-L|k-L}^{(s)}\}_{s=1}^{L_{k-L}}$ 。假如忽略衍生目标，消去式(6.42)中的第三项，则不同类别目标对应的 PHD-JDTC 平滑器是相互独立的。

Step 5 (平滑后粒子重采样)：状态更新后的对每个类别相应的粒子进行类别内重采样，避免粒子匮乏。最终得到反向更新后的 $k-L$ 时刻第 c 类目标粒子集合 $\{\bar{w}_{k-L,c}^s, \bar{x}_{k-L,c}^s, \bar{r}_{k-L,c}^s\}_{s=1}^{N_{k-L}^c}$ 。

Step 6 (平滑后状态提取与数目估计)：然后对不同类别粒子进行类别内粒子聚类，提取平滑后多目标的运动状态，对所有粒子权重求和，可以最终得到平滑后多目标数目估计。

由于平滑过程涉及到大量粒子间的相互作用，所有运算复杂度很高。为了达到实时性要求，需要采用 *kd-tree*^[48] 方法。这种方法考虑大量粒子在空间中分布紧凑的情况，采用 “*group-to-group*” 的方法能够在误差允许的范围内大幅度提升运算速度。

6.5 数值仿真

为了验证本章提出的 PHD-JDTC 前向后向平滑器的性能，我们将其与 PHD-JDTC 滤波器进行对比，同样采用目标交叉和并行运动场景。文献[45]中目标

的属性信息取自于雷达量测信号的信噪比，并假设目标的平均信噪比已知，但是目标真实平均信噪比通常未知或者在某一区间内变化。文献[46]通过在目标可能的信噪比区间对区间进行积分得到了未知信噪比目标的似然函数。本文首先划分不同类别目标平均信噪比可能区间，然后将未知信噪比目标的似然函数作为杂波和各类别目标的属性似然函数。

假设监视区域总共有两种不同类别的目标，目标的平均信噪比分别为 45dB 和 25dB 。我们将信噪比区间分为高信噪比区间和低信噪比区间，不妨分别取为 $[30\text{dB}, 50\text{dB}]$ 和 $[10\text{dB}, 30\text{dB}]$ 。采用 Rayleigh 分布幅值模型，信号的强度利用包络检测器得到。杂波以及不同类别目标的信号幅值概率密度分别为：

$$g_0(a) = a \exp\left(-\frac{a^2}{2}\right), a \geq 0 \quad (6.43)$$

$$g_a(a | d_1, d_2) = \frac{2 \left(\exp\left(\frac{-a^2}{2(1+d_2)}\right) - \exp\left(\frac{-a^2}{2(1+d_1)}\right) \right)}{a (\ln(1+d_2) + \ln(1+d_1))}, a \geq 0 \quad (6.44)$$

其中， a 为目标信号幅值， $[d_1, d_2]$ 定义某一类别目标可能的平均信噪比区间。虚警概率为 $p_{FA}^\tau = \int_\tau^{+\infty} g_0(a) da$ ，目标检测概率为 $p_D^\tau(a | d_1, d_2) = \int_\tau^{+\infty} g_a(a | d_1, d_2) da$ ，其中 τ 为信号检测门限。

对超过信号检测门限 τ 的概率密度函数重新进行归一化，可得杂波以及不同类别目标的属性似然函数分别为：

$$g_0^\tau(a) = g_0(a) / p_{FA}^\tau, a \geq \tau \quad (6.45)$$

$$g_a^\tau(a | d_1, d_2) = g_a(a | d_1, d_2) / p_D^\tau(a | d_1, d_2), a \geq \tau \quad (6.46)$$

假设利用位于原点的单部雷达对观测区域内的多个不同种类的机动目标进行跟踪，传感器探测区域面积为 $[0, 2\pi] \text{rad} \times [0, 3] \text{km}$ 。不妨设定信号幅度检测门限 $\tau = 4.24$ 。进一步计算得到两类目标检测概率理论值分别为 $p_{D,1}^\tau = 0.9981$ 和 $p_{D,2}^\tau = 0.8431$ 。（真实的检测概率为 $p_{D,1, \text{true}}^\tau = 0.9997$ 和 $p_{D,2, \text{true}}^\tau = 0.9720$ ）。干扰杂波个数满足参数为 $c_n = 27$ 的泊松分布。杂波在空间可能出现的位置满足均匀分布。

目标状态向量为 $X_k = [x_k, \text{ }]$ ，状态方程为 $X_k = F_k X_{k-1} + v_k$ 。第一类目标运动模型机动性较大，采用常速(CV)模型和目标转弯速率未知的常速转弯(CT)模型进行表示。

二维 CV 模型的目标状态转移矩阵为

$$F_{k,CV} = \text{diag}\left(\begin{bmatrix} 1 & dT \\ 0 & 1 \end{bmatrix}, \begin{bmatrix} 1 & dT \\ 0 & 1 \end{bmatrix}, 0\right), \quad (6.47)$$

过程噪声假设为正态分布，即 $v_{k,CV} \sim N(0, Q_{k,CV})$ ，采样周期为 $dT = 5s$ ，过程噪声协方差矩阵为：

$$Q_{k,CV} = \text{diag}\left(\begin{bmatrix} \frac{dT^3 l}{3} & \frac{dT^2 l}{2} \\ \frac{dT^2 l}{2} & dT l \end{bmatrix}, \begin{bmatrix} \frac{dT^3 l}{3} & \frac{dT^2 l}{2} \\ \frac{dT^2 l}{2} & dT l \end{bmatrix}, 0\right), \quad (6.48)$$

其中 $l = 5m^2 / s^3$ 。

二维 CT 模型的状态转移矩阵为

$$F_{k,CT} = \begin{bmatrix} 1 & \frac{\sin(w_{k-1}dT)}{w_{k-1}} & 0 & -\frac{\cos(w_{k-1}dT)}{w_{k-1}} & 0 \\ 0 & \cos(w_{k-1}dT) & 0 & -\sin(w_{k-1}dT) & 0 \\ 0 & -\frac{\cos(w_{k-1}dT)}{w_{k-1}} & 1 & \frac{\sin(w_{k-1}dT)}{w_{k-1}} & 0 \\ 0 & \sin(w_{k-1}dT) & 0 & \cos(w_{k-1}dT) & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix}, \quad (6.49)$$

过程噪声满足高斯分布，即 $v_{k,CT} \sim N(0, Q_{k,CT})$ ，而协方差矩阵为

$$Q_{k,CT} = \text{diag}\left(\begin{bmatrix} \frac{dT^3 l_1}{3} & \frac{dT^2 l_1}{2} \\ \frac{dT^2 l_1}{2} & dT l_1 \end{bmatrix}, \begin{bmatrix} \frac{dT^3 l_1}{3} & \frac{dT^2 l_1}{2} \\ \frac{dT^2 l_1}{2} & dT l_1 \end{bmatrix}, dT l_2\right), \quad (6.50)$$

其中， $l_1 = 5m^2 / s^3$ ， $l_2 = 5 \times 10^{-5} rad^2 / s^3$ 。交互式多模型中的模型转移概率假设为

$$\pi = \begin{bmatrix} 0.9 & 0.1 \\ 0.1 & 0.9 \end{bmatrix}.$$

第二类目标为机动性小的目标，仅采用匀速直线（CV）模型进行描述，状态方程相关参数与第一类目标采用相同设置。

二维情况下传感器的量测方程为：

$$z_k = \begin{pmatrix} \sqrt{(x_k - p_x)^2 + (y_k - p_y)^2} \\ \text{atan}\left(\frac{y_k - p_y}{x_k - p_x}\right) \end{pmatrix} + w_k \quad (6.51)$$

量测噪声满足正态分布 $w_k \sim N(\cdot; \mathbf{0}_w)$ ，协方差假设为 $R_w = \text{diag}\left(\left[(60m)^2, (2\pi/180rad)^2\right]\right)$ 。

考虑新生目标，在 k 时刻第一类目标的新生目标强度为

$$\begin{aligned} \gamma_{k,1}(x_k) = & 0.01N\left(x_k; [-1500 \ 0 \ 1000 \ 0 \ 0]^T, \text{diag}\left(\begin{bmatrix} 1 & 100 & 1 & 100 & 10^{-6} \end{bmatrix}\right)\right) \\ & + 0.01N\left(x_k; [-1500 \ 0 \ -1000 \ 0 \ 0]^T, \text{diag}\left(\begin{bmatrix} 1 & 100 & 1 & 100 & 10^{-6} \end{bmatrix}\right)\right) \end{aligned} \quad (6.52)$$

第二类新生目标为

$$\begin{aligned} \gamma_{k,2}(x_k) = & 0.01N\left(x_k; [-1500 \ 0 \ 1000 \ 0 \ 0]^T, \text{diag}\left(\begin{bmatrix} 1 & 100 & 1 & 100 & 10^{-7} \end{bmatrix}\right)\right) \\ & + 0.02N\left(x_k; [-1000 \ 0 \ -1500 \ 0 \ 0]^T, \text{diag}\left(\begin{bmatrix} 1 & 100 & 1 & 100 & 10^{-7} \end{bmatrix}\right)\right) \end{aligned} \quad (6.53)$$

许多有关 PHD 滤波器的文献都没有考虑衍生目标。在本仿真中，我们考虑衍生目标，以体现不同类别条件化的 PHD 滤波器的信息交互作用。假设每一类目标都可能产生衍生目标，衍生目标可能为第一类或第二类，每个时刻只能产生一个衍生目标，按照已存在目标位置进行衍生粒子采样。

衍生目标强度为

$$\beta_{k|k-1}(x_k, r_k, c_k | x_{k-1}, r_{k-1}, c_{k-1}) = \lambda_\beta f_\beta(x_k | x_{k-1}) f_{k|k-1}(r_k, c_k | r_{k-1}, c_{k-1}) b(c_k | c_{k-1}) \quad (6.54)$$

其中， $\lambda_\beta = 0.01$ ， $f_\beta(x_k | x_{k-1}) = N\left(x_k | x_{k-1}, \text{diag}\left(\begin{bmatrix} 100 & 1 & 100 & 1 & 10^{-8} \end{bmatrix}\right)\right)$ ，

$f_{k|k-1}(r_k, c_k | r_{k-1}, c_{k-1}) = \begin{bmatrix} 0.9 & 0.1 \\ 0.1 & 0.9 \end{bmatrix}$ 。假设衍生目标的类别转移概率采用类别转移矩阵表示，即 $b(c_k | c_{k-1}) = \begin{bmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \end{bmatrix}$ 。

目标生存概率为 $P_s = 0.99$ 。每个已存在目标采样 500 个粒子，对每个新生目标各采样 500 个粒子。平滑滞后步数设为两步 $L = 2$ 。

监视区域内总共存在 6 个目标。目标 1（第一类）和目标 3（第二类）在初始时刻分别从位置 $[-1500, 1030]m$ 和 $[-1500, 970]m$ 并行向正东开始常速前进，同时目标 2（第一类）从位置 $[-1500, -1000]m$ 沿正东开始常速前进，目标 4（第二类）则向正北行进，开始位置为 $[-1000, -1500]m$ ，目标 5（第二类）为新生目标于第 34 步时出现，而目标 6（第二类）在第 20 步从目标 2 衍生出来。多类别目标运动场景如图 6-2 所示。




图 6-2 PHD-JDTC 前向-后向平滑仿真场景示意图

(—: 第一类目标, - -: 第二类目标)

Fig.6-2 Simulation scenario of forward-backward PHD-JDTC

(—: type1, - -: type2)

采用 PHD-JDTC 前向-后向平滑器得到态势感知如图 6-3 所示。




图 6-3 PHD-JDTC 前向-后向平滑滤波结果

(o: 第一类目标, *: 第二类目标)

Fig.6-3 Estimated trajectories with forward-backward PHD-JDTC

(o: type1, *: type2)

从滤波跟踪结果可知, 类别信息的引入可以有效处理跟踪不同种类目标交叉和并行运动时跟踪不稳定问题。

不同类别目标的目标数目估计误差如图 6-4 和图 6-5 所示。

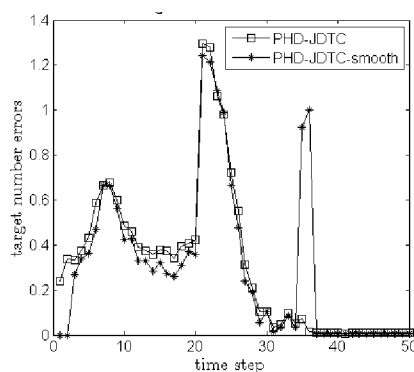


图 6-4 第一类目标数目估计误差对比图
Fig.6-4 Target number error comparison for type 1 targets




图 6-5 第二类目标数目估计误差对比图
Fig.6-5 Target number error comparison for type 2 targets

从图 6-4 和图 6-5 分析可知，不同类别目标个数估计平滑前后基本一致，因此对目标数目的估计性能相似，与 Mahler^[49]推导的结论一致，平滑不能提升基数（cardinality）估计。另外，平滑具有滞后现象。出现目标提前消失现象，造成目标数目在目标消失时刻估计不准确。

不同类别目标的 OSPA 距离对比如图 6-6 和图 6-7 所示。平滑前后全部目标的 OSPA 距离对比如图 6-8 所示。




图 6-6 第一类目标 OSPA 距离对比图
Fig.6-6 OSPA distance comparison for type 1 targets




图 6-7 第二类目标 OSPA 距离对比图
Fig.6-7 OSPA distance comparison for type 2 targets




图 6-8 所有类别目标 OSPA 距离对比图
Fig.6-8 OSPA distance comparison for all type of targets

通过图 6-6 至图 6-7 的 OSPA 距离结果对比可知，本章算法对不同类别的目标估计得到的 OSPA 距离均减小。采用信噪比对目标进行区分，信噪比高的目标平滑后 OSPA 距离更小；相反，信噪比较低的目标 OSPA 距离降低的程度较小。原因在于信噪比高的目标与杂波的区分程度更高，不易受到杂波影响。而信噪比低的目标与杂波信噪比区间接近，因此采用类别信息区分两者的能力比较差。图 6-8 分析可知，综合各类目标考虑，本章提出的 PHD-JDTC 前向-后向平滑器在跟踪精度方面优于 PHD-JDTC 滤波器。

从运算量角度考虑，加入类别信息后，代表不同类别目标的粒子间的相互作用只发生在衍生目标当中，不同类别已有目标的粒子不进行交互，因此引入类别后的平滑运算复杂度要低于不考虑类别信息的平滑算法。

6.6 本章小结

本章提出了一种基于前向-后向平滑的 PHD-JDTC 算法，实现了平滑技术优化的多目标联合检测、跟踪和分类。本章首先介绍了 PHD 前向-后向平滑器，并给出跳变马尔科夫 PHD 滤波器。在此基础上，本章进一步推导了跳变马尔科夫 PHD 平滑器。其次，引入类别信息，采用“自顶向下”的方法重新推导 PHD-JDTC 滤波器。再次，推导得到 PHD-JDTC 平滑器，从而实现了完整的 PHD-JDTC 前向-后向平滑器。最后，通过对不同类别目标采用不同的运动模型集，提出类别相关模型集条件下的 PHD-JDTC 前向-后向平滑算法，并给出了粒子滤波实现方法以及算法框架结构。

在仿真方面，我们提取未知 SNR 目标的信号幅度引入属性信息，从而避免了目标平均 SNR 这一先验信息。另外，充分考虑了已存在目标、新生目标以及衍生目标情况，实现了不同类别目标间完整的信息交互。仿真结果表明，本章算法能够对类别信息进行决策，在目标跟踪精度方面优于 PHD-JDTC 滤波器。

第七章 总结与展望

7.1 工作总结与创新点

本文主要研究了基于随机集的联合检测、跟踪和分类方法。对随机集理论进行了探讨，验证了概率假设密度滤波器在多目标跟踪领域的优势。在单传感器联合检测、跟踪和分类算法基础上，采用信息融合方法研究多传感器多平台联合检测、估计与决策算法。深入研究基于随机有限集的平滑滤波技术，探索了平滑技术优化的联合检测、估计与决策方法。

本文主要对以下内容进行了研究：

(1) 介绍了多目标贝叶斯滤波方程以及相应的一阶矩 PHD 实现方法。通过高斯混合和粒子近似方法给出了两种 PHD 实现方法，即高斯混合 PHD 和粒子滤波 PHD，仿真验证了两种算法解决多目标跟踪问题的有效性。另外，描述了多目标跟踪方法中的性能评价指标。

(2) 在多模型 PHD 原理基础上，采用模型交互的方法替换了原有 PFPHD 实现方法中的粒子模型预测步骤，得到了基于模型交互的粒子 PHD 多目标联合检测与跟踪方法。通过模型交互，提高了滤波器中的粒子数目，在相同的初始条件下，能够对多机动目标进行更有效的跟踪，跟踪误差更小，目标数目估计更准确。

(3) 研究了基于高斯混合 PHD 滤波器和粒子 PHD 滤波器的单传感器联合检测、跟踪和分类算法。采用序贯融合方法将单传感器算法推广到多传感器应用中。实现了多传感器、多目标联合检测、估计与决策。仿真结果表明该方法在目标数目和状态估计方面明显优于相应的单传感器算法。

(4) 介绍了跳变马尔科夫 PHD 滤波器。在此基础上进一步推导了跳变马尔科夫 PHD 平滑器。通过引入类别信息，重新证明 PHD-JDTC 滤波器。基于跳变马尔科夫 PHD 平滑器推导了 PHD-JDTC 平滑器。通过对不同类别目标采用不同的运动模型集，本文提出了类别相关模型集条件下的 PHD-JDTC 前向-后向平滑算法，并给出具体的粒子滤波实现方法，仿真验证了该算法的有效性。

本文的主要创新点有：

(1) 研究基于随机集的多目标联合检测、估计与决策方法从单传感器到多传感器的扩展。

(2) 基于雷达信号信噪比的属性量测提取方法。

(3) 采用平滑滤波技术提高基于随机集的联合检测、跟踪和分类算法性能。

7.2 研究展望

本文主要从多传感器信息融合和平滑滤波方面研究了基于随机有限集的联合检测、估计与决策方法。但是相关研究工作需要进一步完善：

(1) 本文所采用的目标估计与目标类别决策方法都是贝叶斯方法的。类别信息的引入和判断都是在贝叶斯框架下完成的。D-S 证据理论比贝叶斯方法更能有效处理矛盾信息，因此鲁棒性更好，可以进一步引入到随机集理论中。贝叶斯风险的联合估计与决策方法研究较少，因此也存在许多问题值得进一步研究。值得指出的是 Mahler 在专著^[6]中将贝叶斯方法和 D-S 证据理论进行了统一描述，因此这两种理论方法中的成果可以进一步综合进行考虑，相互借鉴。在机器学习和模式识别领域有许多分类器的设计方法，这些训练和分类的方法对解决联合检测、估计与决策问题具有借鉴意义。

(2) 目标类别信息的建模需要一定的工程应用背景，当传感器不同时，类别信息的提取和表现形式也不同，同一种联合检测、估计与决策方法只针对某些特定问题，因此需要结合具体的工程应用实现联合估计与决策方法。另外，检测和分类过程需要一定的先验信息，先验信息的准确程度会直接影响算法的性能，因此如何减少先验信息的影响需要更多的研究工作。

(3) 本文在将联合检测、跟踪和分类算法从单平台推广到多平台时采用的是序贯 PHD 滤波器。然而多传感器 PHD 滤波器还存在许多问题要解决，如观测区域不一致，严格形式的多传感器 PHD 实现问题^[51]，以及漏检概率偏大时滤波器性能下降问题。近年来，国际信息融合会议中不断有学者提出多传感器 PHD 滤波器的新的方法和理论，借鉴新的理论成果将进一步完善多传感器联合检测、估计与决策方法。

(4) 随着传感器分辨率的提高，同一个目标可能产生多个量测值，这种扩展目标跟踪问题以及类似的群目标跟踪问题也是最近的一个研究热点。一种解决思路是采用粒子滤波方法，另一种思路是采用扩展的 PHD 滤波器。针对扩展目标和群目标跟踪问题的联合检测、估计与决策方法都是未来需要探讨的工作。

参 考 文 献

- [1] 周宏仁,敬忠良. 机动目标跟踪[M]. 北京:国防工业出版社. 1991: 29-30.
- [2] 敬忠良. 神经网络跟踪理论及应用[M]. 北京:国防工业出版社. 1995: 10-15.
- [3] 韩崇昭,朱洪艳,段战胜. 多源信息融合[M]. 北京:清华大学出版社. 2006: 20-30.
- [4] Bar-Shalom, Y.,Li, X.-R. Estimation and tracking: principles, techniques, and software[M]. Artech House Norwood. 1993: 21-40.
- [5] Bar-Shalom, Y. Tracking and data association[M]. Academic Press Professional. 1987: 29-30.
- [6] Mahler, R. P. Statistical multisource-multitarget information fusion[M]. Artech House Boston. 2007: 22-35.
- [7] Vo, B.T.,Vo, B.N.,Cantoni, A. Analytic implementations of the cardinalized probability hypothesis density filter[J]. IEEE Transactions on Signal Processing. 2007, 55 (2): 3553-3567.
- [8] Vo, B. N.,Singh, S.,Doucet, A. Sequential Monte Carlo methods for multitarget filtering with random finite sets[J]. IEEE Transactions on Aerospace and Electronic Systems. 2005, 41 (4): 1224-1245.
- [9] Vo, B.N.,Ma, W.K. The Gaussian mixture probability hypothesis density filter[J]. IEEE Transactions on Signal Processing. 2006, 54 (11): 4091-4104.
- [10] Lin, L.,Bar-Shalom, Y.,Kirubarajan, T. Track labeling and PHD filter for multitarget tracking[J]. IEEE Transactions on Aerospace and Electronic Systems. 2006, 42 (3): 778-795.
- [11]Pollard, E.,Pannetier, B.,Rombaut, M. Hybrid algorithms for multitarget tracking using MHT and GM-CPHD[J]. IEEE Transactions on Aerospace and Electronic Systems. 2011, 47 (2): 832-847.
- [12] Li, X. R. Optimal Bayes joint decision and estimation[C]. 10th International Conference on Information Fusion. 2007: 1-8.
- [13] Yang, M. When decision meets estimation: Theory and applications[M]. ProQuest. 2007: 1-50.
- [14] Mei, W.,Shan, G.-L.,Li, X. R. Simultaneous tracking and classification: a modularized scheme[J]. IEEE Transactions on Aerospace and Electronic Systems. 2007, 43 (2): 581-599.

- [15] Challa, S.,Pulford, G. W. Joint target tracking and classification using radar and esm sensors[J]. IEEE Transactions on Aerospace and Electronic Systems. 2001, 37 (3): 1039-1055.
- [16] Leung, H.,Wu, J. Bayesian and Dempster-Shafer target identification for radar surveillance[J]. IEEE Transactions on Aerospace and Electronic Systems. 2000, 36 (2): 432-447.
- [17] Liu, X.,Leung, H.,Valin, P., etc. Multisensor joint tracking and identification using particle filter and Dempster-Shafer fusion[C]. 15th International Conference on Information Fusion. 2012: 902-909.
- [18] Liu, Y.,Li, X. R. Recursive joint decision and estimation based on generalized Bayes risk[C]. 14th International Conference on Information Fusion. 2011: 1-8.
- [19] Vercauteren, T.,Guo, D.,Wang, X. Joint multiple target tracking and classification in collaborative sensor networks[J]. Selected Areas in Communications, IEEE Journal on. 2005, 23 (4): 714-723.
- [20] Boers, Y.,Driessen, H. Hybrid state estimation: a target tracking application[J]. Automatica. 2002, 38 (12): 2153-2158.
- [21] Wei, Y.,Yaowen, F.,Jianqian, L., etc. Joint Detection, Tracking, and Classification of Multiple Targets in Clutter using the PHD Filter[J]. IEEE Transactions on Aerospace and Electronic Systems. 2012, 48 (4): 3594-3609.
- [22] Zajic, T.,Ravichandran, R. B.,Mahler, R. P., etc. Joint tracking and identification with robustness against unmodeled targets[C]. In AeroSense 2003. 2003: 279-290.
- [23] Georgescu, R.,Willett, P. Classification aided cardinalized probability hypothesis density filter[C]. In SPIE Defense, Security, and Sensing. 2012: 83920F-83920F-9.
- [24] Battistelli, G.,Chisci, L.,Morrocchi, S., etc. Robust Multisensor Multitarget Tracker with Application to Passive Multistatic Radar Tracking[J]. IEEE Transactions on Aerospace and Electronic Systems. 2012, 48 (4): 3450-3472.
- [25] 张洪建. 基于有限集统计学的多目标跟踪算法研究[博士论文].上海: 上海交通大学. 2009.
- [26] 王洋,敬忠良,胡士强,等. 基于整合概率数据关联的最优传感器序列研究[J]. 控制与决策. 2011, 26 (8): 1153~1157.
- [27] Swain, A.,Clark, D. The single-group PHD filter: an analytic solution[C]. In Information Fusion (FUSION), Proceedings of the 14th International Conference on. 2011: 1-8.
- [28] Orguner, U.,Lundquist, C.,Granstrom, K. Extended target tracking with a cardinalized probability hypothesis density filter[C]. In Information Fusion (FUSION), Proceedings of the 14th International Conference on. 2011: 1-8.

- [29] Mahler, R.P., Vo, B.T., Vo, B.N. CPHD filtering with unknown clutter rate and detection profile[J]. IEEE Transactions on Signal Processing. 2011, 59 (8): 3497-3513.
- [30] Ristic, B., Clark, D., Vo, B.-N., etc. Adaptive target birth intensity for phd and cphd filters[J]. IEEE Transactions on Aerospace and Electronic Systems. 2012, 48 (2): 1656-1668.
- [31] Nandakumaran, N., Punithakumar, K., Kirubarajan, T. Improved multi-target tracking using probability hypothesis density smoothing[C]. In SPIE, 2007: 66990M.
- [32] Tobias, M., Lanterman, A. D. Techniques for birth-particle placement in the probability hypothesis density particle filter applied to passive radar[J]. Radar, Sonar & Navigation, IET. 2008, 2 (3): 351-365.
- [33] Schuhmacher, D., Vo, B.-T., Vo, B.-N. A consistent metric for performance evaluation of multi-object filters[J]. IEEE Transactions on Signal Processing. 2008, 56 (8): 3447-3457.
- [34] Pasha, S. A., Vo, B.-N., Tuan, H. D., etc. A Gaussian mixture PHD filter for jump Markov system models[J]. IEEE Transactions on Aerospace and Electronic Systems. 2009, 45 (3): 919-936.
- [35] 杨威, 付耀文, 黎湘, 等. 基于 LGJMS-GMPHDF 的多机动目标联合检测, 跟踪与分类算法[J]. 电子与信息学报. 2012, 34 (2): 398~403.
- [36] Tobias, M., Lanterman, A. D. Probability hypothesis density-based multitarget tracking with bistatic range and Doppler observations[J]. IEE Proceedings-Radar, Sonar and Navigation. 2005, 152 (3): 195-205.
- [37] Pham, N. T., Huang, W., Ong, S. H. Multiple sensor multiple object tracking with GMPHD filter[C]. 10th International Conference on Information Fusion. 2007: 1-7.
- [38] Erdinc, O., Willett, P., Coraluppi, S. The Gaussian mixture cardinalized PHD tracker on MSTWG and SEABAR'07 datasets[C]. 11th International Conference on Information Fusion. 2008: 1-8.
- [39] Pao, L. Y., Trailovic, L. The optimal order of processing sensor information in sequential multisensor fusion algorithms[J]. IEEE Transactions on Automatic Control. 2000, 45 (8): 1532-1536.
- [40] Wang, Y., Jing, Z., Hu, S., etc. On the sensor order in sequential integrated probability data association filter[J]. Science China Information Sciences. 2012, 55 (3): 491-500.

- [41] Nagappa, S., Clark, D. E. On the ordering of the sensors in the iterated-corrector probability hypothesis density (PHD) filter[C]. In SPIE Defense, Security, and Sensing. 2011: 80500M-80500M-6.
- [42] Bar-Shalom, Y., Kirubarajan, T., Gokberk, C. Tracking with classification-aided multiframe data association[J]. IEEE Transactions on Aerospace and Electronic Systems. 2005, 41 (3): 868-878.
- [43] Punithakumar, K., Kirubarajan, T., Sinha, A. Multiple-model probability hypothesis density filter for tracking maneuvering targets[J]. IEEE Transactions on Aerospace and Electronic Systems. 2008, 44 (1): 87-98.
- [44] 杨威, 付耀文, 黎湘, 等. 基于 MMPHDF 的多机动目标联合检测, 跟踪与分类算法[J]. 中国科学: 信息科学. 2012, 42(7), 893~906.
- [45] Lerro, D., Bar-Shalom, Y. Automated tracking with target amplitude information[C]. In American Control Conference. 1990: 2875-2880.
- [46] Clark, D., Ristic, B., Vo, B.-N., etc. Bayesian multi-object filtering with amplitude feature likelihood for unknown object SNR[J]. IEEE Transactions on Signal Processing. 2010, 58 (1): 26-37.
- [47] 王晓, 韩崇昭. 用于机动目标跟踪的多模型概率假设密度滤波器[J]. 西安交通大学学报. 2011, 45 (12): 1~5.
- [48] Nadarajah, N., Kirubarajan, T., Lang, T., etc. Multitarget tracking using probability hypothesis density smoothing[J]. IEEE Transactions on Aerospace and Electronic Systems. 2011, 47 (4): 2344-2360.
- [49] Vo, B.N., Vo, B.T., Mahler, R. P. Closed-Form Solutions to Forward-Backward Smoothing[J]. IEEE Transactions on Signal Processing. 2012, 60 (1): 2-17.
- [50] Mahler, R. On multitarget jump-Markov filters[C]. 15th Conference on Information Fusion (FUSION). 2012: 149-156.
- [51] Mahler, R. Approximate multisensor CPHD and PHD filters[C]. 13th Conference on Information Fusion (FUSION). 2010: 1-8.

致 谢

时光荏苒，光阴似箭。一转眼，我的校园生活即将告一段落了。在我的硕士研究生学习阶段，我有幸遇到了很多帮助过我的老师、同学与朋友，在此向他们表示衷心的感谢。

感谢我的导师敬忠良教授的悉心指导。敬老师以渊博的知识、深厚的学术造诣和严谨的治学态度为我树立了一个学术榜样。敬老师对事物的宏观把握能力和洞察力令我折服，感谢老师一直以来对学生的信任与支持，学生今后定当加倍努力，奋力前行，不辜负老师厚望。

感谢雷明老师，雷老师为我的论文提了许多宝贵意见，雷老师优秀的学术能力是我学习的楷模。感谢虞红娅老师对我的帮助和鼓励，在我迷茫的时候虞老师给予我莫大的帮助和鼓舞。感谢航空航天学院信息与控制所所长胡士强教授，胡老师为我们搭建了优秀的科研平台，使我能接触到学科前沿的理论知识。感谢费晓燕老师和周艳平老师在生活及科研方面的亲切关怀。

感谢潘汉、金博和张灿龙师兄在论文写作与科研项目方面对我的指导，为我撰写论文打下了坚实的基础。感谢实验室王梦、徐涛和向融等同学，没有他们就无法构建起一个温暖的集体。感谢大家的陪伴和对我的帮助。

感谢父母、哥哥、嫂子、姐姐和姐夫的支持与爱护，你们一直是我继续向前的动力。感谢所有朋友和同学，你们是我幸福的源泉和坚强的后盾。

攻读硕士学位期间已发表或录用的论文

- [1] **Yanyuan Qin**, Zhongliang Jing, Ming Lei. "Multi-sensor Joint Target Detection, Tracking and Classification with Iterated PHD Filter", 16th International Conference on Information Fusion. 2013. (已发表)
- [2] **秦彦源**, 敬忠良, 雷明, 多传感器目标检测跟踪与分类算法, 计算机仿真 (已录用)
- [3] ZhongLiang Jing, Han Pan, and **YanYuan Qin**. "Current progress of information fusion in China." Chinese Science Bulletin 58.36 (2013): 4533-4540. (已发表)