

基于随机集的多目标航迹关联方法研究

作者姓名 杜璇 导师姓名、职称 宋骥平副教授

一级学科 信息与通信工程 二级学科 信号与信息处理

申请学位类别 工学硕士 提交学位论文日期 2014 年 12 月

学校代码 10701

分类号 TN95

学号 1202121125

密级 公开

西安电子科技大学

硕士学位论文

基于随机集的多目标航迹关联方法研究

作者姓名：杜璇

一级学科：信息与通信工程

二级学科：信号与信息处理

学位类别：工学硕士

指导教师姓名、职称：宋骊平副教授

提交日期：2014 年 12 月

Research on Multi-target Track Association Algorithm Based on Random Finite Sets

A thesis submitted to
XIDIAN UNIVERSITY
in partial fulfillment of the requirements
for the degree of Master
in Information and Communication Engineering

By
Du Xuan
Supervisor: Asso. Prof. Song Li-ping
December 2014

西安电子科技大学 学位论文独创性（或创新性）声明

秉承学校严谨的学风和优良的科学道德，本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，论文中不包含其他人已经发表或撰写过的研究成果；也不包含为获得西安电子科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文若有不实之处，本人承担一切法律责任。

本人签名：_____ 日 期：_____

西安电子科技大学 关于论文使用授权的说明

本人完全了解西安电子科技大学有关保留和使用学位论文的规定，即：研究生在校攻读学位期间论文工作的知识产权单位属于西安电子科技大学。学校有权保留送交论文的复印件，允许查阅、借阅论文；学校可以公布论文的全部或部分内容，允许采用影印、缩印或其它复制手段保存论文。同时本人保证，获得学位后结合学位论文研究成果撰写的文章，署名单位为西安电子科技大学。

保密的学位论文在____年解密后适用本授权书。

本人签名：_____ 导师签名：_____

日 期：_____ 日 期：_____

摘要

目标跟踪作为数据融合系统的关键技术，在现代军事及民用领域占有非常重要的地位，受到国内外学者的广泛重视和研究。近年来随机集理论在多目标跟踪中的应用得到了快速发展，它避免了传统目标跟踪的数据关联技术，为多目标跟踪带来了新的发展。但存在不能提供单独目标航迹的问题，为后续的数据融合处理带来困难。因此如何对随机集下的多目标跟踪并关联航迹是一项值得研究的课题。本文主要研究了多种基于随机集理论的多目标航迹关联方法，主要工作如下：

首先，在随机集理论的基础上，介绍了几种经典的多目标跟踪算法，概率假设密度滤波和势平衡概率假设密度滤波，以及算法的高斯混合实现和粒子实现，讨论了两种滤波器的优缺点，并分析了基于随机集的多目标跟踪评价指标，对全文的后续工作做了坚实的铺垫。

然后，针对 GM-PHD 滤波在目标交叉或靠近时状态提取不准确的问题，提出了一种合作惩罚 GM-PHD 滤波，通过重新分配目标权值并归一化提高目标状态精度，在此基础上与标记 PHD 算法相结合，提高了空间相近目标的正确关联率。由于目标数目对航迹关联有直接影响，针对 PHD 目标数目估计不够准确的问题，本文将标记 CP-PHD 的思想引入 CPHD 滤波框架中，改善了航迹的维持性能。

最后，针对粒子 PHD 目标状态提取不够准确的问题，提出了一种新的目标状态提取方法，本文中将其与预测关联算法相结合，在提高位置估计精度的同时提高了目标航迹关联正确率。针对多目标密集靠近情况下航迹易关联错误的问题，提出了一种改进的航迹关联算法。改进算法使用距离矩阵来辨别目标的相互位置关系，并针对目标密集靠近的情况直接关联其航迹预测值，从而提高目标连续航迹的正确关联率，有效解决了多个目标在同一时刻交叉或者相互靠近时易产生分辨错误的问题，具有较强的抗干扰能力和鲁棒性，仿真实验验证了算法的有效性。

关键词：多目标跟踪，随机有限集，概率假设密度滤波器，数据关联，航迹管理

论文类型：应用基础研究类

ABSTRACT

As the key technology in data fusion system, multi-target tracking has received a lot of attention and researched by domestic and overseas scholars, which played a very important role in modern military and civilian fields. The application of the random finite sets theory in the fields of multi-target tracking has been in rapid development in recent years. It avoids the data association technologies in traditional target tracking and brings new development in multi-target tracking. However it does not provide tracks of individual targets, makes it difficult to deal with the subsequent data fusion. How to associate the tracks in multi-target tracking based on random finite sets is a topic worth studying. This thesis mainly focuses on the various methods of multi-target track association based on random finite sets. Main contributions are as follows:

Firstly, several classical multi-target tracking algorithms based on random finite sets such as probability hypothesis density filter and cardinalized probability hypothesis density filter and their implementations of Gaussian mixture and particle have been introduced. The advantages and disadvantages of two kinds of filter are discussed and the evaluation standard of multi-target tracking based on random finite set is analyzed in this paper. This section mainly makes a good foundation for the following research in the rest of paper.

Secondly, for the problem of state extraction is not accurate for GM-PHD filter when multiple targets closely spaced, a collaborative penalized GM-PHD filter has been proposed, and renormalization schemes to refine the weights has been employed to improve the estimate accuracy. Then combined with labeling PHD algorithm, the normalized correct associations has been improved for close targets. Because the target number estimation has a direct influence on track association, while the estimated target number of PHD filter is not accurate, for this issue, this paper combines the labeling CP-PHD with CPHD, the track maintenance performance has been improved.

Lastly, for the problem of state extraction is not accurate for particle-PHD filter, a new state extraction method has been improved, combined with estimate-to-track algorithm,

the performances of both the target states and the normalized correct associations have been improved. An improved track association algorithm is proposed in this paper to overcome the matter of wrong association when multiple dense targets closely spaced. A distance matrix is proposed and constructed to identify the targets location information to each other, and the predictions of target trajectory are associated with the corresponding tracks directly of dense targets in close proximity. It provides correct association for close targets. This proposed algorithm has great robustness and strong anti-disturbance ability. The simulation experiments show the effectiveness of the algorithm.

Keywords: Multi-target Tracking; Random Finite Set (RFS); Probability Hypothesis Density Filter;
Data Association; Track Management

Type of Dissertation: Applied Basic Research

插图索引

图 1.1	目标跟踪原理图.....	1
图 1.2	随机集滤波+航迹管理	6
图 1.3	随机集预滤波+数据关联	6
图 2.1	多目标跟踪中的集导数与集积分.....	11
图 3.1	高斯项的更新过程.....	22
图 3.2	目标数目估计	33
图 3.3	OSPA 距离比较	33
图 3.4	目标真实运动轨迹.....	33
图 3.5	标记 PHD 法航迹估计.....	33
图 3.6	标记 CP-PHD 法航迹估计	34
图 3.7	标记 CP-CPHD 法航迹估计.....	34
图 3.8	随量测噪声变化的关联性能仿真结果.....	35
图 3.9	随检测概率变化的关联性能仿真结果.....	35
图 4.1	目标真实运动轨迹.....	41
图 4.2	两种算法 OSPA 距离对比.....	41
图 4.3	基于 K-MEANS 聚类的航迹关联	41
图 4.4	基于改进聚类的航迹关联.....	41
图 4.5	原算法流程图.....	47
图 4.6	改进算法流程图.....	48
图 4.7	场景 1 目标真实运动轨迹.....	50
图 4.8	场景 1 原算法跟踪航迹估计.....	50
图 4.9	场景 1 改进算法跟踪航迹估计.....	50
图 4.10	场景 1 原算法 X、Y 坐标航迹估计	50
图 4.11	场景 1 改进算法 X、Y 坐标航迹估计	50
图 4.12	场景 2 目标真实运动轨迹.....	51
图 4.13	场景 2 原算法跟踪航迹估计.....	52
图 4.14	场景 2 改进算法跟踪航迹估计.....	52
图 4.15	场景 2 原算法 X、Y 坐标航迹估计	52
图 4.16	场景 2 改进算法 X、Y 坐标航迹估计	52
图 4.17	随杂波强度变化的关联性能仿真结果.....	53

图 4.18 随检测概率变化的关联性能仿真结果.....	53
------------------------------	----

符号对照表

符号	符号名称
k	时间 / s
μ_s	Lebesgue 测度
$p_k(\cdot \cdot)$	多目标后验概率密度
$p_{k k-1}(\cdot \cdot)$	多目标联合先验概率密度
$v_k(\cdot \cdot)$	多目标后验概率假设密度
$v_{k k-1}(\cdot \cdot)$	多目标预测概率假设密度
$f_{k k-1}(\cdot \cdot)$	多目标状态转移概率密度
$g_k(\cdot \cdot)$	多目标联合似然函数
F_{k-1}	状态转移矩阵
H_k	观测矩阵
Q_{k-1}	过程噪声协方差
R_k	量测噪声协方差
Γ_k	新生目标随机集
$B_{k k-1}$	衍生目标随机集
K_k	杂波随机集
$\gamma_k(\cdot)$	新生目标随机集强度函数
$\beta_{k k-1}(\cdot \cdot)$	衍生目标随机集强度函数
$\kappa_k(\cdot)$	杂波随机集强度函数
$p_{S,k}$	存活概率
$p_{D,k}$	检测概率
$x_{k,i}$	单目标的状态矢量
$z_{k,i}$	单目标的观测矢量
$F(\chi)$	目标状态空间所有有限子集的集合
$F(Z)$	观测空间的所有有限子集的集合

缩略语对照表

缩略语	英文全称	中文对照
CPHD	Cardinalized Probability Hypothesis Density	势均衡概率假设密度
EM	Expectation-Maximation	期望最大算法
FISST	Finite Set Statistics	有限集统计学理论
GM	Gaussian Mixture	高斯混合
ICAR	Incorrect-to-Correct Association Ratio	错误关联比
IMM	Interacting Multiple Model	交互式多模型
JPDA	Joint Probabilistic Data Association	联合概率数据关联
MHT	Multiple Hypothesis Tracking	多假设跟踪
MSE	Mean Square Error	均方误差
MTT	Multiple Target Tracking	多目标跟踪
NCA	Normalized Correct Associations	正确关联率
NN	Nearest Neighbor	最近邻域
OSPA	Optimal Subpattern Assignment	最优子模式分配
PHD	Probability Hypothesis Density	概率假设密度
PPP	Possion Point Process	泊松点过程
RFS	Random Finite Sets	随机有限集
RMSE	Root Mean Square Error	均方根误差
SMC	Sequential Monte Carlo	序贯蒙特卡罗

目录

摘要.....	I
ABSTRACT.....	III
插图索引.....	V
符号对照表.....	VII
缩略语对照表.....	IX
目录.....	XI
第一章 绪论.....	1
1.1 研究背景及意义	1
1.2 国内外发展及现状.....	2
1.2.1 传统数据关联技术.....	4
1.2.2 基于随机集的航迹关联方法.....	5
1.3 论文主要工作及章节安排.....	7
第二章 基于随机集的多目标跟踪基础	9
2.1 引言	9
2.2 随机集理论概述	9
2.2.1 随机集定义.....	9
2.2.2 贝叶斯滤波框架.....	11
2.2.3 随机集理论的多目标模型.....	11
2.3 PHD 滤波算法	12
2.3.1 高斯混合 PHD 滤波.....	13
2.3.2 粒子 PHD 滤波.....	15
2.4 CPHD 滤波算法.....	17
2.5 随机集多目标性能评价指标.....	18
2.6 本章小结	20
第三章 基于标记的概率假设密度航迹关联算法	21
3.1 引言	21
3.2 标记 PHD 算法	21
3.2.1 标记 GM-PHD 关联法.....	21
3.2.2 标记粒子 PHD 关联法.....	23
3.3 惩罚高斯混合概率假设密度 (Penalized GM-PHD) 滤波	25

3.4 合作惩罚高斯项标记法及改进算法.....	27
3.4.1 标记 CP-GMPHD 滤波	27
3.4.2 改进算法.....	30
3.5 仿真实验及分析	32
3.6 本章小结	35
第四章 基于随机集滤波的航迹关联算法	37
4.1 引言	37
4.2 基于标记 particle-PHD 的预测关联算法	37
4.2.1 标记预测关联算法.....	37
4.2.2 改进算法.....	38
4.2.3 仿真实验及分析.....	40
4.3 基于高斯混合 PHD 的航迹关联算法.....	42
4.3.1 航迹关联算法.....	42
4.3.2 改进的航迹关联算法.....	45
4.3.3 仿真实验及分析.....	48
4.4 本章小结	54
第五章 总结与展望	55
5.1 总结.....	55
5.2 展望.....	56
参考文献.....	57
致谢.....	63
作者简介.....	65
1. 基本情况.....	65
2. 教育背景.....	65
3. 攻读硕士学位期间的研究成果	65

第一章 绪论

1.1 研究背景及意义

随着高科技在军事方面的应用发展，现代战争面临着多重挑战，包括电子干扰、低空突防、隐身目标攻击和反辐射目标攻击等，多目标跟踪^[1]作为军事作战中的关键技术，世界各国对此给予了密切的关注和重视，成为研究的重点、热点和难点。多目标跟踪目前是国际上十分活跃的热门领域之一，已经在军事、通信、导航、卫星遥感及其他民用领域中得到了广泛的应用，包括军事防卫系统、海空监视系统、空中交通管制系统、汽车 GPS 导航系统、空间运动体的目标跟踪以及计算机视觉跟踪等。目标跟踪是在第二次世界大战的前夕发展起来的，从最初的跟踪雷达站 SCR-28 发展到其它各种目标跟踪系统，如雷达、红外、声呐和激光等。目标跟踪技术性能直接关系到多传感器系统的整体性能，对战争的胜负成败有很大的影响。

为了能够准确定位目标并估计其状态，多目标跟踪主要利用各种有源和无源探测如雷达、红外及可见光等多传感器提供的多种观测数据进行持续的估计与预测更新过程，从而实时的发现目标并估计目标状态、识别目标属性、分析目标态势与威胁估计，其跟踪过程如图 1.1 所示。多目标跟踪就是对传感器获得的量测数据进行综合优化处理从而得到多个目标位置速度等状态的估计，它属于信息融合^[2]中的位置级融合，包括时间和空间的融合。由于很多无源探测设备并不发射信号，量测信息大多是角度或灰度图像等，使得多目标跟踪变得更加困难。




图 1.1 目标跟踪原理图

在实际的目标跟踪场景中，目标随时可能新生或消失，目标数目未知且随时间不断变化，同时存在杂波和虚警，因而观测站接收到的观测起源存在模糊性，也就是说观测是否来源于真实目标具有不确定性。受传感器探测性能的约束，当传感器存在漏检且存在多个目标时，跟踪问题就变得更加复杂。尤其在现代复杂

作战系统环境中,存在虚警杂波、存在状态噪声和量测噪声等干扰、存在真实目标漏检、目标存在未知的机动特性、多目标还存在航迹交叉、甚至存在对抗性干扰。为了实时准确地对目标进行定位跟踪从而获得最佳作战效果,多目标跟踪的核心和难点问题就是如何准确并有效的对多传感器的量测信息进行数据融合。由于上述因素的影响使得数据关联存在模糊性,因此解决该问题的关键是研究更为简单、有效、实用的跟踪算法。

关于多目标跟踪滤波算法及多种相关改进算法的研究和技术文献目前已有许多,这些算法在某些领域具有较好的性能,但在某些特殊场景下仍然存在目标估计精度差,目标漏跟、计算复杂度高以及实时性差等问题。基于随机集理论的多目标跟踪算法^[3]虽然避免了量测与目标的数据关联,能够很好地应用于多目标跟踪,但由于只估计出每个时刻的目标数目及状态,在相邻的目标状态之间没有给出目标的航迹关联信息,从而不能得到某一特定目标的完整航迹,因此在识别目标行为和身份、进行势态评估及威胁评估等数据融合的后续处理方面带来了极大的困难,并不能满足实际工程需要,如何克服这些问题并将算法应用于实际场景需要我们进一步研究。正是在这一背景下,本文开展了基于随机集理论的多目标跟踪及其航迹关联算法的研究,这一方向对于我国军事防御能力的提高以及国防系统的建设都具有十分重要的现实国防意义。

1.2 国内外发展及现状

多目标跟踪(Multiple Target Tracking, MTT)^[4]的基本概念是1955年由Wax最先提出的。由于雷达、导航、声呐、航空和交通管制等领域的快速发展及应用,直到1970年开始多目标跟踪理论才真正引起人们的关注。相比于单目标跟踪,多目标跟踪需要处理两个问题,一是对于目标数目的估计,二是怎样维持目标的航迹。传统的多目标跟踪如联合概率数据关联(Joint Probabilistic Data Association, JPDA)^[5]和多假设跟踪(Multiple Hypothesis Tracking, MHT)^[6]中,目标当前时刻的状态是由传感器得到的观测信息与目标航迹之间进行数据关联得到的。随机集在多目标跟踪中的应用是二十世纪九十年代末由Mahler提出的,很多国际会议期刊如SPIE 传感器融合专集、IEEE Trans. On AES .AC 都有介绍研究的最新进展情况,Goodman, Mahler, 和 Nguyen 在书^[7]中详细介绍了基于随机有限集(Random Finite Set, RFS)的多目标跟踪方法并提供了严格的数学理论基础。由于单目标跟踪中,传统的Kalman滤波器利用均值和协方差来表征目标的先验后验分布并随时间传递,为了将单目标跟踪的简单思想应用到多目标跟踪中,Mahler和Zajic^[8]提出将目标看作一个不断变化的集合映射到一个连续的函数空间,并随

时间传递函数的一阶矩,并将其一阶矩称为概率假设密度(Probability Hypothesis Density, PHD)^[9], PHD 类似于泊松点过程的强度函数,实际上它是点过程理论^[10]中的一阶矩密度。基于随机集的多目标跟踪可以避免“量测-航迹”之间的数据关联,不但能够减少由于数据关联错误可能带来的估计误差,同时能够很好地估计出观测区域内目标的数目和状态,因此引起了大批国内外学者的广泛关注和深入研究。之后 Vo 等学者也分别给出了 PHD 滤波器的两种实现方式,序贯蒙特卡罗(Sequential Monte Carlo, SMC)实现(也称粒子实现)^[11]和高斯混合(Gaussian Mixture, GM)实现^[12]。针对 PHD 滤波器并不形成目标航迹的问题, Panta^{[13][14]}, Lin^[15]和 Clark^{[16][17]}分别给出了多种不同的方法来形成 PHD 滤波器的目标航迹信息,但各有优缺点,在很多复杂环境下性能仍然受到很大的限制。不同于 Mahler 的随机集方法,2008 年 Streit 通过泊松点过程(Poisson Point Process, PPP)理论重新推导得到了多传感器的 PHD 滤波器的递推公式。势均衡概率假设密度滤波器(Cardinalized Probability Hypothesis Density, CPHD)^[18]中的多目标状态集合被建模为一个聚类点过程,放松了 PHD 滤波器对于泊松点过程的限制。CPHD 在递推计算多目标状态集合的概率假设密度的同时,平行递推估计集合势的后验概率分布。之后 Punithakumar 和 Vo 等将交互式多模型算法与 PHD 滤波器相结合,用于跟踪多个机动目标。

目前,随机集理论有效解决了多目标跟踪领域的很多问题,也在多目标跟踪中的应用体现出了很大的优势,越来越受到各国学者和研究人员的重视,很多学者已将基于随机集理论的多目标跟踪算法应用在很多实际问题中,包括定位与同步地图绘制(simultaneous localization and mapping, SLAM)^[19]、视频图像中的多目标跟踪^{[20][21]}、光学图像特征点跟踪^[22]、收发分置式雷达系统的多目标检测与跟踪^[23]、地面动目标检测和跟踪系统^[24]、前向扫描声呐图像跟踪^{[25][26]}及 3D 声呐图像跟踪^[27]、模糊态势评估系统“IFD03”中的群目标跟踪^[28]、高分辨雷达系统的空中目标识别与跟踪^[29]、地面运动目标指示(ground moving target indicator, GMTI)^[30]等。随着 PHD 滤波器在实际问题中的广泛应用,如何形成多目标航迹等相关工程应用问题还需进一步研究。

基于随机集的多目标跟踪研究领域,虽然以 Mahler、Goodman、Vo 等人为代表的国外学者已经取得不少研究成果,但该领域仍然需要不断深入和持续的研究,是一个不断发展的开放的并且处于国际研究前沿的领域,国内对信息融合领域及目标跟踪技术的研究尚处于起步阶段,上世纪 80 年代起多目标跟踪技术才逐渐开始被重视,之后国内许多高校和相关研究所才开始从事这一技术的理论研究与应用,涉及到传感器信息融合、目标检测与识别、导航制导、目标融合跟踪系统等

领域，近几年来也产生了大量理论成果。在多目标航迹关联方面，王国宏教授和何友教授等人在其专著中已经对传统多目标航迹关联所涉及的算法进行了系统研究，但是总体上我国在基于随机集理论的多目标跟踪技术方面的研究和应用与国外先进水平相比，起点低并且起步晚，仍然存在着很大的差距。因此需要在研究过程中加大投入，重视理论的分析研究与算法设计，以及算法在工程实际中的应用研究工作，不断跟踪国际技术发展前沿，努力赶超国外的先进技术。

1.2.1 传统数据关联技术

传统基于数据关联的多目标跟踪方法大致有三个阶段，处理量测数据、建立目标运动模型和观测模型，滤波预测和数据关联。多目标跟踪是将检测的实测数据进行滤波跟踪后得到目标的航迹，主要分为跟踪门限判定、跟踪起始、跟踪终结及跟踪维持等。实际环境中量测的不确定性使得跟踪问题变得非常复杂，由于存在杂波虚警等干扰，统计意义上最优的方法是每次得到新量测后，联合之前所有量测的基础上重新形成航迹，然而这种方法过于复杂，因此更多的是利用量测与航迹关联的方法，也就是在获得若干量测后起始航迹，将航迹起始和航迹维持分开进行，航迹维持就是在获得新量测后与已有的航迹直接关联。

传统的目标跟踪方法主要采用数据关联技术，其中数据关联主要是“量测-航迹”的关联，实质是利用观测数据的某些特性，从相关门限内的候选回波中得到等效回波以此对状态进行更新。数据关联根据一定的关联规则来辨别观测数据来自真实目标或者是虚假杂波，最终确定量测与航迹的配对过程。下面介绍几种比较经典的数据关联算法：

最近邻域法(Nearest Neighbor, NN)主要是用观测集中距离目标预测位置最近的观测作为关联值，不管观测值是否被其它航迹使用，只用最接近航迹的观测值进行更新。优点是计算简单，但是只有在目标分布分散，量测准确且在跟踪门限内几乎没有漏检的情况下性能较好，当目标密集靠近时，与目标预测位置距离最靠近的量测并不一定是该目标真实的量测，因此算法的抗干扰性较差，一般情况下，一个错误的更新常导致航迹的误跟或失跟，连续两个错误的更新会导致航迹丢失。

概率数据关联(Probabilistic Data Association, PDA)是一种解决杂波中单目标跟踪问题的有效方法，主要思想是由于各量测属于已有航迹的概率不同，在对目标进行状态估计时通过计算相关门限内所有候选量测的概率，并将所有量测概率加权形成一个综合量测作为等效量测进行目标状态估计与航迹维持。联合概率数据关联(JPDA)是概率数据关联的推广，它可以处理杂波环境下多目标跟踪问题，是一种面向目标的关联方法，在计算关联概率时需要解决多目标与多量测的分配问

题。根据落入跟踪门限内的量测信息计算量测属于目标的联合概率。航迹的更新是通过它的跟踪门限内所有观测值的加权和得到，意味着同一个观测值可能对几个航迹的更新有贡献，因此空间相距很近的目标也会存在航迹合并问题，跟踪效果较差。同时在跟踪目标数目较多的情况下，JPDA 算法的计算复杂度大大增加，是一个 NP-Hard 难题，可能会出现“组合爆炸”问题。若密集目标交叉运动或多目标相距较近时，则会导致航迹“聚集”，同时可能引起目标漏跟、误跟及航迹交叉合并等问题；

多假设跟踪(MHT)的算法思想是在每次产生的多个候选假设后，利用后续的量测数据对这些假设进行评估，计算某量测属于已建立目标或者新生目标的概率，并通过设置门限等方法限制假设数，将多目标跟踪简化成单目标跟踪问题。由于 MHT 利用一串数据估计概率并得到关联信息，因此具有航迹起始的能力，并且适用于低检测概率和杂波环境。而 MHT 存在大量的“迭代”，导致计算复杂度呈指数级增长，产生组合爆炸问题，同时需要占用大量存储空间，并不适用于工程实际。

多维分配算法(N-D Assignment)是基于数学规划方法将多目标跟踪中多帧扫描间的数据关联问题描述为一个多维分配问题，其实质是一定约束条件下的最优化问题，它以全局意义下的最小距离准则选取正确关联组合，给定 N 帧量测数据后，在每个量测被用一次且必须用一次的约束条件下得到极小化的目标函数估计目标的状态。它既可以用于航迹起始也可以用于航迹维持，但当 N 大于等于 3 时，N 维分配问题就变为 NP-hard 难题，因此工程上实时实现多维分配是很困难的，要受到系统计算能力和计算时间的限制。

数据关联的目的就是确定量测数据集内每个数据的来源，在杂波环境、密集目标以及存在目标漏检的情况下，数据关联问题也变得比较复杂。传统的多目标跟踪算法在相对理想的目标场景中效果较好，但在现实的目标场景中理想条件难以达到，尤其在密集杂波和存在漏检等复杂多目标场景中，传统目标跟踪算法不但计算复杂度高、适应性低而且估计精度不高，因此算法的工程实用性不强且可行性较差，目标跟踪效果并不理想。当目标密集、间距较近或者交叉运动时还会产生航迹聚集、目标漏跟、误跟、航迹合并等现象，此时数据关联问题会带来更大的困难，关联问题本身比跟踪问题更加难以处理，已经成为多目标跟踪的一个瓶颈，因此研究性能更优的多目标跟踪滤波算法是十分必要的。

1.2.2 基于随机集的航迹关联方法

近年来，有限集统计学理论(Finite Set Statistics, FISST)受到了目标跟踪领域学者的广泛关注，它可以避免观测与目标之间的数据关联计算，FISST 将所有目标的

集合建模为目标状态 RFS，将所有的观测集合建模为量测 RFS，随机有限集是随机集的一个特例，因此即可实现最优多目标贝叶斯滤波，而使用随机有限集方法处理多目标跟踪问题时存在集合积分运算，仅为理论上可解，因此，Mahler 提出的基于 FISST 的多目标跟踪方法，避免了复杂的数据关联，计算复杂度大为降低，算法简单且易于实现，能够估计出多目标的数目和位置速度等状态信息，能够适用于数量较多的目标跟踪问题。基于随机集的多目标跟踪算法估计出的是不同时刻多个孤立目标的状态，但没有区分出连续时刻的不同目标航迹信息。为了对所有目标的航迹进行关联估计从而更好地反映和管理目标的运动轨迹，可结合数据关联等技术进行航迹维持，近年来基于随机集的多目标航迹关联算法的研究成果已经很多，目前主要有以下方法：

1) Panta 等人针对 PHD 滤波器没有提供目标航迹的问题提出两种解决方案^{[13][14]}。一种方法是利用 PHD 估计所得的目标状态直接视为“量测 RFS”，然后将目标状态估计作为新的量测值和已产生的航迹进行“估计-航迹”关联，如图 1.2 所示；




图 1.2 随机集滤波+航迹管理

另外一种方法是将 PHD 作为预滤波器，先滤除观测集中的杂波和虚警，然后采用 MHT 进行航迹关联，从而得到目标航迹，如图 1.3 所示。




图 1.3 随机集预滤波+数据关联

2) Panta 等人^[31]针对 GM-PHD 没有提供目标标记因而无法产生单独目标航迹的问题提出了标记高斯项法，通过对不同的高斯项分配标记，从而在具有航迹标签的目标状态之间进行航迹关联。

3) Pollard 等人^[32]提出了一种混合滤波算法，将 GM-CPHD 与交互式多模型 (Interacting Multiple Model)-多假设跟踪 (IMM-MHT) 相结合，可以关联得到目标航迹信息。

4) Clark 提出在 SMC-PHD 的基础上为各粒子状态向量中加入目标标签，提出

两种解决方法^{[16][17]}。第一种方法是通过对粒子加标签,根据位置信息将粒子分类,将一个类中主要标记的粒子与上一时刻相同标记的类相关联,实现目标航迹估计。第二种方法是在粒子 PHD 的滤波结果上将不同时刻的目标状态根据位置速度信息进行关联,并保持每个目标标识的连续性,从而得到目标航迹。

5) Lin 等人^[15]提出一种基于分辨单元的 PHD 滤波器。主要思想是在 PHD 滤波的目标提取过程中,将分辨单元内的粒子权重进行加权求和从而得到目标的权值。通过对提取出的峰值加上标签(Labelling)用来区分不同目标的航迹,利用约束最优化算法进行二维分配,实现多目标关联跟踪。

6) Panta 等人^[33]提出对 GM-PHD 的所有高斯项采用树结构模式进行管理,从而实现目标航迹管理,包括航迹起始、航迹合并、航迹维持及航迹终结。

7) Aoki 等人^{[34][35][36]}针对目标与标记的维持性常在相互靠近之后就会出现混合标记的情况,提出了 RBM-M-SMC(Rao-Blackwellized marginal Multi-target Sequential Monte Carlo)滤波器,主要思想是对随机集进行标记,通过计算每个粒子可能分配的标记情况计算标记概率并归一化,再将粒子权值归一化同时对每个粒子计算均值最优子模式分配(Mean Optimal Subpattern Assignment, MOSPA)函数,通过最小均值最优子模式分配-标记概率最大化的方法提取目标状态,根据提取出的最大的标记概率进行分配标记,实现目标的航迹关联。缺点是计算量太大,只适用于少量目标的情况,很难直接应用于工程实际。

以上方法在多个领域得到了应用,但是现有的航迹生成方法各有优缺点,很容易产生虚假航迹、一个目标产生多条航迹、航迹合并、误跟、漏跟、失跟等问题。目标交叉的情况下航迹跟踪效果并不好,影响到监测区域目标综合态势的分析和评估,因此基于随机集的多目标航迹关联方法的研究还需要进一步研究。

1.3 论文主要工作及章节安排

论文通过对基于随机集的多目标跟踪及航迹关联问题的研究,提出了一系列解决实际问题的算法,主要有以下几个方面:

(1) 针对基于随机集滤波的多目标跟踪不提供航迹的问题,提出了标记法、估计与航迹关联等多种方法,在得到目标数目及位置的基础上能够区分出不同目标的航迹。

(2) 针对高斯项标记法中当目标相距较近的情况下标记易产生错误的问题提出了改进,并将改进的惩罚权值重新归一化的思想应用到 CPHD 中,提高了航迹的正确关联率。

(3) 在基于随机集多目标的基础上进行滤波估计到航迹的关联,针对多目标交

叉或者相距较近时易产生错误关联的问题提出了一种改进算法，改善了航迹的关联率。多次仿真实验验证了本文算法的有效性。论文的主要工作安排如下：

第一章 总结概述了论文研究的背景及意义，介绍了多目标跟踪的发展现状，分析了传统的多目标跟踪方法，简要概述了几种传统数据关联方法，基于随机集理论的多目标航迹关联方法以及国内外的研究现状。

第二章 简要介绍了基于随机集的多目标跟踪方法，在随机集理论及贝叶斯框架下，给出了概率假设密度滤波器的两种实现方法，高斯混合 PHD 与粒子 PHD 算法，详细给出了两种方法的具体实现，最后给出了基于势均衡的概率假设密度滤波器，改进了 PHD 的对目标数目估计不准确的问题，同时介绍了评价随机集多目标跟踪的性能标准。

第三章 对基于随机集的标记高斯项 PHD 法和标记粒子 PHD 法做了简单介绍，详细分析了多目标相距较近时产生的提取目标状态不够准确的问题，并针对这一问题采用合作惩罚高斯项并重新归一化权值的方法，同时与标记高斯项 PHD 法相结合，从而提高目标状态估计精度，最后本文将这一改进思想与标记高斯项 CPHD 法相结合，通过仿真实验对比了三种算法的性能，验证了改进算法的航迹关联性能。

第四章 基于随机集滤波的基础上，介绍了几种估计与航迹关联的方法，针对粒子 PHD 提取的目标状态不够准确的问题，提出将一种新的聚类方法与关联算法结合，改善了航迹关联性能。针对多目标密集靠近时刻已存在的关联方法均容易产生错误关联的问题提出了改进算法，通过距离矩阵分辨目标的相互位置关系来分情况进行处理，很大程度上避免了原来算法的弊端，有效提高了目标航迹的分辨正确率，不同环境下的仿真实验均验证了改进算法的有效性。

第五章 对论文的主要工作做了总结，并指出今后需要进一步研究和完善的工作。

第二章 基于随机集的多目标跟踪基础

2.1 引言

在复杂的多目标跟踪场景中不但存在目标漏检、虚警杂波及量测噪声等干扰，并且伴随目标的新生、衍生和消亡，目标和量测的数目都是未知且变化的，多目标跟踪需要联合估计目标数目及状态。传统的多目标跟踪采用数据关联方法，利用多个滤波器对目标分别进行跟踪以实现单个目标与其量测之间的关联，随着目标数目的增多其算法计算复杂度也将呈指数形式增长。近年来，有限集统计学理论（FISST）受到了目标跟踪领域学者的广泛关注，它可以避免目标和量测之间的数据关联，因此基于随机集理论的多目标跟踪算法大大降低了计算量，着力解决数目未知且变化的多目标状态估计问题，不但估计精度高而且易于实现，适用于密集多目标情况，能够同时估计出多目标数目及目标状态。FISST 将所有目标状态建模为状态随机有限集，把所有的观测值集合建模为量测随机有限集，可实现最优多目标贝叶斯滤波。而基于随机集理论的多目标跟踪方法存在集合积分运算，仅为理论上可解。其中 PHD 滤波器递推的是多目标联合分布的一阶矩(即概率假设密度)来近似多目标贝叶斯后验概率密度，可将集合积分运算转化为单个变量的积分运算，现在刚刚成为多传感器信息融合的热点。序贯蒙特卡罗概率假设密度滤波器（SMC-PHD）和高斯混合概率假设密度滤波器（GM-PHD）分别提供了 PHD 滤波器非线性非高斯条件下和线性高斯条件下的闭合解。随机集理论为多目标跟踪提供了系统且严格的数学理论基础，其在目标跟踪中的应用能解决复杂环境中的未知数目且变化的多目标跟踪问题，具有理想的近似结果和严格的贝叶斯意义，对多目标跟踪领域的研究具有十分重要的理论意义和实用价值。

2.2 随机集理论概述

2.2.1 随机集定义

有限集随机统计理论是从随机变量到随机有限集理论的一种推广，随机集指的是取值为集合的随机元，即元素及其个数均是随机变量的集合，它是一种集合映射，其处理的是随机集值函数。集合中元素个数有限的随机集称为随机有限集，否则为随机无限集，一般我们处理的均为随机有限集。随机集的定义如下：

假设存在一概率空间 $(\Omega, \mathcal{A}, \Pr)$ ， R^n 为欧式空间， E 是 R^n 的有界闭子集， $B(E)$ 是 E 的所有有限子集的集合，则称可测映射 $\Xi: \Omega \rightarrow B(E)$ 为一随机集。

对于随机集 Ξ ，则 Ξ 的概率律用信任函数 β_Ξ 表示：

$$\beta_E(S) = \Pr(\{\omega: \Xi(\omega) \subseteq S\}), \forall S \subseteq E \quad (2-1)$$

在空间区域 $S \subseteq X$ 上函数 $f = \frac{\delta F}{\delta(\cdot)}(T)$ 的集积分定义为:

$$\int_S f(X) \delta X = \sum_{i=0}^{\infty} \frac{1}{i!} \int_{S^i} f(\{\mathbf{x}_1, \dots, \mathbf{x}_i\}) d\mathbf{x}_1 \cdots d\mathbf{x}_i \quad (2-2)$$

集导数定义为: 若 $F: B(E) \rightarrow [0, +\infty)$ 是任意集类函数, 其中 E 是函数的任意闭合子集。则 F 在点 $\mathbf{x} \in E$ 处的集导数为:

$$\frac{\delta F}{\delta \mathbf{x}}(T) = \lim_{i \rightarrow \infty} \frac{F(T \cup \Delta_{\mathbf{x}}^i) - F(T)}{\lambda(\Delta_{\mathbf{x}}^i)} \quad (2-3)$$

其中, $\mathbf{x} \in \Delta_{\mathbf{x}}^i \in B(E)$, $\lambda(\Delta_{\mathbf{x}}^i)$ 是 $\Delta_{\mathbf{x}}^i$ 的 Lebesgue 测度。

可以推广得到, 集类函数 $F: B(E) \rightarrow [0, +\infty)$ 在随机集 $X = \{\mathbf{x}_1, \dots, \mathbf{x}_M\}$ 处的集导数为:

$$\frac{\delta F}{\delta X}(T) = \frac{\delta^M F}{\delta \mathbf{x}_1 \cdots \delta \mathbf{x}_M}(T) \quad (2-4)$$

上式为 M 重集导数, 且与求导次序无关。

集积分和集导数可以通过下式得到, 两者是互逆的:

$$f(X) = \frac{\delta F}{\delta X}(\emptyset) \Leftrightarrow \int_S f(X) \delta X \quad (2-5)$$

上式也是 RFS 理论的核心。

在多目标跟踪问题中, 目标状态模型与观测模型均可看作随机集, 因此集导数和集积分在多目标跟踪的应用中非常重要, 如图 2.1 所示。RFS 理论已经在许多领域中得到应用, 其多目标跟踪领域的应用将目标检测、分类和跟踪融为一体, 已成为解决变化数目的多目标跟踪问题的有力工具。




图 2.1 多目标跟踪中的集导数与集积分

2.2.2 贝叶斯滤波框架

多目标跟踪问题的本质是滤波得到目标状态的估计，这是在给定观测值的条件下进行的，贝叶斯滤波就是在目标状态先验已知的条件下，联合当前观测的似然函数构造贝叶斯模型，从而求解目标的后验概率密度。根据贝叶斯理论，基于随机集的贝叶斯估计为：

$$p_{k|k-1}(X_k | Z_{1:k-1}) = \int f_{k|k-1}(X_k | X_{k-1}) p_{k-1}(X_{k-1} | Z_{1:k-1}) \mu_S(dX_{k-1}) \quad (2-6)$$

$$p_k(X_k | Z_{1:k}) = \frac{g_k(Z_k | X_k) p_{k|k-1}(X_k | Z_{1:k-1})}{\int g_k(Z_k | X_k) p_{k|k-1}(X_k | Z_{1:k-1}) \mu_S(dX_k)} \quad (2-7)$$

上面两个式子构成了理论上最优递推贝叶斯估计，其递推的是多目标后验概率密度，但是由于存在多重积分而难以得到解析解，因此直接使用贝叶斯滤波进行多目标跟踪难以实现。

2.2.3 随机集理论的多目标模型

由于在复杂的目标场景下，观测区域中随时会有目标新生和消失，导致目标与量测的数目随时间不断变化且未知。 k 时刻目标随机集 X_k 和量测随机集 Z_k 分别表示为：

$$X_k = \{\mathbf{x}_{k,1}, \dots, \mathbf{x}_{k,N_k}\} \in F(\chi) \quad (2-8)$$

$$Z_k = \{\mathbf{z}_{k,1}, \dots, \mathbf{z}_{k,M_k}\} \in F(Z) \quad (2-9)$$

其中， N_k 表示目标数目， M_k 表示量测数目。 $F(\chi)$ 为目标状态空间所有有限子集的集合， $F(Z)$ 为观测空间的所有有限子集的集合。考虑到有杂波虚警漏检的存在，观测集 Z_k 中可能包含虚假回波，也可能存在漏检。

假设 $k-1$ 时刻的多目标状态随机集为 X_{k-1} ，那么 k 时刻的多目标状态随机集可表示为：

$$X_k = \left(\bigcup_{\mathbf{x} \in X_{k-1}} S_{k/k-1}(\mathbf{x}) \right) \bigcup \left(\bigcup_{\mathbf{x} \in X_{k-1}} B_{k/k-1}(\mathbf{x}) \right) \bigcup \Gamma_k \quad (2-10)$$

上式主要由三部分组成，分别为存活目标随机集 $S_{k/k-1}(\cdot)$ 、衍生的目标随机集 $B_{k/k-1}(\cdot)$ 以及新生目标随机集 Γ_k 。

由于目标观测模型需要考虑到杂波和虚警的存在，因此多目标观测随机集分为两部分，其表示形式为：

$$Y_k = \kappa_k \bigcup \left(\bigcup_{\mathbf{x} \in X_k} \Theta_k(\mathbf{x}) \right) \quad (2-11)$$

其中 κ_k 表示虚警和杂波的观测集， $\Theta_k(\mathbf{x})$ 表示源自真实目标的观测集，根据上述描述，多目标贝叶斯公式分为下面预测和更新两个步骤：

$$p_{k/k-1}(X_k | Y_{1:k-1}) = \int f_{k/k-1}(X_k | \boldsymbol{\varsigma}) p_{k-1}(\boldsymbol{\varsigma} | Y_{1:k-1}) \mu_s(d\boldsymbol{\varsigma}) \quad (2-12)$$

$$p_k(X_k | Y_{1:k}) = \frac{g_k(Y_k | X_k) p_{k/k-1}(X_k | Y_{1:k-1})}{\int g_k(Y_k | \boldsymbol{\varsigma}) p_{k/k-1}(\boldsymbol{\varsigma} | Y_{1:k-1}) \mu_s(d\boldsymbol{\varsigma})} \quad (2-13)$$

假设 $g(\mathbf{y} | \mathbf{x})$ 为单目标似然函数，检测概率、虚警概率为常量，传感器的噪声分布已知，则多目标联合似然函数如下：

$$\begin{aligned} & g(\{\mathbf{y}_1, \dots, \mathbf{y}_{M_k}\} | \{\mathbf{x}_1, \dots, \mathbf{x}_{N_k}\}) \\ &= p_D^{M_k} (1-p_D)^{N_k-M_k} \times \sum_{1 \leq i_1 \neq \dots \neq i_k \leq N_k} g(\mathbf{y}_1 | \mathbf{x}_{i_1}) \cdots g(\mathbf{y}_{N_k} | \mathbf{x}_{i_k}) \end{aligned} \quad (2-14)$$

可以看出，随着目标数目增加多目标联合似然函数的计算量非常大，实际可行性受到很大的限制，贝叶斯滤波只能适用于理想情况下少量目标的跟踪。要对工程实际中的数目较多的目标进行跟踪，需要寻求基于贝叶斯滤波的次优算法。

2.3 PHD 滤波算法

PHD 滤波器建立在贝叶斯框架的基础上，避免了复杂的数据关联问题，具有理想的贝叶斯意义和近似效果。PHD 作为一种贝叶斯滤波的次优解，不但计算量大大减小，同时在贝叶斯框架下解决了多目标跟踪问题，因此得到了广泛的重视及应用。PHD 滤波器并不计算多目标的后验概率密度，递推的是目标的后验强度即概率假设密度，它是多目标后验概率密度的一阶矩。PHD 滤波是基于以下假设的：

假设 1. 每个目标运动与产生量测相互独立；假设 2. 杂波服从 Poisson 分布，且与产生的量测相互独立；假设 3. 预测的多目标随机集服从 Poisson 分布，若不存在目标衍生，后验多目标随机集和新生目标随机集均服从 Poisson 分布；

假设 v_k 表示多目标后验强度密度， $v_{k|k-1}$ 表示多目标预测强度密度，那么后验 PHD 随时间递推公式为：

$$v_{k|k-1}(\mathbf{x}) = \int p_{S,k}(\boldsymbol{\varsigma}) f_{k|k-1}(\mathbf{x}|\boldsymbol{\varsigma}) v_{k-1}(\boldsymbol{\varsigma}) \mu_s(d\boldsymbol{\varsigma}) + \int \beta_{k|k-1}(\mathbf{x}|\boldsymbol{\varsigma}) v_{k-1}(\boldsymbol{\varsigma}) d\boldsymbol{\varsigma} + \gamma_k(\mathbf{x}) \quad (2-15)$$

$$v_k(\mathbf{x}) = (1 - p_{D,k}(\mathbf{x})) v_{k|k-1}(\mathbf{x}) + \sum_{\mathbf{z} \in Z_k} \frac{p_{D,k}(\mathbf{x}) g_k(\mathbf{z}|\mathbf{x}) v_{k|k-1}(\mathbf{x})}{\kappa_k(\mathbf{z}) + \int p_{D,k}(\boldsymbol{\varsigma}) g_k(\mathbf{z}|\boldsymbol{\varsigma}) v_{k|k-1}(\boldsymbol{\varsigma}) d\boldsymbol{\varsigma}} \quad (2-16)$$

从上面两个式子可以看出 PHD 滤波避免了传统的数据关联问题，但是同样不存在解析解，并且存在数值积分的“维数灾难”问题，下面分别给出 PHD 滤波的高斯混合实现（GM-PHD）和粒子实现（SMC-PHD）。

2.3.1 高斯混合 PHD 滤波

GM-PHD 利用多个高斯分量的加权和近似目标强度函数并随时间传递来实现对数目变化且未知的多目标跟踪。它是 PHD 滤波器在线性高斯条件下的闭合解，因此需要满足以下假设：

假设 1：目标状态模型和观测模型均服从线性高斯模型，即

$$f_{k|k-1}(\mathbf{x}|\boldsymbol{\varsigma}) = N(\mathbf{x}; \mathbf{F}_{k-1}\boldsymbol{\varsigma}, \mathbf{Q}_{k-1}) \quad (2-17)$$

$$g_k(\mathbf{z}|\mathbf{x}) = N(\mathbf{z}; \mathbf{H}_k\mathbf{x}, \mathbf{R}_k) \quad (2-18)$$

假设 2：目标的存活概率和检测概率是状态独立的，即：

$$p_{S,k}(\mathbf{x}) = p_{S,k} \quad (2-19)$$

$$p_{D,k}(\mathbf{x}) = p_{D,k} \quad (2-20)$$

假设 3：新生目标随机集和衍生目标随机集的强度函数也可以表示为高斯混合的形式：

$$\gamma_k(\mathbf{x}) = \sum_{i=1}^{J_{\gamma,k}} w_{\gamma,k}^i N(\mathbf{x}; \mathbf{m}_{\gamma,k}^i, \mathbf{P}_{\gamma,k}^i) \quad (2-21)$$

$$\beta_{k|k-1}(\mathbf{x}|\boldsymbol{\varsigma}) = \sum_{j=1}^{J_{\beta,k}} w_{\beta,k}^j N(\mathbf{x}; \mathbf{F}_{\beta,k|k-1}^j \boldsymbol{\varsigma} + d_{\beta,k-1}^j, \mathbf{Q}_{\beta,k-1}^j) \quad (2-22)$$

假设上述命题成立，则 GM-PHD 滤波算法的实现步骤如下：

步骤 1: 初始化

假设在 $k=0$ 初始时刻, 强度函数 v_0 表示为 J_0 个高斯项的混合形式,

$$v_0(\mathbf{x}) = \sum_{i=1}^{J_0} w_0^i N(\mathbf{x}; \mathbf{m}_0^i, \mathbf{P}_0^i) \quad (2-23)$$

步骤 2: 预测

若 $k-1$ 时刻目标随机集后验强度 v_{k-1} 是高斯混合的形式, 即

$$v_{k-1}(\mathbf{x}) = \sum_{i=1}^{J_{k-1}} w_{k-1}^i N(\mathbf{x}; \mathbf{m}_{k-1}^i, \mathbf{P}_{k-1}^i) \quad (2-24)$$

那么 k 时刻预测 PHD 也是高斯混合的形式, 表示为

$$v_{k|k-1}(\mathbf{x}) = v_{S,k|k-1}(\mathbf{x}) + v_{\beta,k|k-1}(\mathbf{x}) + \gamma_k(\mathbf{x}) \quad (2-25)$$

其中, $\gamma_k(\mathbf{x})$ 上述公式(2-21)已经给出,

步骤 3: 更新

若预测的强度函数 $v_{k|k-1}$ 可以表示成高斯混合的形式, 那么 k 时刻的后验强度函数 v_k 也是一个高斯混合的形式, 表示为,

$$v_k(\mathbf{x}) = (1 - p_{D,k}) v_{k|k-1}(\mathbf{x}) + \sum_{\mathbf{z} \in \mathbf{Z}_k} v_{D,k}(\mathbf{x}; \mathbf{z}) \quad (2-26)$$

其中,

$$v_{D,k}(\mathbf{x}) = \sum_{j=1}^{J_{k|k-1}} w_k^j(\mathbf{z}) N(\mathbf{x}; \mathbf{m}_{k|k}^j, \mathbf{P}_{k|k}^j) \quad (2-27)$$

$$w_k^j(\mathbf{z}) = \frac{p_{D,k} w_{k|k-1}^j q_k^j(\mathbf{z})}{\kappa_k(\mathbf{z}) + p_{D,k} \sum_{l=1}^{J_{k|k-1}} w_{k|k-1}^l q_k^l(\mathbf{z})} \quad (2-28)$$

$$q_k^j(\mathbf{z}) = N(\mathbf{z}; \mathbf{H}_k \mathbf{m}_{k|k-1}^j, \mathbf{R}_k + \mathbf{H}_k \mathbf{P}_{k|k-1}^j (\mathbf{H}_k)^T) \quad (2-29)$$

$$\mathbf{m}_{k|k}^j(\mathbf{z}) = \mathbf{m}_{k|k-1}^j + \mathbf{K}_k^j (\mathbf{z} - \mathbf{H}_k \mathbf{m}_{k|k-1}^j) \quad (2-30)$$

$$\mathbf{P}_{k|k}^j = [\mathbf{I} - \mathbf{K}_k^j \mathbf{H}_k] \mathbf{P}_{k|k-1}^j \quad (2-31)$$

$$\mathbf{K}_k^j = \mathbf{P}_{k|k-1}^j (\mathbf{H}_k)^T (\mathbf{H}_k \mathbf{P}_{k|k-1}^j (\mathbf{H}_k)^T + \mathbf{R}_k)^{-1} \quad (2-32)$$

步骤 4: 修剪合并

更新后的高斯项数目 J_k 大量增长，将权值很小的高斯项直接删除，只保留权值较大的高斯分量，并将空间一定门限内的不同的高斯项进行合并，达到减少高斯分量的目的。

步骤 5：目标状态提取

将权值大于某一阈值 w_{Th} 的高斯项均值作为估计的目标状态输出：

$$\hat{X}_k = \{\mathbf{m}_k^i : w_k^i > w_{Th}, i = 1, \dots, J_k\} \quad (2-33)$$

2.3.2 粒子 PHD 滤波

实际生活中，经常会遇到很多非线性非高斯问题，上一小节介绍的 GM-PHD 滤波器虽然简单易行，但是受到线性高斯模型的限制，而粒子 PHD^[38]（也叫 SMC-PHD）不受模型线性和噪声高斯的限制，可以适用非线性非高斯系统，应用范围更广。它的基本思想是利用随机抽取的一组带有权值的粒子近似概率假设密度分布，从而得到粒子 PHD 的闭合解，其缺点是计算复杂度较高，需要重采样及聚类等操作，目标状态提取精度不高。粒子 PHD 的实现过程如下：

步骤 1：初始化

初始时刻，从先验概率分布 $v_{0|0}$ 中抽取 N_0 个粒子，假设粒子在观测空间是均匀分布的，每个目标用 N 个粒子表示，且粒子数与目标数成正比，每个粒子权值为：

$$w_0^i = \frac{1}{N}, i = 1, \dots, N \quad (2-34)$$

$$v_{0|0} = \sum_{i=1}^{N_0} w_0^i \delta(\mathbf{x} - \mathbf{x}_0^i) \quad (2-35)$$

步骤 2：预测

在 $k \geq 1$ 时刻，每个时刻存活目标的粒子从建议密度函数 $q_k(\cdot | \mathbf{x}_{k-1}^i, Z_k)$ 中采样，假设新生目标的粒子数目为 M 个，新生目标的粒子从另一建议密度函数 $p_k(\cdot | Z_k)$ 中采样，即

$$\tilde{\mathbf{x}}_k^i \sim \begin{cases} q_k(\cdot | \mathbf{x}_{k-1}^i, Z_k), i = 1, \dots, N_{k-1} \\ p_k(\cdot | Z_k), i = N_{k-1} + 1, \dots, N_{k-1} + M \end{cases} \quad (2-36)$$

相应预测粒子及新生粒子权值分别为：

$$\tilde{w}_{k|k-1}^i = \begin{cases} \frac{\phi_{k|k-1}(\tilde{\mathbf{x}}_k^i, \mathbf{x}_{k-1}^i)}{q_k(\tilde{\mathbf{x}}_k^i | \mathbf{x}_{k-1}^i, Z_k)} w_{k-1}^i, i = 1, \dots, N_{k-1} \\ \frac{1}{M} \frac{\gamma_k(\tilde{\mathbf{x}}_k^i)}{p_k(\tilde{\mathbf{x}}_k^i | Z_k)}, i = N_{k-1} + 1, \dots, N_{k-1} + M \end{cases} \quad (2-37)$$

其中

$$\phi_{k|k-1}(\tilde{\mathbf{x}}_k^i, \mathbf{x}_{k-1}^i) = \beta_{k|k-1}(\tilde{\mathbf{x}}_k^i, \mathbf{x}_{k-1}^i) + p_{S,k}(\mathbf{x}_{k-1}^i) f_{k|k-1}(\tilde{\mathbf{x}}_k^i, \mathbf{x}_{k-1}^i) \quad (2-38)$$

粒子总数为:

$$R_k = N_{k-1} + M \quad (2-39)$$

步骤 3: 更新

由传感器获得新的量测值后更新粒子权值如下:

$$\tilde{w}_k^i = \left[v(\tilde{\mathbf{x}}_k^i) + \sum_{\mathbf{z} \in Z_k} \frac{\psi_{k,z}(\tilde{\mathbf{x}}_k^i)}{\kappa_k(\mathbf{z}) + C_k(\mathbf{z})} \right] \tilde{w}_{k|k-1}^i \quad (2-40)$$

其中

$$C_k(\mathbf{z}) = \sum_{i=1}^{R_k} \psi_{k,z}(\tilde{\mathbf{x}}_k^i) \tilde{w}_{k|k-1}^i, \forall \mathbf{z} \in Z_k \quad (2-41)$$

步骤 4: 重采样

计算所有粒子权值之和, \hat{T}_k 即为估计的目标数目:

$$\hat{T}_k = \sum_{i=1}^{R_k} \tilde{w}_k^i \quad (2-42)$$

令 $N_k = N \cdot \text{int}(\hat{T}_k)$, 对原来的粒子集 $\left\{ \frac{\tilde{w}_k^i}{\hat{T}_k}, \tilde{\mathbf{x}}_k^i \right\}_{i=1}^{R_k}$ 重采样 N_k 个粒子, 获得新的粒

子集 $\left\{ \frac{\tilde{w}_k^i}{\hat{T}_k}, \tilde{\mathbf{x}}_k^i \right\}_{i=1}^{N_k}$, 重采样后每个粒子的权值均为 $\frac{\hat{T}_k}{N_k}$ 。

步骤 5: 目标状态提取

PHD 函数 v_k 是目标状态空间上的多峰值函数, PHD 峰值的个数即为估计的目标数, 可近似看作多个目标概率密度的叠加, 目标状态估计由粒子表示的 PHD 后验分布中利用聚类等方法提取峰值得到, 其中期望最大(Expectation-Maximation,

EM)算法应用较早, 但容易陷入局部最大值; CLEAN 算法单纯应用粒子的权值信息, 容易受杂波干扰; 而基于 MCMC 采样算法的复杂度较高, 计算代价较大。k-means 聚类应用最广, k-means 聚类算法的性能优于 EM 算法^[17]。因此一般选用的是简单实用的 k-means 聚类算法。

2.4 CPHD 滤波算法

我们知道 PHD 滤波器中假设多目标随机集的势服从泊松分布, 多目标随机集近似地描述为一个泊松点过程, 因此一阶矩信息可完全描述其随机特性。由于 PHD 传递的是多目标随机集状态的一阶矩, 对于服从泊松分布的随机变量来说其期望和方差相等, 当观测区域中目标密集分布时, PHD 的目标数估计准确度将大大下降导致方差较大, 此时滤波估计的可信度降低, 存在对目标数目估计不准确的问题。一旦目标数目估计错误, 那么多目标状态也将无法正确提取, 会影响到 PHD 滤波器的性能。

为解决这个问题, Mahler 提出了 CPHD 滤波器, 与 PHD 中多目标随机集被建模为泊松点过程不同, CPHD 中多目标随机集被建模为聚类点过程。CPHD 滤波器在传递多目标随机集强度的同时并行递推集合势的后验概率分布, 两者的预测相互独立, 两者的更新却相互耦合。CPHD 比 PHD 获得了更为充分的信息, 因此可以获得更加准确的目标数目及位置估计。相应的缺点是计算量变大, 迭代公式也更加复杂。

CPHD 滤波器的算法流程如下:

假设 $v_{k|k-1}$ 和 $\rho_{k|k-1}$ 分别代表多目标状态预测强度函数和多目标状态预测势分布, $v_{k|k}$ 和 $\rho_{k|k}$ 分别代表多目标状态后验强度函数和多目标状态后验势分布。

CPHD 的预测过程为:

$$\rho_{k|k-1}(n) = \sum_{j=0}^n \rho_{\Gamma,k}(n-j) \Pi_{k|k-1}[v_{k-1}, \rho_{k-1}](j) \quad (2-43)$$

$$v_{k|k-1}(\mathbf{x}) = \int p_{S,k}(\boldsymbol{\varsigma}) f_{k|k-1}(\mathbf{x}|\boldsymbol{\varsigma}) v_{k-1}(\boldsymbol{\varsigma}) d\boldsymbol{\varsigma} + \gamma_k(\mathbf{x}) \quad (2-44)$$

其中,

$$\Pi_{k|k-1}[v, \rho](j) = \sum_{l=j}^{\infty} C_j^l \frac{\langle p_{S,k}, v \rangle^j \langle 1 - p_{S,k}, v \rangle^{l-j}}{\langle 1, v \rangle^l} \rho(l) \quad (2-45)$$

CPHD 的更新过程为:

$$\rho_k(n) = \frac{\gamma_k^0[v_{k|k-1}; Z_k](n) \rho_{k|k-1}(n)}{\langle \gamma_k^0[v_{k|k-1}; Z_k], \rho_{k|k-1} \rangle} \quad (2-46)$$

$$\begin{aligned} v_k(\mathbf{x}) = & (1 - p_{D,k}(\mathbf{x})) \frac{\langle \gamma_k^1[v_{k|k-1}; Z_k], \rho_{k|k-1} \rangle}{\langle \gamma_k^0[v_{k|k-1}; Z_k], \rho_{k|k-1} \rangle} v_{k|k-1}(\mathbf{x}) \\ & + \sum_{\mathbf{z} \in Z_k} \psi_{k,\mathbf{z}}(\mathbf{x}) \frac{\langle \gamma_k^1[v_{k|k-1}; Z_k / \{\mathbf{z}\}], \rho_{k|k-1} \rangle}{\langle \gamma_k^0[v_{k|k-1}; Z_k], \rho_{k|k-1} \rangle} v_{k|k-1}(\mathbf{x}) \end{aligned} \quad (2-47)$$

其中,

$$\gamma_k^u[v, Z](n) = \sum_{j=0}^{\min(|Z|, n)} (|Z| - j)! \rho_{\kappa,k}(|Z| - j) P_{j+u}^n \times \frac{\langle 1 - p_{D,k}, v \rangle^{n-(j+u)}}{\langle 1, v \rangle^n} e_j(\Xi_k(v, Z)) \quad (2-48)$$

$$\Xi_k(v, Z) = \{ \langle v, \psi_{k,\mathbf{z}} \rangle; \mathbf{z} \in Z \} \quad (2-49)$$

$$\psi_{k,\mathbf{z}}(\mathbf{x}) = \frac{\langle 1, \kappa_k \rangle}{\kappa_k(\mathbf{z})} g_k(\mathbf{z}|\mathbf{x}) p_{D,k}(\mathbf{x}) \quad (2-50)$$

上述已经提到, PHD 滤波器通过目标权值计算目标数目, 且由于目标数目服从泊松分布的限制存在对目标数目估计不准确的问题, CPHD 滤波器估计的是目标状态的一阶矩及目标数目的高阶矩, 目标数目由下式计算:

$$n_{k|k} = \sum_{n=1}^{\infty} n \rho_{k|k}(n) \quad (2-51)$$

因此 CPHD 对目标数目的估计精度有很大提高。类似 PHD 滤波器, 线性高斯条件下 CPHD 滤波器可通过高斯混合(GM) 方法^[39]实现, 而非线性非高斯条件下可通过序贯蒙特卡罗(SMC) 方法实现。

2.5 随机集多目标性能评价指标

多目标跟踪性能评价标准^[40]是算法性能好坏的评价标准, 而常见的多目标性能评价指标如均方误差 (Mean Square Error, MSE), 均方根误差 (Root Mean Square Error, RMSE) 等由于需要计算期望, 通常很难获得。这些评价指标是一种点和点之间的误差评判准则, 很难在目标数目较多时给出多目标整体跟踪性能的评价。而基于随机集的多目标跟踪需要重点考虑集值估计的性能, 本节对几种常用的随

机集多目标评价指标做一简要介绍。

1) Hausdorff 距离

对于非空的有限子集 $X = \{\mathbf{x}_1, \dots, \mathbf{x}_m\}$ 和 $Y = \{\mathbf{y}_1, \dots, \mathbf{y}_n\}$, 两者的 Hausdorff 距离为:

$$d_H(X, Y) = \max \left\{ \max_{\mathbf{x} \in X} \min_{\mathbf{y} \in Y} d(\mathbf{x}, \mathbf{y}), \max_{\mathbf{y} \in Y} \min_{\mathbf{x} \in X} d(\mathbf{x}, \mathbf{y}) \right\} \quad (2-52)$$

其中, $d(\mathbf{x}, \mathbf{y})$ 表示 \mathbf{x}, \mathbf{y} 之间的一阶距离。

Hausdorff 距离的缺点是对异常值的处罚过于严重, 当存在一个集合为空时, Hausdorff 距离将趋于无穷大。

2) Wasserstein 距离

Wasserstein 距离的多目标性能评价标准优于 Hausdorff 距离, p 阶 Wasserstein 距离为:

$$W_p(p, X, Y) = \min_C \left(\sum_{i=1}^m \sum_{j=1}^n C_{i,j} d(\mathbf{x}_i, \mathbf{y}_j)^p \right)^{1/p} \quad (2-53)$$

$$d_\infty(X, Y) = \min_C \max_{1 \leq i \leq m, 1 \leq j \leq n} \tilde{C}_{i,j} d(\mathbf{x}_i, \mathbf{y}_j) \quad (2-54)$$

$C = \{C_{i,j}\} (n \times m)$, 矩阵元素 $C_{i,j} \geq 0$, $\sum_{j=1}^n C_{i,j} = \frac{1}{m}$, $\sum_{i=1}^m C_{i,j} = \frac{1}{n}$; 当 $C_{i,j} \neq 0$ 时

$\tilde{C}_{i,j} = 1$; 否则, $\tilde{C}_{i,j} = 0$ 。

Wasserstein 距离用于度量两个集合之间的距离, 通过改变参数 p 来调整对异常值的处罚程度来评价集合之间的差异。当两集合间的元素个数不相等时, Wasserstein 距离往往惩罚过重, 尤其是在目标数目估计不准确时评价数值会出现很大的误差, Wasserstein 距离在某一个集合的势为 0 的情况下没有任何意义。

3) 最优子模式分配距离

最优子模式分配(Optimal Subpattern Assignment, OSPA)距离建立在 Wasserstein 距离的基础上提出的, p 阶 OSPA 距离为:

$$OSPA(p, c, X, Y) = \left(\frac{1}{n} \left(\min_{\pi \in \Pi_n} \sum_{i=1}^m d(c, \mathbf{x}_i, \mathbf{y}_{\pi(i)})^p + c^p (n - m) \right) \right)^{1/p} \quad m \leq n \quad (2-55)$$

$$OSPA(p, c, X, Y) = OSPA(p, c, Y, X) \quad m > n \quad (2-56)$$

$$OSPA(\infty, c, X, Y) = \begin{cases} \min_{\pi \in \Pi_n} \max_{1 \leq i \leq n} d(c, \mathbf{x}_i, \mathbf{y}_{\pi(i)}), & m = n \\ c, & m \neq n \end{cases} \quad (2-57)$$

其中 $X = \{\mathbf{x}_1, \dots, \mathbf{x}_m\}$ 和 $Y = \{\mathbf{y}_1, \dots, \mathbf{y}_n\}$ 是任意两个有限集合， p 是距离参数，反映位置估计误差对性能的影响； c 是水平参数，反映势估计误差对性能的影响。

OSPA 距离通过引入水平参数 c 改变对势误差的处罚程度以及对异常值的敏感性，弥补了 Wasserstein 距离的不足。它从位置估计误差和势估计误差两个方面描述集合误差的估计，可以通过设定参数 p 和 c 的值来决定哪个误差对跟踪性能的影响更大。参数值设定越大，相应的误差影响越大。OSPA 距离更加全面的描述了随机集下的目标跟踪性能，是目前比较常用的一种评价标准。

2.6 本章小结

本章主要介绍了基于随机集的目标跟踪基础，并简要叙述了随机集理论的定义和目标跟踪模型，在此理论基础上详细介绍了 PHD 滤波算法，以及线性高斯条件下的闭合解 GM-PHD 和非线性非高斯条件下的闭合解 SMC-PHD，给出了算法的具体流程以及基于随机集理论的 CPHD 滤波算法，并对随机集下的多目标跟踪评价标准做了简单介绍，为后续章节中基于随机集的多目标跟踪及航迹关联算法奠定了坚实的基础。

第三章 基于标记的概率假设密度航迹关联算法

3.1 引言

多目标跟踪问题就是在杂波等干扰导致量测的不确定性条件下估计未知数目的目标位置信息，解决这一问题的一般方法就是对每个目标分配一个独立的滤波器进行跟踪，然后再使用数据关联技术将每个滤波器与正确的量测进行关联^[41]。但是由于计算量太大实际应用中很难实现。基于随机集的概率假设密度滤波器将目标和量测均看做随机集，大大减少了计算量，但是却无法提供目标的航迹信息。因此本章主要研究基于随机集的标记滤波算法，包括标记 GM-PHD、标记粒子 PHD、标记 CP-PHD 等多种算法，在有效估计多个目标数目和状态的同时，还能关联出不同目标的航迹，同时本文还将标记 CP-PHD 算法中合作惩罚权值的思想应用在 CPHD 滤波器中，有效改善了算法的目标航迹提取性能。

3.2 标记 PHD 算法

3.2.1 标记 GM-PHD 关联法

高斯项标记法^[42]通过对每个高斯项进行标记，递推估计目标状态的同时能根据标记分辨出目标并得到目标航迹。高斯项标记法包含如下步骤：

步骤 1：初始化

假设初始时刻强度函数是 J_0 个高斯项的混合形式，对每个高斯项分配独特的标记，

$$T_0 = \{\tau_0^1, \dots, \tau_0^{J_0}\} \quad (3-1)$$

其中 $\tau^{(j)}$ 代表第 j 个高斯项的标记， T 是所有标记的集合。

步骤 2：预测：

k 时刻预测的强度函数也是一个高斯混合的形式，则预测的高斯项将与 $k-1$ 时刻的标记相同，新生目标和衍生目标的高斯项分配新的标记，那么新的标记集变为：

$$T_{k|k-1} = T_k \cup \left\{ \tau_{\gamma_k}^{(1)}, \dots, \tau_{\gamma_k}^{(J_{\gamma_k})} \right\} \cup \left\{ \tau_{\beta_k}^{(1)}, \dots, \tau_{\beta_k}^{(J_{\beta_k})} \right\} \quad (3-2)$$

步骤 3：更新




图 3.1 高斯项的更新过程

在更新步骤中由于对真实目标和漏检目标的更新高斯项大量增长，一个预测的高斯项将会变为 $(1+|Z_k|)$ 个高斯项，注意到由同一个高斯项更新的多个高斯项将会与预测时刻的标记相同，如图 3.1 所示。

步骤 4：修剪合并

距离一定门限内的多个高斯项将被合并为一项，若被合并的不同高斯项具有相同的标记，则合并后的标记与之前的标记相同，相反地，若被合并的不同高斯项之间标记不相同，则取合并之前具有最大权值的高斯项标记作为合并后的标记。在修剪合并操作结束后，若还存在不同的高斯项标记相同，还需要重新标记，保留权值最大的高斯项的标记，而其他相同标记的高斯项则分配成不同的标记。

步骤 5：目标状态提取

每个时刻，大于某一门限 w_{th} 的高斯项作为单独目标状态的估计，目标状态的标记由下式给出：

$$\hat{T}_k = \{\tau_k^i : w_k^i > w_{TH}\} \quad (3-3)$$

步骤 6：目标航迹估计

目标航迹的含义是一个目标在空间中的运动路径。在上述步骤中可知，新的标记是在初始化时刻分配的，每个时刻预测步骤中新生高斯项也会分配新的标记，对漏检和量测更新后这些高斯项会线性增长，类似树的结构，每棵树的树枝都有唯一的标记，且标记与根结点标记相同，树的每个树枝都是目标可能的运动轨迹，获得目标航迹的一种解决办法就是从每棵树中选择权值大于门限 w_{th} 的树枝组成单独目标的航迹。首先将树分类，分别为确认树和暂时树。若存在至少一个树枝权值大于门限 w_{th} 则认为是确认树，否则认为是暂时树，所有初始化的树均是暂时树。所有确认树以及它的标记作为目标航迹身份并进行航迹输出的集合称作航迹集 ξ_k 。也就是说，航迹集中的每个元素都是一个具有唯一标记的目标轨迹，即 $(\{\mathbf{m}_{k_i}^i, \dots, \mathbf{m}_k^i\}, \tau^i)$ ，其中 $\{\mathbf{m}_{k_i}^i, \dots, \mathbf{m}_k^i\}$ 是第 i 个目标的航迹， τ^i 代表第 i 个目标航迹的

标记, k_i 是标记为 τ^i 的航迹进入观测区域的时刻, 那么航迹管理方案^[33]如下:

航迹起始: 在初始时刻, 对每个初始的高斯项和新生高斯项起始一个假设树 (看作暂定树)。

航迹确认: 在 k 时刻, 至少有一个树枝满足条件 $w_k^i > w_{TH}$ 时, 确认假设树。

航迹维持: 若 k 时刻没有满足确认条件的树枝, 则从 $k-1$ 时刻已经确认的树枝中选择当前时刻权值最大的树枝。

航迹终止: 若一个目标航迹属于 $k-1$ 时刻的航迹集 ξ_{k-1} , 但不属于 k 时刻的航迹集 ξ_k , 可看做目标已不在监测区域, 对航迹终结。

标记高斯项法虽简单易行, 但是不同高斯项的修剪合并等操作易导致航迹丢失与航迹合并等问题。

3.2.2 标记粒子 PHD 关联法

粒子 PHD 中, 聚类技术被用来提取 PHD 分布的峰值^[43], 因此标记粒子关联法的主要思想就是对聚类划分的粒子类分配标记, 在每步迭代中, 对粒子分类并对同一个类中的粒子分配相同的标记, 在下一步迭代中, 重采样的粒子将继承其父粒子的标记, 之后重新对粒子分类, 并将每个类中多数粒子带有的标记与上一时刻相同标记的粒子类进行关联。由于粒子 PHD 滤波的目标状态含有目标的位置与速度信息, 而聚类对粒子的分类是根据位置信息划分的, 因此如果位置域不能准确划分粒子, 则采用速度信息划分。

在粒子 PHD 的基础上, 粒子标记关联法的步骤如下:

步骤 1: 预测

假设 $k-1$ 时刻 N_{k-1} 个粒子已经分配好标记, k 时刻预测步骤中原有的标记不变, 记为

$$L_k^P(\tilde{\mathbf{x}}_k^{(i)}) = L_{k-1}(\mathbf{x}_{k-1}^{(i)}), i = 1, \dots, N_{k-1} \quad (3-4)$$

定义新生粒子的分类 $P_{k, L_{new}}^P$, 对新生的粒子分配一个新的标记:

$$L_k^P(\tilde{\mathbf{x}}_k^{(i)}) = L_{new}, i = 1, \dots, M \quad (3-5)$$

定义预测分类:

$$\{P_{k,1}^P, \dots, P_{k, \hat{T}_{k-1}}^P\} = \{P_{k-1,1}, \dots, P_{k-1, \hat{T}_{k-1}}\} \quad (3-6)$$

步骤 2: 更新

根据预测步骤可知, 更新后的粒子分类为:

$$\{P_{k,1}^U, \dots, P_{k,\hat{T}_{k-1}+1}^U\} = \{P_{k,1}^P, \dots, P_{k,\hat{T}_{k-1}}^P\} \cup P_{k,L_{new}}^P \quad (3-7)$$

步骤 3: 重采样

重采样后, 子粒子被赋予与父粒子相同的标记:

$$L_k^R(\mathbf{x}_k^{(j)}) = L_k^U(\tilde{\mathbf{x}}_k^{(i)}), \mathbf{x}_k^{(j)} \in Child(\tilde{\mathbf{x}}_k^{(i)}) \quad (3-8)$$

步骤 4: 目标状态提取

通过聚类等技术得到目标的状态和协方差 $\{(\hat{\mathbf{x}}_{k,1}, \mathbf{S}_{k,1}), \dots, (\hat{\mathbf{x}}_{k,\hat{T}_k}, \mathbf{S}_{k,\hat{T}_k})\}$, 若对任意两状态存在:

$$\exp\left\{-(1/2)(\mathbf{H}\hat{\mathbf{x}}_{k,j} - \mathbf{H}\hat{\mathbf{x}}_{k,i})^T (\mathbf{H}^T \mathbf{S}_{k,i} \mathbf{H})(\mathbf{H}\hat{\mathbf{x}}_{k,j} - \mathbf{H}\hat{\mathbf{x}}_{k,i})\right\} < \gamma \quad (3-9)$$

则对粒子重新利用距离分类, 其中 \mathbf{H} 为量测矩阵。对新估计的粒子类分配标记, $\{L_{k,1}^E, \dots, L_{k,\hat{T}_k}^E\}$, 提取的粒子分类为: $\{P_{k,1}, \dots, P_{k,\hat{T}_k}\}$ 。

步骤 5: 标记关联

定义两个矩阵 A 和 C , 其中

$$A_{g,h} = \begin{cases} 1, & \left| \left\{ i: \mathbf{x}_k^{(i)} \in P_{k,g}^R \cap P_{k,h}^E \right\} \right| > \varepsilon_1 N \\ 0, & \text{其他} \end{cases} \quad (3-10)$$

$$C_{g,h} = \left| \left\{ i: Child(\tilde{\mathbf{x}}_k^{(i)}) \in P_{k,g}^R \cap P_{k,h}^E \right\} \right| \quad (3-11)$$

A 矩阵说明当前时刻 k 粒子类 g 与前一时刻的粒子类 h 是否存在对应, 在两个分类中若存在超过一定数目的粒子标记相同, 则说明存在粒子类对应, 此时 $A_{g,h} = 1$, 否则为 0。 C 矩阵表明当前时刻有多少重采样的粒子与上一时刻的粒子对应。

根据矩阵 A 和矩阵 C , 则目标估计与航迹关联如下:

若 $\sum_h A_{g,h} = 0$, 则将航迹 $L_{k,h}$ 终止;

若 $\sum_h A_{g,h} = 1$, 则将粒子类 $P_{k,g}^R$ 关联到已有航迹 $L_{k,h}$;

若 $\sum_h A_{g,h} > 1$, 则将粒子类 $P_{k,g}^R$ 关联到已有航迹 $L_{k,h}$, 其中

$$h = \arg \max_h C_{g,h} \quad (3-12)$$

并对其他使得 $A_{g,h} = 1$ 的 $h \in \{h_1, \dots, h_n\}$ 起始新航迹;

标记粒子 PHD 关联法首先对所有粒子进行标记, 分别计算聚类后各个类中不同标记的粒子数目, 从而进行关联。由于需要进行重采样和聚类等复杂计算, 不仅会使提取的目标位置和状态不够准确, 在重采样阶段当多个目标相距很近时还容易导致不同标记重采样数目不均衡, 使得最终提取的不同目标具有相同的标记。

3.3 惩罚高斯混合概率假设密度 (Penalized GM-PHD) 滤波

GM-PHD 滤波器在没有目标相互靠近时性能良好, 然而在目标运动相互靠近时估计性能就急剧下降。在多目标跟踪问题中假定量测和目标是一对一的关系, 因此同一个目标将不能同时把多个量测作为它的目标估计进行输出, 而在 GM-PHD 滤波器中当多个量测距离一个目标较近而距离其他目标较远时就会违背这一假设, 它根据更新的权值大小而输出距离目标相近的多个量测, 为了克服这一缺点, 文章^{[44][45]}提出了 PGM-PHD 滤波器, 其主要思想是在 GM-PHD 迭代过程中重新分配每个目标的权值并进行归一化, 提高了空间相距较近的多个目标的跟踪估计性能。

PGM-PHD 的算法步骤:

GM-PHD 的算法步骤在第二章我们已经做过详细介绍, 在目标的状态提取步骤中, 权值大于某一预设阈值的高斯项作为估计的目标状态进行输出, 为了避免被同一目标更新的多个量测作为目标输出, 我们需要重新定义各高斯项的权值, 具体操作如下:

假设在 k 时刻, 首先建立一个权值矩阵 M_w , 其矩阵元素 $\langle n, m \rangle$ 代表了目标 x_k^n 被量测 Z_k^m 更新后 $x_k^{n,m}$ 的权值 $w_k^{n,m}$, 矩阵行代表了目标数目, 矩阵列代表了量测数目, 其中

$$w_k^{n,m} = P_{D,k} w_{k|k-1}^n N(Z_k^m; \mathbf{z}_{k|k-1}^n, S_k^n) \quad (3-13)$$

归一化权值为:

$$\bar{w}_k^{n,m} = \frac{w_k^{n,m}}{\kappa_k(Z_k^m) + \sum_{i=1}^{N_{k|k-1}} w_k^{i,m}}, \forall n = 1: N_{k|k-1} \quad (3-14)$$

首先找出归一化权值中最大值:

$$\langle n^*, m^* \rangle = \arg \max_{n \in I, \forall m=1:M_k} (\bar{w}_k^{n,m}), \forall I = \{1, \dots, N_{k|k-1}\} \quad (3-15)$$

其中 $\bar{w}_k^{n^*, m^*}$ 对应的 $x_k^{n^*, m^*}$ 的权值, M_k 是 k 时刻量测个数。

如果存在 $\sum_{m=1}^{M_k} \bar{w}_k^{n^*, m} > 1$, 那么除权值矩阵中对应的最大权值外, 同一行的其他元素都要被惩罚, 惩罚后的权值为:

$$w_{new}^{n^*, m} = \begin{cases} w_k^{n^*, m} \times \rho^{n^*}, \forall m=1:M_k, m \neq m^* \\ w_k^{n^*, m}, & m = m^* \end{cases} \quad (3-16)$$

$$\rho^{n^*} = \alpha \times (1 - \bar{w}_k^{n^*, m^*}) \quad (3-17)$$

其中 ρ^{n^*} 是惩罚系数, α 为一个常量, 决定了惩罚的程度, 若 $\alpha = 0$, 意味着除权值矩阵中对应的最大归一化权值 $w_k^{n^*, m^*}$ 外, 同一行的其他权值都可以忽略惩罚。

经过惩罚之后, 权值矩阵中每个目标对应的所有量测的新权值, 都必须经过重新归一化, 重新归一化后的权值直接由下式得到:

$$\bar{w}_{new}^{n,m} = \begin{cases} \frac{1}{\varpi} \times w_k^{n,m}, \forall n=1:N_{k|k-1}, n \neq n^* \\ \frac{1}{\varpi} \times (\bar{w}_k^{n,m} \times \rho^{n^*}), n = n^* \end{cases} \quad (3-18)$$

$$\varpi = \kappa_k(Z_k^m) + (w_k^{n^*, m} \times \rho^{n^*}) + \sum_{i=1, i \neq n^*}^{N_{k|k-1}} w_k^{i,m} \quad (3-19)$$

惩罚后再重新归一化这一过程需要重复进行。假设 $N_{k|k-1}$ 是 k 时刻预测的目标数, I 是目标的初始索引列表:

$$I = \{1, \dots, N_{k|k-1}\} \quad (3-20)$$

每次惩罚并重新归一化步骤中, 具有最大权值的目标 n^* 就会从列表中选出并判断其权值和 $\sum_{m=1}^{M_k} \bar{w}_k^{n^*, m}$ 。若大于 1, 就将此目标进行上述惩罚并重新归一化, 若小于 1, 则不进行此步骤。然后将目标 n^* 从列表中删除, 对下一个满足 $\sum_{m=1}^{M_k} \bar{w}_k^{n^*, m} > 1$ 条件的目标处理, 直到目标的初始索引列表为空。因此, 惩罚并重新归一化的过程最多进行 $N_{k|k-1}$ 次。

必须注意到, 在 GM-PHD 滤波器中, 目标权值的总和提供了目标数目的估计, 也就是说, 估计的目标数目

$$\hat{N}_k = \sum_{n=1}^{N_{k|k-1}} \sum_{m=1}^{M_k} \bar{w}_k^{n,m} \quad (3-21)$$

而 PGM-PHD 滤波器保留了目标权值的总和, 因此目标的估计数目并不发生改变, 下面将对这一假设做出证明:

假设 $w_{old}^{n,m}$ 为 GM-PHD 滤波器目标 $\mathbf{x}_k^{n,m}$ 的权值, $\bar{w}_{new}^{n,m}$ 是 PGM-PHD 目标 $\mathbf{x}_k^{n,m}$ 重新归一化后的权值, 目标 n^* 被选为惩罚目标, 利用上述式子, 对每个量测有:

$$\begin{aligned} \sum_{n=1}^{N_{k|k-1}} \bar{w}_{new}^{n,m} &= \bar{w}_{new}^{n^*,m} + \sum_{n=1, n \neq n^*}^{N_{k|k-1}} \bar{w}_{new}^{n,m} = \frac{1}{\varpi} \left(w_{old}^{n^*,m} \times \rho^{n^*} + \sum_{n=1, n \neq n^*}^{N_{k|k-1}} w_{old}^{n,m} \right) \\ &= \frac{1}{\varpi} \left(\varpi - \kappa_k(Z_k^m) \right) = 1 - \bar{\kappa}_k(Z_k^m), \forall m = 1:M_k \end{aligned} \quad (3-22)$$

$$\bar{\kappa}_k(Z_k^m) = \frac{\kappa_k(Z_k^m)}{\kappa_k(Z_k^m) + \sum_{i=1}^{N_{k|k-1}} w_k^{i,m}} \quad (3-23)$$

其中 $\bar{\kappa}_k(Z_k^m)$ 代表归一化的杂波密度, 由上式可知

$$\sum_{n=1}^{N_{k|k-1}} \bar{w}_{new}^{n,m} + \bar{\kappa}_k(Z_k^m) = 1, \forall m = 1:M_k \quad (3-24)$$

若 $\bar{w}_{old}^{n,m}$ 为 GM-PHD 滤波器目标 $\mathbf{x}_k^{n,m}$ 的归一化权值, 那么有:

$$\sum_{n=1}^{N_{k|k-1}} \bar{w}_{old}^{n,m} + \bar{\kappa}_k(Z_k^m) = 1, \forall m = 1:M_k \quad (3-25)$$

从上面两个式子可以得出:

$$\hat{N}_k = \sum_{n=1}^{N_{k|k-1}} \sum_{m=1}^{M_k} \bar{w}_{old}^{n,m} = \sum_{n=1}^{N_{k|k-1}} \sum_{m=1}^{M_k} \bar{w}_{new}^{n,m} \quad (3-26)$$

因此 PGM-PHD 滤波虽然对目标的权值进行了重新分配, 但是并没有改变对目标数目的估计, 与 GM-PHD 相比, 由于提取的高斯项不同, 因此目标估计位置更准确。

3.4 合作惩罚高斯项标记法及改进算法

3.4.1 标记 CP-GMPHD 滤波

上一小节中已经介绍了 PGM-PHD 滤波, 将重新分配权值的思想引入 GM-PHD 滤波, 对空间位置相距较近目标的估计性能有很大提高, 但 PGM-PHD 同样没有提供航迹的估计, 而标记的 GM-PHD 存在对空间位置相近目标之间辨识错误导致

航迹关联错误的问题仍然没有解决，因此文献^[46]提出了 CP-GMPHD(Collaborative penalized GMPHD)跟踪器，将标记高斯项的方法应用在改进的 PGM-PHD 滤波器中，不但能够在目标空间位置相近时提高估计精度，正确辨识并提取高斯项标记，同时提高航迹的正确关联率。

CP-GMPHD 跟踪器的算法如下：

初始化及预测步骤与标记的 GM-PHD 相同，在更新步骤中，所有预测目标的未归一化权值构成了权值矩阵 M_w ，归一化的权值构成了归一化权值矩阵 \bar{M}_w ，两个矩阵维数相同，均为 $J_{k|k-1} \times M_k$ ，其中 $J_{k|k-1}$ 是 k 时刻预测高斯项个数， M_k 是 k 时刻量测个数。矩阵元素 $\langle n, m \rangle$ 代表了高斯项 $\{\mathbf{m}_k^{n,m}, \mathbf{P}_k^{n,m}\} (n=1:J_{k|k-1}, m=1:M_k)$ 的权值 $w_k^{n,m}$ ，假设 $w_k^{n,m}$ 和 $\bar{w}_k^{n,m}$ 分别代表目标 $\mathbf{x}_k^{n,m}$ 的权值及归一化权值，则

$$w_k^{n,m} = P_{D,k} w_{k|k-1}^n N(\mathbf{z}_k^m; \mathbf{H}_k \mathbf{m}_{k|k-1}^n, \mathbf{R}_k + \mathbf{H}_k \mathbf{P}_{k|k-1}^n (\mathbf{H}_k)^T) \quad (3-27)$$

$$\bar{w}_k^{n,m} = \frac{w_k^{n,m}}{\kappa_k(\mathbf{z}_k^m) + \sum_{i=1}^{J_{k|k-1}} w_k^{i,m}} \quad (3-28)$$

其中 \mathbf{z}_k^m 是 k 时刻第 m 个量测，每个预测目标都有一个标记 $\tau_{k|k-1}^n$ ，同一个预测目标由不同量测更新及漏检更新得到的高斯项将有相同的标记，即 $\tau_k^{n,m} = \tau_{k|k-1}^n$ ，每个高斯项由四部分构成 $\{\mathbf{m}_k^{n,m}, \mathbf{P}_k^{n,m}, w_k^{n,m}, \tau_k^{n,m}\}$ 。

当多个目标运动相互靠近时，若同一时刻对于其他目标而言，多个量测更靠近某一目标，那么归一化权值矩阵中此目标对应行中多个高斯项的权值之和将大于 1，即 $\sum_{m=1}^{M_k} \bar{w}_k^{n,m} > 1$ ，此时第 n 个目标称为不连续目标。

为解决上述问题，首先需要根据归一化权值矩阵选出目标 $\mathbf{x}_{k|k-1}^{n^*}$ 与所有量测之间的最佳关联对 $\langle n^*, m^* \rangle$ ，即

$$\langle n^*, m^* \rangle = \arg \max_{n \in I, \forall m=1:M_k} (\bar{w}_k^{n,m}), I = \{1, \dots, J_{k|k-1}\} \quad (3-29)$$

若满足条件 $\sum_{m=1}^{M_k} \bar{w}_k^{n^*,m} > 1$ ，将对权值矩阵 M_w 中所有与权值最大目标 $\bar{w}_k^{n^*,m^*}$ 标记 $\tau_k^{n^*,m^*}$ 相同的其他高斯项的权值进行惩罚，即第 n^* 行中除元素 $\langle n^*, m^* \rangle$ 外的其他元素，同时还包括其他行中标记为 $\tau_k^{n^*,m^*}$ 的所有元素，再对惩罚后的权值矩阵重新归

一化。经权值惩罚后的新权值矩阵 $M_{w,new}$ 变为：

$$w_{k,new}^{n,m} = \begin{cases} w_k^{n,m}, m = m^* \\ w_k^{n,m} \times (1 - \bar{w}_k^{n^*,m^*}), n = n^*, \forall m = 1:M_k, m \neq m^* \\ w_k^{n,m} \times (1 - \bar{w}_k^{n^*,m^*}), n \neq n^*, \forall m = 1:M_k, m \neq m^*, \tau_k^{n,m} = \tau_k^{n^*,m^*} \\ w_k^{n,m}, n \neq n^*, \forall m = 1:M_k, m \neq m^*, \tau_k^{n,m} \neq \tau_k^{n^*,m^*} \end{cases} \quad (3-30)$$

新的归一化权值矩阵 $\bar{M}_{w,new}$ 变为：

$$\bar{w}_{k,new}^{n,m} = \frac{w_{k,new}^{n,m}}{\kappa_k(\mathbf{z}_k^m) + \sum_{i=1}^{J_{k|k-1}} w_{k,new}^{i,m}} \quad (3-31)$$

经过一轮惩罚并归一化后，若仍存在 $\sum_{m=1}^{M_k} \bar{w}_{k,new}^{n^*,m} > 1$ ，则对权值矩阵 $M_{w,new}$ 进行新一轮的惩罚并归一化，直到 $\sum_{m=1}^{M_k} \bar{w}_{k,new}^{n^*,m} \leq 1$ ，惩罚系数仍然是 $(1 - \bar{w}_k^{n^*,m^*})$ 。

假设 $\rho = (1 - \bar{w}_k^{n^*,m^*})$ ，与 $\tau_k^{n^*,m^*}$ 标记相同的预测目标的集合为 S ，那么

$$\begin{aligned} \bar{w}_{k,new}^{n^*,m} - \bar{w}_k^{n^*,m} &= \frac{\rho w_k^{n^*,m}}{\kappa_k(\mathbf{z}_k^m) + \sum_{i \notin S} w_k^{i,m} + \rho \sum_{i \in S} w_k^{i,m}} - \frac{w_k^{n^*,m}}{\kappa_k(\mathbf{z}_k^m) + \sum_{i=1}^{J_{k|k-1}} w_k^{i,m}} \\ &= \frac{(\rho - 1) w_k^{n^*,m} (\kappa_k(\mathbf{z}_k^m) + \sum_{i \notin S} w_k^{i,m})}{(\kappa_k(\mathbf{z}_k^m) + \sum_{i \notin S} w_k^{i,m} + \rho \sum_{i \in S} w_k^{i,m}) (\kappa_k(\mathbf{z}_k^m) + \sum_{i=1}^{J_{k|k-1}} w_k^{i,m})} < 0 \end{aligned} \quad (3-32)$$

即惩罚后的权值 $\bar{w}_{k,new}^{n^*,m}$ 一定不大于原来的权值 $\bar{w}_k^{n^*,m}$ ，因此每一次的惩罚权值都会使权值总和 $\sum_{m=1}^{M_k} \bar{w}_{k,new}^{n^*,m}$ 越来越小。

若 $\sum_{m=1}^{M_k} \bar{w}_k^{n^*,m} \leq 1$ ，此时忽略第 n^* 行，在剩余其他行中寻找相应最大权值对应的目标，若存在 $\sum_{m=1}^{M_k} \bar{w}_k^{n^*,m} > 1$ ，则按照上述过程对矩阵相应元素的权值惩罚并归一化，直到权值矩阵中的每一行均满足条件 $\sum_{m=1}^{M_k} \bar{w}_k^{n^*,m} \leq 1$ 为止。

考虑到在对目标权值惩罚并归一化的操作可能会使一些杂波的权值变大，可能会产生一些虚假航迹，因此若某些航迹较短，即目标状态数目较少，由于无法判断其为真实目标还是杂波，因此应该保持其原始权值不变。假设稳定航迹的标记集合为 T_s ，那么最终的权值矩阵 \bar{M}_w^{final} 为：

$$\bar{w}_{k,final}^{n,m} = \begin{cases} \bar{w}_{k,new}^{n,m}, \forall n = 1: J_{k|k-1}, \forall m = 1: M_k, \tau_k^{n,m} \in T_s \\ \bar{w}_k^{n,m}, \forall n = 1: J_{k|k-1}, \forall m = 1: M_k, \tau_k^{n,m} \notin T_s \end{cases} \quad (3-33)$$

若目标状态估计的标记属于已确定的航迹的标记集，直接将此估计值关联到

相应航迹，否则将此标记加入航迹标记集，并且起始新航迹。

在 PGM-PHD 滤波器中，一旦归一化权值矩阵中的最大权值对应的目标所在行权值之和小于 1 时，惩罚并重新归一化权值的过程即停止。这种情况下 CPGM-PHD 则对其他剩余目标均进行检查其是否为不连续目标，循环惩罚并重新归一化直到所有目标均满足条件为止。

3.4.2 改进算法

我们注意到，CPGM-PHD 跟踪器是将高斯项标记法与改进的 PGM-PHD 相结合，但在一些特殊的目标场景下，当目标距离很近导致代表不同目标的高斯混合项被合并为一个高斯项时，相应的标记也会被合并，利用惩罚权值并归一化的思想从这样一个合并后的高斯项中通过重新分配权值的方法来获得具有不同标记的估计值是不可能的。因此必须记录每个高斯项所带有的标记以及隐藏的标记，对于隐藏多个标记的高斯项，跳过对其权值的惩罚归一化处理。

CPHD 滤波器随时间传递的不仅是目标状态的后验似然函数，同时还有后验势密度即目标数目的概率质量函数。CPHD 放松了 PHD 中对多目标状态集合是泊松分布的限制，可以获得关于多目标状态集合势分布更多更充分的信息，因此估计精度更高。由于 GM-CPHD 滤波算法可以较好的适应虚警、漏检和近距离目标的多目标跟踪情况，算法优势较为突出。因此改进算法的思想是将合作惩罚权值的思想引入 CPHD 并与标记高斯项方法相结合为标记 CP-CPHD，能够更加准确地估计目标状态并关联航迹。

GM-CPCPHD 的算法步骤如下：

预测：

假设 $k-1$ 时刻的目标随机集后验强度函数为 v_{k-1} ，目标随机集后验势分布为 ρ_{k-1} ，并且后验强度函数可以表示成高斯混合的形式，即：

$$v_{k-1}(\mathbf{x}) = \sum_{i=1}^{J_{k-1}} w_{k-1}^i N(\mathbf{x}; \mathbf{m}_{k-1}^i, \mathbf{P}_{k-1}^i) \quad (3-34)$$

那么预测的强度函数仍然是高斯混合的形式，

$$v_{k|k-1}(\mathbf{x}) = v_{S,k|k-1}(\mathbf{x}) + \gamma_k(\mathbf{x}) \quad (3-35)$$

预测的目标势分布为：

$$\rho_{k|k-1} = \sum_{j=0}^n \rho_{\Gamma,k}(n-j) \sum_{l=j}^{\infty} C_j^l \rho_{k-1}(l) p_{S,k}^j (1-p_{S,k})^{l-j} \quad (3-36)$$

更新：

假设 k 时刻的目标随机集预测强度函数为 $v_{k|k-1}$ ，目标随机集预测势分布为

$\rho_{k|k-1}$ ，若预测的强度函数 $v_{k|k-1}$ 可以表示成高斯混合的形式，即

$$v_{k|k-1}(\mathbf{x}) = \sum_{i=1}^{J_{k|k-1}} w_{k|k-1}^i N(\mathbf{x}; \mathbf{m}_{k|k-1}^i, \mathbf{P}_{k|k-1}^i) \quad (3-37)$$

那么 k 时刻的目标随机集后验强度函数仍然是高斯混合的形式，

$$\begin{aligned} v_k(\mathbf{x}) = & (1 - p_{D,k}) \frac{\langle \Psi_k^1[w_{k|k-1}, Z_k], \rho_{k|k-1} \rangle}{\langle \Psi_k^0[w_{k|k-1}, Z_k], \rho_{k|k-1} \rangle} v_{k|k-1}(\mathbf{x}) \\ & + \sum_{\mathbf{z} \in Z_k} \sum_{j=1}^{J_{k|k-1}} w_k^j(\mathbf{z}) N(\mathbf{x}; m_k^j(\mathbf{z}), P_k^j) \end{aligned} \quad (3-38)$$

预测的目标势分布为：

$$\rho_k(n) = \frac{\Psi_k^0[w_{k|k-1}, Z_k](n) \rho_{k|k-1}(n)}{\langle \Psi_k^0[w_{k|k-1}, Z_k], \rho_{k|k-1} \rangle} \quad (3-39)$$

其中，

$$\Psi_k^u[w, Z](n) = \sum_{j=0}^{\min(|Z|, n)} (|Z| - j)! \rho_{\kappa, k}(|Z| - j) P_{j+u}^n \times \frac{\langle 1 - p_{D,k}, w \rangle^{n-(j+u)}}{\langle 1, w \rangle^{j+u}} e_j(\Xi_k(w, Z)) \quad (3-40)$$

$$\Xi_k(w, Z) = \left\{ \frac{\langle 1, \kappa_k \rangle}{\kappa_k(\mathbf{z})} p_{D,k} w^T q_k(\mathbf{z}); \mathbf{z} \in Z \right\} \quad (3-41)$$

$$w_{k|k-1} = \left[w_{k|k-1}^1, \dots, w_{k|k-1}^{J_{k|k-1}} \right]^T \quad (3-42)$$

$$q_k(\mathbf{z}) = \left[q_k^1(\mathbf{z}), \dots, q_k^{J_{k|k-1}}(\mathbf{z}) \right]^T \quad (3-43)$$

$$q_k^j(\mathbf{z}) = N(\mathbf{z}; \mathbf{H}_k \mathbf{m}_{k|k-1}^j, \mathbf{R}_k + \mathbf{H}_k \mathbf{P}_{k|k-1}^j \mathbf{H}_k^T) \quad (3-44)$$

$$w_k^j(\mathbf{z}) = p_{D,k} w_{k|k-1}^j q_k^j(\mathbf{z}) \frac{\langle \Psi_k^1[w_{k|k-1}, Z_k \setminus \{\mathbf{z}\}], \rho_{k|k-1} \rangle}{\langle \Psi_k^0[w_{k|k-1}, Z_k], \rho_{k|k-1} \rangle} \quad (3-45)$$

$$\mathbf{m}_{k|k}^j(\mathbf{z}) = \mathbf{m}_{k|k-1}^j + \mathbf{K}_k^j (\mathbf{z} - \mathbf{H}_k \mathbf{m}_{k|k-1}^j) \quad (3-46)$$

$$\mathbf{P}_{k|k}^j = [\mathbf{I} - \mathbf{K}_k^j \mathbf{H}_k] \mathbf{P}_{k|k-1}^j \quad (3-47)$$

$$\mathbf{K}_k^j = \mathbf{P}_{k|k-1}^j (\mathbf{H}_k)^T (\mathbf{H}_k \mathbf{P}_{k|k-1}^j (\mathbf{H}_k)^T + \mathbf{R}_k)^{-1} \quad (3-48)$$

其它对高斯项分配标记步骤、重新分配权值步骤、剪枝合并高斯项等步骤均与 CP-GMPHD 相同。

3.5 仿真实验及分析

为了验证改进算法的性能，给出了多次蒙特卡罗实验下标记的三种算法 CPGM-CPHD、CPGM-PHD 与 GM-PHD 的性能比较。

首先设定一个二维平面场景，目标在观测区域 $[-100,100] \times [-100,100]$ 内运动，随时会有新生目标出现和目标的消失并且伴随目标的漏检与杂波干扰，目标个数是随时间变化且未知的。目标运动满足线性高斯模型，

$$\mathbf{x}_k = \begin{bmatrix} 1 & T & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & T \\ 0 & 0 & 0 & 1 \end{bmatrix} \mathbf{x}_{k-1} + \begin{bmatrix} T^2/2 & 0 \\ T & 0 \\ 0 & T^2/2 \\ 0 & T \end{bmatrix} \begin{bmatrix} q_{1,k} \\ q_{2,k} \end{bmatrix} \quad (3-49)$$

其中目标状态 $\mathbf{x}_k = [x, \dot{x}, y, \dot{y}]^T$ ， $[x, y]^T$ 和 $[\dot{x}, \dot{y}]^T$ 分别代表目标在 k 时刻的位置和速度，过程噪声 $q_{1,k}$ 和 $q_{2,k}$ 是标准差分别为 0.5 和 0.1 的独立零均值高斯噪声。目标在 k 时刻的存活概率 $p_{S,k} = 0.99$ 并且状态独立，采样的时间间隔为 $T = 1\text{s}$ ，测量时间为 40s。

假设新生目标的泊松有限集强度函数为

$$\gamma_k(\mathbf{x}) = \sum_{i=1}^3 0.1 N(\mathbf{x}; \mathbf{m}_\gamma^{(i)}, \mathbf{P}_\gamma) \quad (3-50)$$

其中， $\mathbf{P}_\gamma = \text{diag}([5, 1, 5, 1]^T)$ ， $\mathbf{m}_\gamma^{(i)}$ 将在不同目标场景给出。

量测矩阵为

$$\mathbf{H}_k = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \quad (3-51)$$

量测噪声协方差

$$\mathbf{R}_k = \sigma_w^2 \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad (3-52)$$

其中量测噪声标准差 $\sigma_w = 0.5$ ， k 时刻传感器的检测概率为 $p_{D,k} = 0.98$ 且状态独立。杂波在观测空间是均匀分布的，杂波强度为 $\lambda = 2$ ，最大高斯分量数 $J_{\max} = 100$ ，进行 50 次蒙特卡罗实验。

设定有三个目标，作相互交叉运动，初始时刻只有一个目标，其它两个目标均为新生目标， $\mathbf{m}_0 = [5, 0, 0, 0]^T$ ， $\mathbf{m}_\gamma^{(1)} = [30, 0, -35, 0]^T$ ， $\mathbf{m}_\gamma^{(2)} = [55, 0, -50, 0]^T$

目标 1 初始时刻已经存在，第 $k = 30$ 时刻消失，目标 2 在第 $k = 5$ 时刻新生，目标 3 在第 $k = 10$ 时刻新生，三个目标在 $k = 20$ 时刻同时交叉。仿真结果如图 3.2~图 3.7 所示。




图 3.2 目标数目估计




图 3.3 OSPA 距离比较




图 3.4 目标真实运动轨迹




图 3.5 标记 PHD 法航迹估计

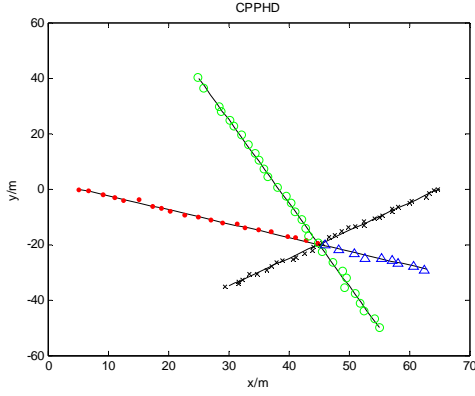


图 3.6 标记 CP-PHD 法航迹估计

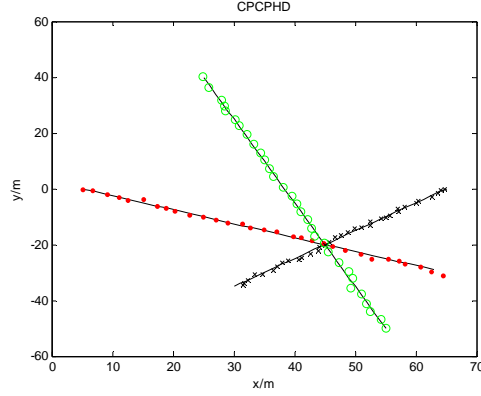


图 3.7 标记 CP-CPHD 法航迹估计

图 3.2 是标记条件下 PHD、CP-PHD、CP-CPHD 三种算法 50 次蒙特卡罗实验下的目标数目估计结果。图 3.3 分别为三种滤波器目标估计的 OSPA 距离。观测区域内目标的真实轨迹如图 3.4 所示，图 3.5 为标记 PHD 算法估计的目标航迹仿真实验结果，图 3.6 为标记 CP-PHD 算法估计的目标航迹仿真实验结果，图 3.7 为标记 CP-CPHD 算法估计的目标航迹仿真实验结果，可以看出，在多个目标很靠近时，由于标记 PHD 中高斯项的剪枝合并等操作使得靠近目标提取的状态不准确，导致航迹错误，而 CP-PHD 性能有所提高，但仍然不能完全正确区分目标，标记 CP-CPHD 其估计的目标状态 OSPA 距离平均最小，位置数目更为准确因此关联性能最好。仿真结果表明，改进的标记 CP-CPHD 算法航迹维持性能较其他两种算法好。


实验 2

为了进一步验证本文中航迹关联算法的性能，进行了多次不同环境下重复 100 次蒙特卡罗实验取均值，采用正确关联率(the normalized correct associations, NCA)和错误关联比 (the incorrect-to-correct association ratio, ICAR)^[47]来衡量目标的航迹关联性能，根据定义，正确关联率和错误关联比分别如下：

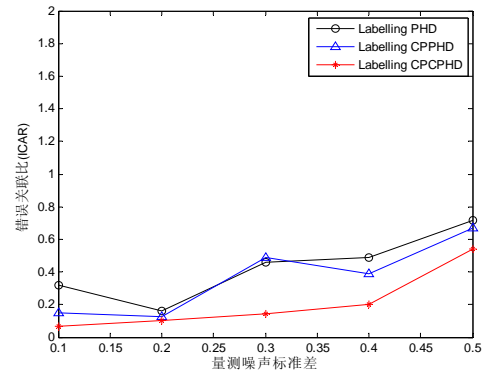
$$NCA(\omega) = \frac{|CA(\omega)|}{|SA(\omega^*)|} \quad (3-53)$$

$$ICAR(\omega) = \frac{|SA(\omega)| - |CA(\omega)|}{|CA(\omega)|} \quad (3-54)$$

其中 $SA(\omega)$ 表示可行性事件的所有关联集合， $CA(\omega)$ 表示正确关联的集合， ω^* 表示不含杂波的关联事件。




(A) 正确关联率 NCA

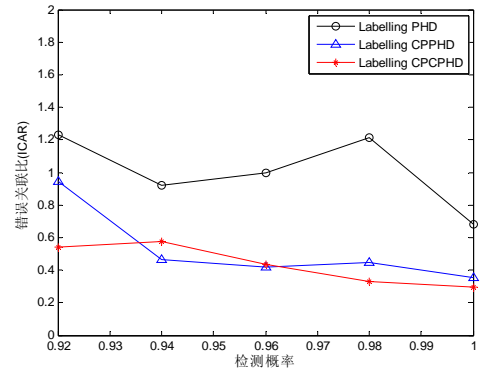


(B) 错误关联比 ICAR

图 3.8 随量测噪声变化的关联性能仿真结果



(A) 正确关联率 NCA



(B) 错误关联比 ICAR

图 3.9 随检测概率变化的关联性能仿真结果

图 3.8 和图 3.9 分别给出了量测噪声变化和检测概率变化情况下标记 PHD、CP-PHD、CP-CPHD 三种算法关联性能的比较, 均为 100 次蒙特卡罗实验的结果。图 3.8(A)为随着量测噪声标准差的增加正确关联率的变化对比情况, 图 3.8(B)为随着量测噪声标准差的增加错误关联比的变化对比情况, 可以看出随着量测噪声的增加, 三种算法的正确关联率略有下降, 但是改进的 CP-CPHD 仍然高于其它两种算法。图 3.9(A)为随着检测概率的增加三种算法正确关联率的变化对比情况, 图 3.9(B)为随着检测概率的增加三种算法错误关联比的变化对比情况, 仿真结果可以看到随着检测概率的增大算法的正确关联率也随之升高。实验结果表明, 本文提出的改进标记 CP-CPHD 算法具有较强的抗干扰能力和鲁棒性, 提高了多个航迹的正确关联率, 与标记 PHD 算法和标记 CP-PHD 算法相比, 提出的改进算法性能较优于原有算法。

3.6 本章小结

本章主要研究的是基于随机集的标记目标航迹关联问题，首先简要介绍了标记 GM-PHD 以及标记粒子 PHD 滤波器，针对多目标相距较近时代表目标的不同高斯项被量测更新后会产生状态提取不准确的问题，提出了一种合作惩罚 PHD 算法，通过对空间靠近的高斯项重新分配权值并归一化，改善了多目标靠近时目标容易被标记错误的问题。在此基础上，本文将合作惩罚的思想引入 CPHD 滤波器中，提高了目标关联的准确性。

第四章 基于随机集滤波的航迹关联算法

4.1 引言

上一章提到的标记粒子 PHD 滤波中由于重采样和聚类等操作导致代表不同目标的粒子的标记比例失衡，从而造成不同的目标带有相同的标记。基于标记 GM-PHD 的目标航迹关联方法，虽然可以在滤波过程中通过加标记的方法得到目标的航迹，但是在多个目标相互靠近的情况下，由于高斯混合 PHD 滤波中存在修剪合并等操作，导致相近的多个不同标记的高斯项被合并为一项，从而使得目标无法正确关联。

针对基于随机集滤波再进行航迹关联的问题，国内外很多学者对此作了不少研究^[48]。Panta 等将 PHD 的滤波结果通过多假设跟踪（MHT）等传统数据关联滤波器进行关联，计算比较复杂。预测关联法直接将标记粒子 PHD 滤波器的滤波结果当作正确真实的目标数目和状态进行关联，一旦目标数目估计错误就会导致最终航迹的错误。混合滤波算法将 MHT 和 GM-CPHD 滤波相结合，需要用到传统的多假设跟踪进行处理，算法复杂度较高。航迹关联方法（Track association, TA）^[49]利用关联矩阵和概率矩阵对滤波后的状态进行处理，航迹关联性能较好，但是只能在少量目标相近时正确关联，一旦多个目标同时交叉或者相距很近时就容易产生错误关联。针对这一问题，本文提出了一种改进的航迹关联方法（Improved Track association, ITA），核心思想是提出并构造距离矩阵，距离矩阵描述了每个时刻存在的所有目标相互之间的位置关系，从而有针对性的对多个目标在同一时刻距离很近的情况进行相应处理，有效解决了多个空间相近目标航迹易关联错误的问题，提高了航迹的正确关联率。为此本章从滤波后再进行数据关联的角度对航迹关联问题做了深入研究。

4.2 基于标记 particle-PHD 的预测关联算法

4.2.1 标记预测关联算法

在标记 Particle-PHD 滤波算法的每一步中，目标状态估计都是通过计算粒子聚类后的均值得到的。标记预测关联算法就是利用每一步估计出的目标状态，并根据目标运动模型推出前一时刻目标状态在当前时刻的预测估计值，从两者之间寻找最优的关联，维持每个目标航迹的连续性。预测标记关联算法^[16]流程如下：

假设粒子 PHD 滤波算法中 k 时刻通过聚类运算已经得到目标的状态及协方差矩阵，分别为 $\{\hat{\mathbf{x}}_{k,1}, \dots, \hat{\mathbf{x}}_{k,\hat{T}_k}\}$ $\{\mathbf{S}_{k,1}, \dots, \mathbf{S}_{k,\hat{T}_k}\}$ ，定义一个有效域 V ：

$$V_{k,i}(\gamma) = \left\{ \mathbf{x} : [\mathbf{x} - \hat{\mathbf{x}}_{k,i}]^T (\mathbf{S}_{k,i})^{-1} [\mathbf{x} - \hat{\mathbf{x}}_{k,i}] \leq \gamma \right\} \quad (4-1)$$

在没有对量测更新前先对前一时刻的目标估计状态预测：

$$\hat{\mathbf{x}}_{k|k-1,j} = \mathbf{F} \hat{\mathbf{x}}_{k-1,j} \quad (4-2)$$

则预测随机集为 $\{\hat{\mathbf{x}}_{k|k-1,1}, \dots, \hat{\mathbf{x}}_{k|k-1,\hat{T}_{k-1}}\}$ 。

假设 $\hat{B}_{k|k-1}$ 是 $k-1$ 时刻到 k 时刻的关联数目，这里假设 PHD 滤波已经滤除了所有杂波，提取的目标状态被当作真实目标，且每一个目标只对应一种关联。显然存在 $\hat{B}_{k|k-1} \leq \min(\hat{T}_{k|k-1}, \hat{T}_k)$ ，新生的目标数即为 $\hat{T}_k - \hat{B}_{k|k-1}$ ，计算 β_k ，它是预测随机集 $\{\hat{\mathbf{x}}_{k|k-1,1}, \dots, \hat{\mathbf{x}}_{k|k-1,\hat{T}_{k-1}}\}$ 和状态随机集 $\{\hat{\mathbf{x}}_{k,1}, \dots, \hat{\mathbf{x}}_{k,\hat{T}_k}\}$ 之间一对一有效关联的集合。在 β_k 中找出最优关联 $b_k \in \beta_k$ ，并有：

$$b_k = \arg \max_{b \in \beta_k} \sum_b \exp \left\{ -1/2 \left(\hat{\mathbf{x}}_{k,i} - \hat{\mathbf{x}}_{k|k-1,j} \right)^T (\mathbf{S}_{k,i})^{-1} \left(\hat{\mathbf{x}}_{k,i} - \hat{\mathbf{x}}_{k|k-1,j} \right) \right\} \quad (4-3)$$

对于没有关联的目标状态，起始新航迹。给它们分配新的标记：

$$\{\mathbf{x}_k^{n_1}, \dots, \mathbf{x}_k^{n_k}\} \leftrightarrow \{L_k^{n_1}, \dots, L_k^{n_k}\} \quad (4-4)$$

关联步骤的目标就是将不同时刻的目标状态联系起来从而使每个目标航迹维持。由于这里的关联不包含量测，只是目标的估计位置，因此估计位置会比量测更准确，属于杂波的虚假量测也已经被滤波器滤除，同时估计出的目标状态含有速度维等不可观测信息，允许在量测位置靠近但是速度不同的情况下更好的区分目标。

4.2.2 改进算法

上一小节介绍的预测标记关联法是直接在 particle-PHD 滤波的基础上对目标航迹进行关联的，减少了大量杂波的干扰，因此计算量较小，关联性能较好。缺点是预测关联法的关联有效门限是通过协方差矩阵确定的，因此在目标密度较大时易使目标航迹偏离原目标，估计误差显著增大，导致航迹关联性能降低。尤其是粒子 PHD 滤波中存在重采样和聚类过程，因此目标状态估计不准确，同样会影响目标航迹的正确关联。针对此问题，本文提出了一种改进算法，将文献^[50]中提出的状态提取方法应用于标记预测关联算法中，不但在密集目标情况下提高了

目标状态估计精度，而且比原算法能更准确的关联目标航迹。

基于标记的 particle-PHD 前面已经介绍过，此处不再赘述。改进算法是在此基础上进行的，具体算法流程如下：

步骤 1：首先在滤波过程的预测步骤与标记 particle-PHD 相同。

步骤 2：在更新步骤中，由传感器获得新的量测值后，利用似然函数 $g(\mathbf{z}|\mathbf{x})$ 更新粒子权值：

$$\tilde{w}_k^i = \left[v(\tilde{\mathbf{x}}_k^i) + \sum_{\mathbf{z} \in Z_k} \frac{\psi_{k,z}(\tilde{\mathbf{x}}_k^i)}{\kappa_k(\mathbf{z}) + C_k(\mathbf{z})} \right] \tilde{w}_{k|k-1}^i \quad (4-5)$$

其中

$$C_k(\mathbf{z}) = \sum_{i=1}^{R_k} \psi_{k,z}(\tilde{\mathbf{x}}_k^i) \tilde{w}_{k|k-1}^i = \sum_{i=1}^{R_k} u_k(\tilde{\mathbf{x}}_k^i, \mathbf{z}), \forall \mathbf{z} \in Z_k \quad (4-6)$$

$$u_k(\tilde{\mathbf{x}}_k^i, \mathbf{z}) = \psi_{k,z}(\tilde{\mathbf{x}}_k^i) \tilde{w}_{k|k-1}^i \quad (4-7)$$

其中 $u_k(\tilde{\mathbf{x}}_k^i, \mathbf{z})$ 是每个粒子对于不同量测的似然函数。

步骤 3： k 时刻粒子可以用 $\{\tilde{\mathbf{x}}_k^i, \tilde{w}_k^i, \tau_k^i\}_{i=1}^{R_k}$ 来描述， τ_k^i 是粒子所带的标记，将所有粒子根据不同标记分为不同的粒子类，相同标记的粒子被分到同一类中。此时所有粒子被分为 $N_{G,k}$ 个粒子类，表示为：

$$\{G_k^n, \tau_{G,k}^n\}_{n=1}^{N_{G,k}}, G_k^n = \{\tilde{\mathbf{x}}_k^i | \tau_k^i = \tau_{G,k}^n, i=1, \dots, M_{G_n}\} \quad (4-8)$$

其中， $\tau_{G,k}^n$ 是粒子类的类标记， M_{G_n} 是粒子类 G_k^n 中的粒子数目。

步骤 4：对于量测集中的每个量测 $\mathbf{z} \in Z_k$ ，分别计算每个粒子类 $G_k^n (n=1, \dots, N_{G,k})$ 对不同量测的似然和：

$$S_{k,\mathbf{z}_j}^n = \sum_{\tilde{\mathbf{x}}_k^i \in G_k^n} u_k(\tilde{\mathbf{x}}_k^i, \mathbf{z}_j), \mathbf{z}_j \in Z_k \quad (4-9)$$

$$S_{k,\mathbf{z}_j}^n = \max_{\mathbf{z}_j \in Z_k} \{S_{k,\mathbf{z}_j}^n\} \quad (4-10)$$

$$\mathbf{z}_{n^*} = \arg \max_{\mathbf{z}_j \in Z_k} \{S_{k,\mathbf{z}_j}^n\} \quad (4-11)$$

同时计算出似然和最大值 $S_{k,\mathbf{z}_{n^*}}^n$ 。

步骤 5：重复步骤 4 计算所有粒子类 $G_k^n (n=1, \dots, N_{G,k})$ 的最大似然之和 $S_{k,\mathbf{z}_{n^*}}^n$ 。

得到对应的粒子集 $\{\tilde{\mathbf{x}}_k^i, u_k(\tilde{\mathbf{x}}_k^i, \mathbf{z}_{n'}) | \tilde{\mathbf{x}}_k^i \in G_k^n\}$ ，对所有粒子集的最大似然度之和进行从大到小排列：

$$\tilde{S}_{k,S_1}^{S_1} \geq \tilde{S}_{k,S_2}^{S_2} \geq \dots \geq \tilde{S}_{k,S_{N_{G,k}}}^{S_{N_{G,k}}} \quad (4-12)$$

假设目标数目估计个数为 N_k ，则取上述最大似然度排列中的前 N_k 个最大值，其对应的粒子集为

$$\{\tilde{\mathbf{x}}_k^i, u_k(\tilde{\mathbf{x}}_k^i, \mathbf{z}_{S_j}) | \tilde{\mathbf{x}}_k^i \in G_k^{S_j}\}_{j=1, \dots, N_k} \quad (4-13)$$

步骤 6：目标状态通过上述的粒子集及其对应的似然度计算：

$$\hat{\mathbf{x}}_{k,j} = \frac{\sum_{\tilde{\mathbf{x}}_k^i \in G_k^{S_j}} \tilde{\mathbf{x}}_k^i u_k(\tilde{\mathbf{x}}_k^i, \mathbf{z}_{S_j})}{\sum_{\tilde{\mathbf{x}}_k^i \in G_k^{S_j}} u_k(\tilde{\mathbf{x}}_k^i, \mathbf{z}_{S_j})}, j=1, \dots, N_k \quad (4-14)$$

步骤 7：得到目标状态后计算目标协方差矩阵，再用标记预测关联法关联目标航迹。

4.2.3 仿真实验及分析

假设目标在二维观测区域 $[-100, 100] \times [-100, 100]$ 内运动，目标个数是随时间变化且未知的。设定有三个目标，作相互交叉运动，初始时刻只有一个目标，其它两个目标均为新生目标，目标 1 初始时刻已经存在，第 $k=30$ 时刻消失，目标 2 在第 $k=5$ 时刻新生，目标 3 在第 $k=10$ 时刻新生，三个目标在 $k=20$ 时刻同时交叉。

目标运动方程为：

$$\mathbf{x}_k = \mathbf{F}\mathbf{x}_{k-1} + \mathbf{G}\mathbf{w}_k \quad (4-15)$$

目标观测方程为：

$$\mathbf{z}_k^i = \arctan\left(\frac{y_k - y_{S_i}}{x_k - x_{S_i}}\right) + \mathbf{v}_k^i \quad (4-16)$$

$$\text{其中, } \mathbf{F} = \begin{bmatrix} 1 & T & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & T \\ 0 & 0 & 0 & 1 \end{bmatrix}, \mathbf{G} = \begin{bmatrix} T^2/2 & 0 \\ T & 0 \\ 0 & T^2/2 \\ 0 & T \end{bmatrix}$$

目标状态 $\mathbf{x}_k = [x, \dot{x}, y, \dot{y}]^T$ ， $[x, y]^T$ 和 $[\dot{x}, \dot{y}]^T$ 分别代表目标在 k 时刻的位置和速

度，过程噪声 \mathbf{w}_k 是标准差为 0.5 的独立零均值高斯噪声。 \mathbf{v}_k 是量测噪声，其中量测噪声标准差 $\sigma_w = 0.5$ 。 (x_{S_i}, y_{S_i}) 为第 i 个观测站的位置。 $\mathbf{P}_\gamma = \text{diag}([5, 1, 5, 1]^T)$ ， $\mathbf{m}_0 = [5, 0, 0, 0]^T$ ， $\mathbf{m}_\gamma^{(1)} = [30, 0, -35, 0]^T$ ， $\mathbf{m}_\gamma^{(2)} = [55, 0, -50, 0]^T$ ，实验中采用三个位置分别为 $S_1(0\text{m}, -50\text{m})$ ， $S_2(40\text{m}, 30\text{m})$ 和 $S_3(80\text{m}, -50\text{m})$ 的观测站对目标进行独立观测。传感器的检测概率为 $p_{D,k} = 0.98$ 。目标存活概率 $p_{S,k} = 0.99$ ，杂波在观测空间是均匀分布的，杂波强度为 $\lambda = 2$ ，采样的时间间隔为 $T = 1\text{s}$ ，测量时间为 40s。进行 50 次蒙特卡罗实验，仿真结果如图 4.1~图 4.4 所示。

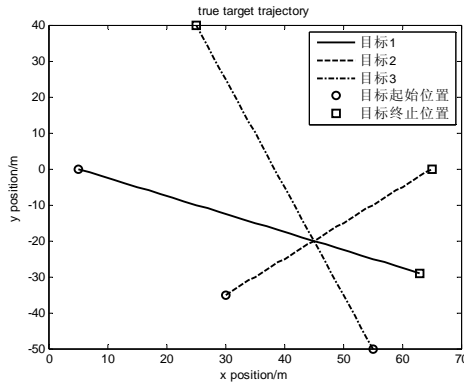


图 4.1 目标真实运动轨迹




图 4.2 两种算法 OSPA 距离对比




图 4.3 基于 k-means 聚类的航迹关联




图 4.4 基于改进聚类的航迹关联

图 4.1 是目标在观测区域中的真实运动轨迹。图 4.2 为基于 k-means 聚类提取的目标状态与改进算法提取的目标状态 OSPA 距离对比。图 4.3 为基于 k-means 聚类的航迹仿真结果，图 4.4 为改进聚类的航迹关联仿真结果。可以看出，两种算法在目标交叉或靠近时 OSPA 距离相差最大，尤其是在目标密集时改进算法提取的目标状态精度更高。两种算法在估计出相同目标数目的前提下，不同的目标提取方法下得到的目标航迹也不同。仿真结果表明，改进聚类的目标航迹关联方法

性能优于原算法。

4.3 基于高斯混合 PHD 的航迹关联算法

4.3.1 航迹关联算法

GM-PHD 滤波之前已经介绍过, 采用 GM-PHD 滤波器进行预滤波, 剔除了原始观测中的大量虚警和杂波, 因此滤波后的目标状态可以作为“伪量测”再进行航迹关联, 由于“伪量测”保留了原始观测的形式, 并且滤波的结果也接近真实的目标数目和目标状态, 因此很大程度的减少了后续数据关联的计算量。

假设 k 时刻滤波估计的“伪量测”数目为 m_d , 到 k 时刻仍然存在的航迹数目为 n_d , 若第 j 个“伪量测”落入第 i 条航迹预测的一定门限内, 那么第 j 个“伪量测”就作为第 i 条航迹的关联备选。航迹关联算法的主要思想是将落入航迹的预测门限内的备选“伪量测”关联到该航迹, 若有多个备选“伪量测”落入同一门限内, 再通过概率矩阵等分情况处理进行后续的关联。

1) 初始化

首先进行初始化, 我们通过目标的均值 \mathbf{m}_{k-1}^i 、协方差 \mathbf{P}_{k-1}^i 、权值 w_{k-1}^i 以及航迹得分 l_{k-1}^i 直接作为起始航迹信息来进行关联计算, 其中 i 代表第 i 个目标的航迹, 同时航迹的初始得分可利用下式进行计算:

$$l_{k-1}^i = \ln(1 + w_{k-1}^i) \quad (4-17)$$

对于已存在目标航迹的预测可根据以下的公式得到:

$$\hat{\mathbf{x}}_{k|k-1}^i = \mathbf{F}_{k-1} \hat{\mathbf{x}}_{k-1}^i \quad (4-18)$$

$$\mathbf{P}_{k|k-1}^i = \mathbf{F}_{k-1} \mathbf{P}_{k-1}^i (\mathbf{F}_{k-1})^T + \mathbf{Q}_{k-1} \quad (4-19)$$

$$w_{k|k-1}^i = w_{k-1}^i \quad (4-20)$$

$$l_{k|k-1}^i = l_{k-1}^i \quad (4-21)$$

2) 构造矩阵

已知 k 时刻的滤波估计的“伪量测”为 $\hat{\mathbf{m}}_k^j (j=1, \dots, m_d)$, 当前时刻存在的第 i 条航迹的预测值为 $\hat{\mathbf{x}}_{k|k-1}^i (i=1, \dots, n_d)$, 两者的统计距离为:

$$d_{i,j}^2 = (\hat{\mathbf{x}}_{k|k-1}^i - \hat{\mathbf{m}}_k^j)^T [\mathbf{P}_{k|k-1}^i]^{-1} (\hat{\mathbf{x}}_{k|k-1}^i - \hat{\mathbf{m}}_k^j) \quad (4-22)$$

由上式可知，“伪量测”与航迹预测状态距离越近，两者的统计距离越小。为了进行目标航迹与状态的关联，航迹关联算法^[16]构造了关联矩阵 M_a （维数为 $n_d \times m_d$ ）和概率矩阵 M_p （维数为 $n_d \times m_d$ ），其中关联矩阵 M_a 和概率矩阵 M_p 分别为：

$$M_a(i, j) = \begin{cases} 1, & d_{i,j} \leq G \\ 0, & d_{i,j} > G \end{cases} \quad (4-23)$$

$$M_p(i, j) = \begin{cases} \frac{e^{-d_{i,j}^2/2}}{\sqrt{|2\pi P_{k|k-1}^i|}}, & d_{i,j} \leq G \\ 0, & d_{i,j} > G \end{cases} \quad (4-24)$$

其中 G 代表椭圆门限^[51]。

3) 对矩阵的处理

对关联矩阵 M_a 每一行处理，对于行处理有三种情况：

$$\text{a) } \sum_{j=1}^{m_d} M_a(i, j) = 0$$

当前时刻目标 i 没有检测到，需要利用上面的公式(4-18)~(4-21)对其进行外推，同时漏检计数器 n_{miss} 加 1，当连续漏检次数超过预设门限值(2 次及以上)时说明目标已经消亡，对航迹进行终结。

$$\text{b) } \sum_{j=1}^{m_d} M_a(i, j) = 1$$

当前时刻目标 i 只有一个备选量测，若此时这个量测没有落入其它目标航迹的预测门限内，则将此量测直接关联给目标 i ，否则按 c) 进行处理。

$$\text{c) } \sum_{j=1}^{m_d} M_a(i, j) > 1$$

当前时刻目标 i 有多个备选量测，将哪个量测关联到航迹并不能直接决定，需要分别将 M_a 和 M_p 的第 i 行复制到新矩阵 $M_{s,a}$ 和 $M_{s,p}$ 中，然后对新生成的矩阵进行后续处理。

其次，对关联矩阵列处理，若存在关联矩阵的列和为 0，即 $\sum_{i=1}^{n_d} M_a(i, j) = 0$ ，

则起始新航迹。

最后，若矩阵 $M_{s,a}$ 和 $M_{s,p}$ 非空，我们还需进行多个备选“伪量测”对航迹的分配关联，假设其维数均为 $n_{d,s} \times m_{d,s}$ ，对矩阵 $M_{s,a}$ 和 $M_{s,p}$ 的处理如下：

若 $\sum_{i=1}^{n_{d,s}} M_{s,a}(i, j) = 0$ ，则删除 $M_{s,a}$ 和 $M_{s,p}$ 的对应列，即剩下的航迹均与第 j 个“伪量测”无关。

若 $\sum_{i=1}^{n_{d,s}} M_{s,a}(i, j) > 1$ ，第 j 个“伪量测”同时落入多条航迹的预测门限，此时将第 j 个“伪量测”分配给航迹得分最高的目标，其它目标状态使用外推法， k 时刻目标航迹得分为

$$l_k^i = l_{k-1}^i + \Delta l_k^i \quad (4-25)$$

$$\Delta l_k^i = \ln(1 + M_{s,p}(i, j)) \quad (4-26)$$

其中 i 是 $M_{s,a}$ 和 $M_{s,p}$ 的第 i 行， Δl_k^i 为 k 时刻得分增益，若没有量测时 $\Delta l_k^i = 0$ 。若有几条航迹连续 5 帧以上共用同一量测则将多条航迹合并到得分最高的目标。

对于 $M_{s,a}$ ，同样也有以下三种情况：

(1) $n_{d,s} < m_{d,s}$

i 是 $M_{s,a}$ 的第 i 行，目标的状态，协方差，权值及得分按照下式进行计算：

$$\hat{\mathbf{x}}_k^i = \frac{\sum_{j=1}^{m_d} \hat{\mathbf{m}}_k^i M_p(i, j)}{\sum_{j=1}^{m_d} M_p(i, j)} \quad (4-27)$$

$$\mathbf{P}_k^i = \frac{\sum_{j=1}^{m_d} \left[\mathbf{P}_k^j + (\hat{\mathbf{x}}_k^i - \hat{\mathbf{m}}_k^i)^T (\hat{\mathbf{x}}_k^i - \hat{\mathbf{m}}_k^i) \right] M_p(i, j)}{\sum_{j=1}^{m_d} M_p(i, j)} \quad (4-28)$$

$$w_k^{i'} = \frac{\sum_{j=1}^{m_d} w_k^j M_p(i', j)}{\sum_{j=1}^{m_d} M_p(i', j)} \quad (4-29)$$

$$l_k^{i'} = \frac{\sum_{j=1}^{m_d} \Delta l_k^{i',j} M_p(i', j)}{\sum_{j=1}^{m_d} M_p(i', j)} \quad (4-30)$$

$$(2) n_{d,s} = m_{d,s}$$

将落入目标航迹门限内的概率最大的伪量测分配给目标进行关联。

$$(3) n_{d,s} > m_{d,s}$$

未得到分配的航迹根据公式(4-18)~(4-21)进行预测，并关联到对应的目标航迹。

4.3.2 改进的航迹关联算法

航迹的关联是在已有目标航迹预测值与“伪量测”之间距离一定门限内进行的，利用关联矩阵可知存在哪些“伪量测”落入已有航迹的备选，通过概率矩阵即可得到对应“伪量测”关联到落入已有航迹的概率，由于航迹与“伪量测”为一对一关联，因此对所有作为备选的“伪量测”，选取其中的对应概率最大者关联到航迹。在相对复杂的目标场景中，尤其是当多个目标在相距较近甚至交叉运动时，多个“伪量测”会同时落入多条航迹的预测门限内，即“伪量测”与已有航迹之间、已有航迹预测值相互之间、以及“伪量测”相互之间均相距较近，航迹的预测门限相互重叠，导致对应落入各航迹的概率相差不大，即使利用概率矩阵进行分配“伪量测”也很难完全正确关联目标，容易产生错误关联。一旦在相距较近时刻关联错误，后续时刻即使关联正确也会导致整条航迹关联错误，目标航迹关联正确率就会大大下降。

针对上述问题，本文提出了改进的航迹关联算法，在原有算法的基础上进一步构造距离矩阵 M_d （维数为 $n_d \times n_d$ ）。由于滤波的结果接近真实的目标数目和目标状态，因此通过判断“伪量测”之间的位置关系即可看作是目标的位置信息，我们可以构造距离矩阵来识别当前目标位置关系，当存在多个目标在同一时刻相距较近的情况时进行相应的距离矩阵的处理以达到正确关联。距离矩阵的构造如下：

已知 $\{(\hat{\mathbf{m}}_k^1, \mathbf{P}_k^1), (\hat{\mathbf{m}}_k^2, \mathbf{P}_k^2), \dots, (\hat{\mathbf{m}}_k^{n_d}, \mathbf{P}_k^{n_d})\}$ 为 k 时刻滤波后“伪量测”的状态和协方

差，则任意两目标状态的指数距离^[17]为：

$$D_{i,j} = \exp\left\{-(1/2)(\mathbf{H}\hat{\mathbf{m}}_k^j - \mathbf{H}\hat{\mathbf{m}}_k^i)^T (\mathbf{H}^T \mathbf{P}_k^i \mathbf{H})(\mathbf{H}\hat{\mathbf{m}}_k^j - \mathbf{H}\hat{\mathbf{m}}_k^i)\right\} (i, j = 1, \dots, n_d) \quad (4-31)$$

$$M_d(i, j) = \begin{cases} 1, & D_{i,j} \geq \gamma \\ 0, & D_{i,j} < \gamma \end{cases} \quad (4-32)$$

其中 \mathbf{H} 是量测矩阵， γ 是指数距离门限。

由上式(4-31)可知 $D_{i,j}$ 的取值范围在 $(0, 1]$ 区间，两目标相距越近，则指数距离 $D_{i,j}$ 越趋近于 1，相反两目标相距越远， $D_{i,j}$ 越趋近于 0。因此若两目标的指数距离 $D_{i,j}$ 超出预设的距离门限 γ ($0 < \gamma < 1$)，则视为两目标相距较近，距离矩阵 M_d 相应元素置为 1，否则为 0。

此时我们得到了关联矩阵 M_a 、概率矩阵 M_p 以及距离矩阵 M_d 。在对所有矩阵处理之前，首先判断当前时刻是否存在目标的新生与消亡，因此我们先对关联矩阵 M_a 列处理，若 $\sum_{i=1}^{n_d} M_a(i, j) = 0$ ，说明“伪量测” \hat{m}_k^j 并没有落入任何已有航迹的预测门限，存在目标的新生，则起始新的航迹。再对 M_a 每一行处理，若存在 $\sum_{j=1}^{m_d} M_a(i, j) = 0$ ，说明当前时刻目标 i 没有检测到，可能是目标当前时刻的漏检，也可能是目标已消亡，需要利用上面的公式(4-18)~(4-21)对其进行外推，同时漏检计数器 n_{miss} 加 1，当连续漏检次数超过预设门限值(3 次及以上)时说明目标已经消亡，对航迹进行终结。

其次，需要判断目标之间的相互位置关系，对距离矩阵 M_d 的每一行处理：

若 $\sum_{j=1}^{n_d} M_d(i, j) \geq 3$ ，说明当前时刻对于目标 \hat{m}_k^i 而言，空间中有多个目标与之相距很近，此时靠近计数器 n_{close} （初始值为 0）加 1，当 $n_{close} \geq 3$ 时，说明此刻至少三个以上的目标均存在与多个目标相距靠近，在这种目标密集靠近的复杂情况下，由于目标数目相对较多，且目标分布紧密，“伪量测”与航迹预测值非常接近，因此将同一个“伪量测”分配到每个相近目标的概率差别不大，而关联到相邻目标的错误概率却大大增加，如果仍采用原算法通过概率矩阵的概率进行关联往往容易产生关联错误，因此对上述情况我们采用对已经存在的航迹利用公式(4-18)~(4-21)将预测值直接关联到原来的航迹输出，否则视为并不存在多个目标同时靠近的情况，直接进行下面关联矩阵和概率矩阵的处理。

通过以上对关联矩阵、概率矩阵、距离矩阵的处理，可以得到目标的航迹信

息，其原算法与改进算法流程如图 4.5 所示，改进算法的优越性可通过仿真实验进一步说明。




图 4.5 原算法流程图




图 4.6 改进算法流程图

4.3.3 仿真实验及分析

为了验证本文改进航迹关联算法的性能，我们进行下面两组实验，实验 1 验证了不同目标场景下改进航迹关联算法与原航迹关联算法的目标航迹输出结果对比，实验 2 给出了多次蒙特卡罗实验不同杂波强度和检测概率下改进航迹关联算法与原航迹关联算法的关联性能比较。

实验 1

首先设定一个二维平面场景，目标在观测区域 $[-100,100] \times [-100,100]$ 内运动，随时会有新生目标出现和目标的消失并且伴随目标的漏检与杂波干扰，目标个数是随时间变化且未知的。目标运动满足线性高斯模型，

$$\mathbf{x}_k = \begin{bmatrix} 1 & T & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & T \\ 0 & 0 & 0 & 1 \end{bmatrix} \mathbf{x}_{k-1} + \begin{bmatrix} T^2/2 & 0 \\ T & 0 \\ 0 & T^2/2 \\ 0 & T \end{bmatrix} \begin{bmatrix} q_{1,k} \\ q_{2,k} \end{bmatrix} \quad (4-33)$$

其中目标状态 $\mathbf{x}_k = [x, \dot{x}, y, \dot{y}]^T$, $[x, y]^T$ 和 $[\dot{x}, \dot{y}]^T$ 分别代表目标在 k 时刻的位置和速度, 过程噪声 $q_{1,k}$ 和 $q_{2,k}$ 是标准差分别为 0.5 和 0.1 的独立零均值高斯噪声。目标在 k 时刻的存活概率 $p_{s,k} = 0.99$ 并且状态独立, 采样的时间间隔为 $T = 1$, 测量时间为 40s。

假设新生目标的泊松有限集的强度函数为

$$\gamma_k(\mathbf{x}) = \sum_{i=1}^4 0.1 N(\mathbf{x}; \mathbf{m}_\gamma^{(i)}, \mathbf{P}_\gamma) \quad (4-34)$$

其中, $\mathbf{P}_\gamma = \text{diag}([5, 1, 5, 1]^T)$, $\mathbf{m}_\gamma^{(i)}$ 将在不同目标场景给出。

量测矩阵为

$$\mathbf{H}_k = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \quad (4-35)$$

量测噪声协方差

$$\mathbf{R}_k = \sigma_w^2 \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad (4-36)$$

其中量测噪声标准差 $\sigma_w = 0.5$, k 时刻传感器的检测概率为 $p_{D,k} = 0.99$ 且状态独立。杂波在观测空间是均匀分布的, 杂波强度为 $\lambda = 10$, 最大高斯分量数 $J_{\max} = 100$, 椭圆门限为 $G = 50$, 指数距离门限 $\gamma = 0.2$, 进行 100 次蒙特卡罗实验。

以下给出两组不同目标场景, 分别验证改进算法的航迹关联性能。场景 1 验证了多个目标在同一时刻相互交叉运动时改进算法的有效性, 场景 2 验证了多个目标非常靠近时的改进算法的有效性。

场景 1: 仿真实验场景 1 中设定有五个目标, 作相互交叉运动, 初始时刻只有一个目标, 其它四个目标均为新生目标, $\mathbf{m}_0 = [0, 0, -5, 0]^T$,

$$\mathbf{m}_\gamma^{(1)} = [25, 0, -40, 0]^T, \mathbf{m}_\gamma^{(2)} = [52, 0, -49, 0]^T, \mathbf{m}_\gamma^{(3)} = [56, 0, -13, 0]^T, \mathbf{m}_\gamma^{(4)} = [40, 0, -40, 0]^T$$

目标 1 初始时刻已经存在, 第 $k = 35$ 时刻消失, 目标 2 在第 $k = 5$ 时刻新生, 目标 3 在第 $k = 8$ 时刻新生, 目标 4 在第 $k = 12$ 时刻新生, 目标 5 在第 $k = 15$ 时刻新生, 均在 $k = 40$ 时刻消失, 五个目标在 $k = 20$ 时刻同时交叉。仿真结果如图 4.7~图 4.11 所示。

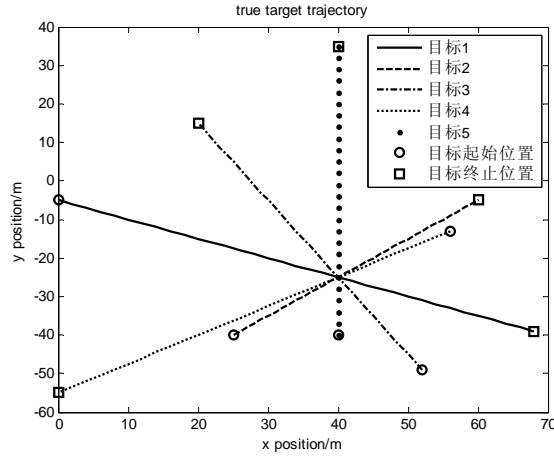


图 4.7 场景 1 目标真实运动轨迹




图 4.8 场景 1 原算法跟踪航迹估计

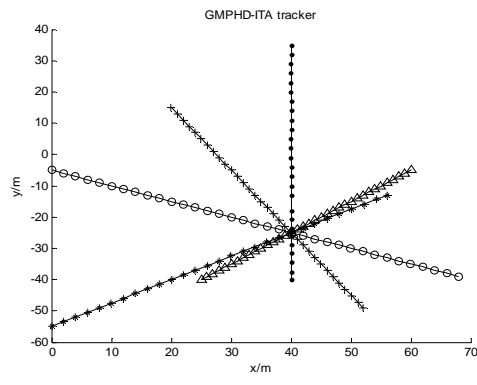


图 4.9 场景 1 改进算法跟踪航迹估计

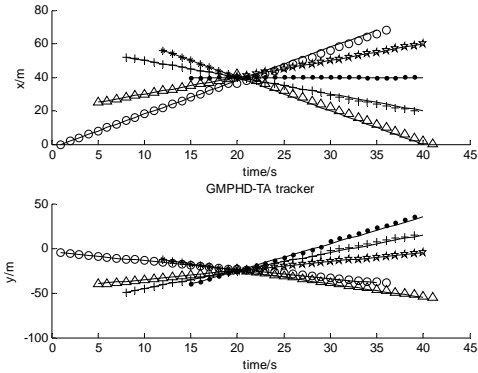


图 4.10 场景 1 原算法 x、y 坐标航迹估计




图 4.11 场景 1 改进算法 x、y 坐标航迹估计

观测区域内场景 1 的目标的真实轨迹如图 4.7 所示，为了验证改进的航迹关联算法性能，与文献^[49]中的算法进行了仿真对比，图 4.8 为文献^[49]中的算法仿真实验结果，图 4.9 为本文改进的算法仿真结果，图 4.10 和图 4.11 分别为目标场景 1 下航迹关联算法与改进算法在 x 和 y 坐标的航迹估计结果，可以看出，在多个目标同时交叉时往往很容易关联错误，原因是各航迹的预测门限相互重叠，并且各“伪

量测”也非常靠近，即使通过计算概率和航迹得分也很难完全正确关联，在靠近时刻由于不同目标航迹得分的细微差距易导致关联到相邻目标，并且当前时刻航迹的预测门限仅与上一时刻关联到航迹的目标状态有关，因此即使后续时刻目标相距较远时关联正确也会导致整条目标航迹的错误。而本文的算法对于上述情况避免了计算关联概率，而直接将存在的航迹预测值关联到原有航迹，不但少了后续计算处理，还能维持原有航迹。由仿真结果看出改进的航迹关联算法具有很好的关联性能，即使对多个交叉目标也能够正确分辨。

场景 2：仿真实验场景 2 中同样设定有五个目标，初始时刻只有一个目标，其它四个目标均为新生目标， $\mathbf{m}_0 = [0, 0, 0, 0]^T$ ， $\mathbf{m}_y^{(1)} = [45, 0, 10, 0]^T$ ， $\mathbf{m}_y^{(2)} = [23, 0, -34, 0]^T$ ， $\mathbf{m}_y^{(3)} = [67, 0, -20, 0]^T$ ， $\mathbf{m}_y^{(4)} = [52, 0, -51, 0]^T$

目标 1 初始时刻已经存在，第 $k = 35$ 时刻消失，目标 2 在第 $k = 3$ 时刻新生，目标 3 在第 $k = 5$ 时刻新生，目标 4 在第 $k = 7$ 时刻新生，目标 5 在第 $k = 9$ 时刻新生，均在 $k = 40$ 时刻消失，五个目标不完全交叉但相互靠近，其中五个目标在 $k = 21$ 时刻在 x 方向相互靠近，其中四个同时交叉，在 y 方向 $k = 20$ 时刻有三个目标交叉，另外两个目标交叉。仿真结果如图 4.12~图 4.16 所示。




图 4.12 场景 2 目标真实运动轨迹




图 4.13 场景 2 原算法跟踪航迹估计

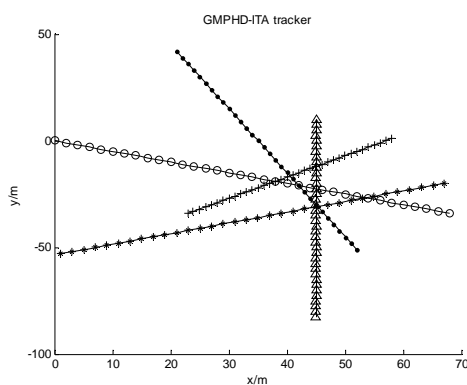


图 4.14 场景 2 改进算法跟踪航迹估计

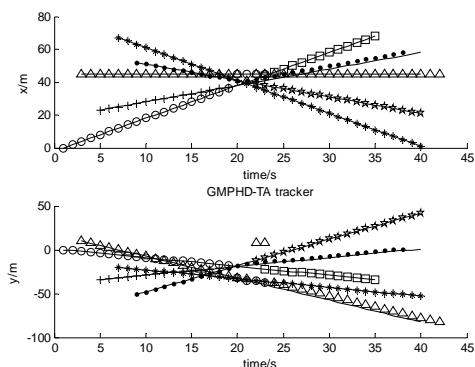


图 4.15 场景 2 原算法 x、y 坐标航迹估计




图 4.16 场景 2 改进算法 x、y 坐标航迹估计

观测区域内场景 2 的目标的真实轨迹如图 4.12 所示, 图 4.13 为文献^[49]中的算法仿真实验结果, 图 4.14 为本文改进的算法仿真结果, 图 4.15 和图 4.16 分别为目标场景 2 下的航迹关联算法与改进算法在 x 和 y 坐标的航迹估计结果, 可以看出, 在多个目标在很靠近时也容易关联错误, 常出现关联到相邻目标的情形, 由于原算法根据选择距离航迹预测概率最大的“伪量测”进行关联, 一旦“伪量测”更靠近邻近目标, 则导致原应关联目标的航迹无法得到正确的关联量测, 从而将预测值进行关联, 几条航迹出现共用同一量测的情形, 若此时关联错误的航迹得分较高, 连续几个时刻之后最终多条航迹合并为一条航迹, 之前的航迹就会被迫终结, 无法完全正确关联, 而改进的航迹关联算法通过对相近多目标直接预测关联因而具有很好的关联性能, 即使对多个目标非常靠近也能够正确分辨。不同目标场景下的仿真结果均表明, 改进的航迹关联算法提供了多个相互靠近甚至交叉目标的连续平滑航迹, 提高了航迹的连续性, 并且航迹维持性能较好。

实验 2

为了进一步验证本文中航迹关联算法的性能, 进行了多次不同环境下重复 100

次蒙特卡罗实验取均值，采用上一章已经定义的正确关联率 NCA 和错误关联比 $ICAR$ 来衡量目标的航迹关联性能，关联性能如下：

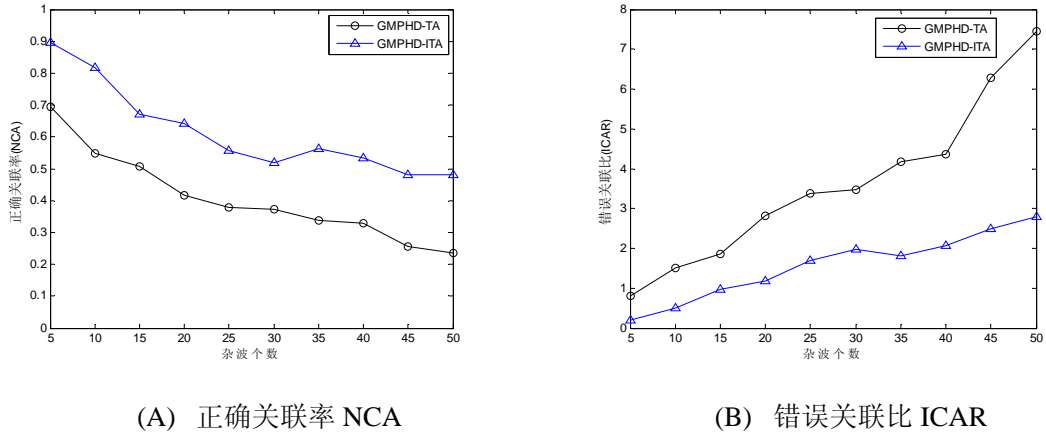


图 4.17 随杂波强度变化的关联性能仿真结果




图 4.18 随检测概率变化的关联性能仿真结果

图 4.17 和图 4.18 分别给出了杂波强度变化和检测概率变化情况下的两种算法之间关联性能的比较，均为 100 次蒙特卡罗实验的结果。图 4.17(A)为随着杂波强度的增加正确关联率的变化对比情况，图 4.17(B)为随着杂波强度的增加错误关联比的变化对比情况，可以看出杂波的增加对于算法的影响相对比较缓慢，主要原因是先采用 **GM-PHD** 滤波器剔除了量测集中的虚警和杂波，把滤波的结果作为“伪量测”再进行航迹关联，由于“伪量测”保留了原始观测的形式，并且由于滤波后的杂波数大大减少，滤波的结果也接近真实的目标数目和目标状态，因此得到的目标航迹维持性能较好，当杂波强度远大于目标强度时，正确关联率略有下降，此时滤波性能对后续航迹关联性能具有较大的影响，但在同样滤波性能的基础上改进的算法正确关联率仍然高于原算法。图 4.18(A)为随着检测概率的增加正确关联率的变化对比情况，图 4.18(B)为随着检测概率的增加两算法错误关联比的变化

对比情况，仿真结果可以看到检测概率不同时对算法的影响比较明显，随着检测概率的增大改进算法的正确关联率也随之升高，相反原算法的正确关联率增幅缓慢，主要原因是当目标均检测到并且距离越近时，越难辨别目标与量测的对应关系，越容易产生错误关联，而改进的算法可以在目标被检测到时能够正确关联。实验结果表明，本文提出的改进算法具有较强的抗干扰能力和鲁棒性，即使在多目标靠近甚至交叉时也能正确关联航迹，提高了多个航迹的正确关联率，就选取正确的目标轨迹及航迹估计而言，提出的改进算法性能优于原航迹关联算法。

4.4 本章小结

本章主要研究基于随机集滤波的多目标估计与航迹关联问题，首先简要介绍了基于标记粒子 PHD 的预测关联法，针对粒子 PHD 提取的目标状态不够准确影响后续关联的问题，提出一种改进的聚类方法并将其与预测关联法相结合，有效改善了关联性能。航迹关联方法将随机集滤波视作一个预滤波器，滤除大量杂波的基础上进行数据关联，针对航迹关联方法中多目标发生交叉或者靠近运动时很难正确关联航迹的问题，也提出了一种改进算法，通过构造距离矩阵并判别目标相互位置关系的基础上进行关联，避免了计算关联概率产生的不确定性，有效提高了航迹的关联性能。

值得注意的是，改进的航迹关联算法中某些门限参数的设定缺乏理论依据，如何根据不同的实际目标场景建立合适的准则进行参数优化是今后需要研究的工作。

第五章 总结与展望

5.1 总结

多目标跟踪一直是工程应用领域研究的热点，也是信息融合领域的重点和难点。伴随科技的迅猛发展，要求更有效的目标跟踪技术完成对杂波环境下变化数目的多目标跟踪及航迹管理。本文在国家自然科学基金项目“复杂环境下多传感器随机集目标跟踪方法研究”和中央高校基本科研业务费项目的资助下，主要展开了随机集理论下多目标航迹关联为主题的研究，在总结国内外学者的科研成果及已有算法的基础上进行了深入且系统的研究，提出了一系列随机集理论下的多目标航迹关联算法，研究成果对军用领域和民用领域都有很重要的应用价值和现实意义，主要研究的工作和成果如下：

(1) 概括了目标跟踪领域中的数据关联算法和非数据关联算法，分析了算法的优缺点和存在问题，以及随机集理论在目标跟踪中的发展趋势。阐述了随机集理论的相关概念以及相关滤波算法，重点介绍了 PHD 和 CPHD 滤波并给出了算法的基本原理和两种不同的实现方法，分析比较了两种算法的优缺点。

(2) 基于标记的目标航迹关联方面：研究了相应的标记 GM-PHD 滤波和标记粒子 PHD 滤波法，以及合作惩罚 PHD (CPGM-PHD) 滤波算法。针对多个目标靠近时状态估计不准确的问题重新分配权值并归一化，并将合作惩罚权值的思想与标记高斯项法相结合，在提高目标位置的估计精度的同时提高了目标航迹的正确关联率。针对 PHD 存在对目标数目不够准确的问题，提出了标记 CP-CPHD 滤波器，将合作惩罚权值的思想应用于标记 CPHD 中，在提高了跟踪性能的基础上也进一步有效提高了航迹关联正确率。

(3) 估计与航迹关联方面：在随机集滤波的基础上对目标估计状态进行航迹关联，分别研究了预测关联法和航迹关联法，针对预测关联法在目标状态精度不够准确时已产生关联错误问题提出了改进，改进算法利用新的目标状态提取方法在目标密度较大时更准确的提取目标状态，改善了目标关联性能。针对已有的航迹关联方法均在密集目标相距较近的情况下容易产生错误关联的问题提出了一种改进算法，通过构造距离矩阵判别目标之间的相互位置关系，当存在目标密集靠近的情况时采用直接预测输出的方法来避免复杂的计算关联，很大程度上提高了多个交叉目标或是空间靠近目标的航迹关联性能。所提算法能够更好地保持目标航迹，具有较强的鲁棒性和航迹维持性能。

5.2 展望

本文基于随机集的多目标跟踪与航迹关联理论研究具有较大的理论和工程应用价值，虽然已经取得了一定的成果，在实际应用中仍存在很多问题，由于课题难度较大，然而本人时间精力十分有限，研究工作还需要今后不断的深入完善。后续研究包括以下几个方面：

(1) 基于随机集的多目标跟踪是最新研究的热点，相关跟踪理论算法都受到一定假设条件的限制，且随机集目标跟踪方法虽然避免了复杂的数据关联，但是只能得到孤立的目标状态，如何有效提取目标的航迹信息还是今后需要深入研究的方向。

(2) 本文提出的标记 CPGM-CPHD 滤波虽然具有较好的航迹关联性能，但是由于 CPHD 存在估计的延迟问题，并且此合作惩罚高斯项算法思想只适用于线性高斯系统，实际中很难完全符合条件。粒子 PHD 虽然适用于非线性系统，但是由于重采样聚类等操作会使得空间相距较近的标记粒子比例失衡，导致目标标记错误，如何在非线性条件下准确估计出多目标位置状态及航迹信息还需要进一步研究。

(3) 本文改进的航迹数据关联算法适用于密集靠近目标的航迹关联，但是由于关联过程中存在一定的门限，门限的选取也关系到航迹的精度，实际中如何科学的确定这些门限取值还有待研究。

(4) 基于对随机集进行标记的目标跟踪方法尚处于起步阶段，最近 Vo 等对基于标记随机集的方法也已经做了一些研究，但是取得的成果还是非常有限，还没有适用到整个随机集滤波方法中，如何将已有的研究成果推广到更一般的情况仍然是今后需要开展的工作。

参考文献

- [1] 夏佩伦. 目标跟踪与信息融合[M]. 北京: 国防工业出版社, 2010: 88-124.
- [2] Mahler R P S. Statistical multisource multitarget information fusion[M]. Boston: Artech House, 2007: 539-682.
- [3] Vo B T. Random finite sets in multi-object filtering[D]. the dissertation for the degree of Doctor of Philosophy of the university of western Australia, 2008.
- [4] Maybeck P S. Stochastic models estimation and control[M]. New York: Academic, 1982: 223-257.
- [5] Fortmann T, Bar S Y, Scheffe M. Sonar tracking of multiple targets using joint probabilistic data association[J]. IEEE Transactions on Oceanic Engineering, 1983, 8(3): 173-184.
- [6] Blackman S. Multiple hypothesis tracking for multiple target tracking[J]. IEEE Transactions on Aerospace and Electronic Systems Magazine, 2004, 19(1): 5-18.
- [7] Goodman I. R, Mahler, R. P. S, Nguyen H T. Mathematics of Data Fusion[M]. Holland: Kluwer Academic Publishers, 2010: 389-403.
- [8] Mahler R. Multitarget moments and their application to multitarget tracking[C]//Proc. of The Workshop on Estimation, Tracking, and Fusion: A Tribute to Yakov Bar-Shalom, 2001: 134-166.
- [9] Mahler R. Multitarget Bayes Filtering via First-Order Multitarget Moments[J]. IEEE Transactions on Aerospace and Electronic Systems, 2003, 39(4):1152-1178.
- [10] Daley D J, Vere-Jones D. An Introduction to the Theory of Point Processes Volume I: Elementary Theory and Methods[M]. Berlin: Springer Science & Business Media, 2003: 111-211.
- [11] Vo B N, Singh S, Doucet A. Sequential Monte Carlo implementation of the PHD filter for multi-target tracking[C]//Proc. Int'l Conf. on Information Fusion. 2003: 792-799.
- [12] Vo B N, Ma W K. The Gaussian mixture probability hypothesis density filter[J]. IEEE Transactions on Signal Processing, 2006, 54(11): 4091-4104.
- [13] Panta K, Vo B N, Singh S. Novel data association schemes for the probability hypothesis density filter[J]. IEEE Transactions on Aerospace and Electronic Systems, 2007, 43(2): 556-570.
- [14] Panta K, Vo B N, Singh S, et al. Probability hypothesis density filter versus multiple hypothesis tracking[C]//Proc. of SPIE, Signal Processing, Sensor Fusion & Target Recognition XIII, 2004:

284-295.

- [15] Lin L, Bar-Shalom Y, Kirubarajan T. Track labeling and PHD filter for multitarget tracking[J]. IEEE Transactions on Aerospace and Electronic Systems, 2006, 42(3): 778-795.
- [16] Clark D E, Bell J. Data association for the PHD filter[C]//Intelligent Sensors, Sensor Networks and Information Processing Conference, Proc. of the 2005 International Conference on. IEEE, 2005: 217-222.
- [17] Clark D E, Bell J. Multi-target state estimation and track continuity for the particle PHD filter[J]. IEEE Transactions on Aerospace and Electronic Systems, 2007, 43(4): 1441-1453.
- [18] Vo B T, Vo B N, Cantoni A. Analytic Implementations of the Cardinalized probability Hypothesis Density Filter[J]. IEEE Transactions on Signal Processing, 2007, 55(7): 3553-3567.
- [19] Mullane J, Vo B N, Adams M D, et al. Random set formulation for Bayesian SLAM[C]//Proceedings of the 2008 IEEE/RSJ International Conference on Intelligent Robots and Systems, Nice, France, 2008:1043-1049.
- [20] Wang Y D, Wu J K, Kassim A, et al. Data-driven probability hypothesis density filter for visual tracking[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2008, 18(8): 1085-1095.
- [21] Maggio E, Taj M, Cavallaro A. Efficient multitarget visual tracking using random finite sets[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2008, 18(8): 1016-1027.
- [22] Ikoma N, Uchino T, Maeda H. Tracking of feature points in image sequence by SMC implementation of PHD filter[C]//Proceedings of the Society of Instrument and Control Engineers Annual Conference, Hokkaido, Japan, 2004: 1696-1771.
- [23] Tobias M, Lanterman A D. Probability hypothesis density-based multitarget tracking with bistatic range and Doppler observations[J]. IEEE Proceedings-Radar Sonar and Navigation, 2005, 152(3): 195-205.
- [24] Ulmke M, Erdinc O, Willett P. Gaussian mixture cardinalized PHD filter for ground moving target tracking[C]//Proceedings of the 10th Conference of the International Society of Information Fusion, Quebec,Que, Canada, 2007: 1040-1047.
- [25] Clark D E, Ruiz I T, Petillot Y, et al. Particle PHD filter multiple target tracking in sonar image[J]. IEEE Transactions on Aerospace and Electronic Systems, 2007, 43(1): 409-416.
- [26] Clark D, Bell J. Bayesian multiple target tracking in forward scan sonar images using the PHD filter[J]. IEEE Proceedings-Radar Sonar and Navigation, 2005, 10(152): 327-334.
- [27] Clark D, Bell J, Saint-Pern Y D, et al. PHD filter multitarget tracking in 3D sonar[C]//Published with kind permission of QinetiQ, Brest, France, 2005:20-23.

-
- [28] Ahlberg S, Horling P, Johansson K, et al. An information fusion demonstrator for tactical intelligence processing in network-based defense[J]. *Information Fusion*, 2007, 8(1): 84-107.
- [29] Zajic T, Ravichandran B, Mahler R, et al. Joint tracking and identification with robustness against unmodeled targets[C]//*Proceedings of the Signal Processing, Sensor Fusion, and Target Recognition*, SPIE, Bellingham, WA, 2003: 279-290.
- [30] Ulmke M, Erdinc O, Willett P. GMTI tracking via the Gaussian mixture cardinalized probability hypothesis density filter[J]. *IEEE Transaction on Aerospace and Electronic Systems*, 2010, 46(4): 1821-1833.
- [31] Panta K, Clark D E. An efficient track management scheme for the Gaussian-mixture probability hypothesis density tracker[C]//*Intelligent Sensing and Information Processing*, 2006. ICISIP 2006. Fourth International Conference on. IEEE, 2006: 230-235.
- [32] Pollard E, Pannetier B, Rombaut M. Hybrid algorithms for multitarget tracking using MHT and GM-CPHD[J]. *IEEE Transaction on Aerospace and Electronic Systems*, 2011, 47(2): 832-847.
- [33] Panta K, Clark D E, Vo B N. Data association and track management for the Gaussian mixture probability hypothesis density filter[J]. *IEEE Transaction on Aerospace and Electronic Systems*, 2009, 45(3): 1003-1016.
- [34] Aoki E H, Boers Y, Svensson L, et al. A Bayesian look at the optimal track labelling problem[C]//*Data Fusion & Target Tracking Conference (DF&TT 2012): Algorithms & Applications*, 9th IET. 2012: 1-6.
- [35] Aoki E H, Bagchi A, Mandal P K, et al. A theoretical analysis of Bayes-optimal multi-target tracking and labelling[EB]. [2011.09], <http://www.math.utwente.nl/publications>.
- [36] Aoki E H, Boers Y, Svensson L, et al. An analysis of the Bayesian track labelling problem[EB]. [2012.03], <http://www.math.utwente.nl/publications>.
- [37] Aoki E H, Boers Y, Svensson L, et al. The Rao-Blackwellized marginal M-SMC filter for Bayesian multi-target tracking and labelling[C]//*Information Fusion (FUSION)*, 2012 15th International Conference on. IEEE, 2012: 90-97.
- [38] Vo B, Singh S, Doucet A. Sequential Monte Carlo Methods for Multi-target Filtering with Random Finite Sets[J]. *IEEE Transaction on Aerospace and Electronic Systems*, 2005, 41(4): 1224-1245.
- [39] Ulmke M, Erdinc O, Willett P. Gaussian Mixture Cardinalized PHD Filter for Ground Moving Target Tracking[C]//*10th International Conference on Information Fusion Quebec*, 2007: 1-8.
- [40] 刘伟峰, 文成林. 随机集多目标跟踪性能评价指标比较与分析[J]. *光电工程*, 2010, 37(9): 14-26.

- [41] 杨柏胜, 姬红兵, 高小东. 随机集粒子滤波的快速被动数据关联算法[J]. 西安电子科技大学学报 (自然科学版), 2010, 37(4): 655-659.
- [42] Clark D E, Panta K, Vo B N. The GM-PHD filter multiple target tracker[C]//Information Fusion, 2006 9th International Conference on. IEEE, 2006: 1-8.
- [43] 唐续, 魏平, 陈欣. PHD 粒子滤波中目标状态提取方法研究[J]. 电子与信息学报, 2010, 32(11): 2691-2694.
- [44] Dehkordi M Y, Azimifar Z, Shirazi M M. Penalized Gaussian mixture probability hypothesis density filter for multiple target tracking [J]. IEEE Transaction on Signal Processing. 2012, 92(1): 1230-1242.
- [45] Dehkordi M Y, Azimifar Z, Shirazi M M. Competitive Gaussian mixture probability hypothesis density filter for multiple target tracking in the presence of ambiguity and occlusion [J]. IEEE Proceedings-Radar Sonar and Navigation, 2012, 6(4): 251-262.
- [46] Wang Y, Meng H, Liu Y, et al. Collaborative penalized Gaussian mixture PHD tracker for close target tracking[J]. IEEE Transaction on Signal Processing, 2014, 102(1): 1-15.
- [47] Sigalov D, Shimkin N. Cross entropy algorithms for data association in multi-target tracking[J]. IEEE Transaction on Aerospace and Electronic Systems, 2011, 47(2): 1166-1185.
- [48] 谭顺成, 王国宏, 王娜等. 基于 PHD 滤波和数据关联的多目标跟踪[J]. 系统工程与电子技术, 2011, 33(4): 734-737.
- [49] Zhang S, Li J, Wu L. A novel multiple maneuvering targets tracking algorithm with data association and track management[J]. International Journal of Control, Automation and Systems, 2013, 11(5): 947-956.
- [50] 罗少华, 徐晖, 薛永宏. 一种新的 SMC-PHD 滤波的多目标状态估计方法[J]. 宇航学报, 2011, 32(10): 2187-2193.
- [51] Blackman S, Papoli R. Design and Analysis of Modem Tracking System[M]. Norwood:Artech House, 1999: 93-109.
- [52] 胡士强, 敬忠良. 粒子滤波原理及其应用[M]. 北京: 科学出版社, 2010: 53-130.
- [53] Arulampalam T S, Maskell S, Gordon N, et al. A tutorial on particle filters for online nonlinear /non-Gaussian Bayesian tracking[J]. IEEE Transaction on Signal Processing, 2002, 50(2): 174-188.
- [54] 陈金广, 马丽丽. 基于随机集理论的多目标跟踪研究进展[J]. 光电工程, 2012, 39(10): 15-20.
- [55] Mahler R. PHD Filters of Higher Order in Target Number[J]. IEEE Transactions on Aerospace and Electronic Systems, 2007, 43(3):1523-1543.

- [56] Doucet A, Gordon N J, Krishnamurthy V. Particle Filters for State Estimation of Jump Markov Linear Systems[J]. IEEE Transactions on Signal Processing, 2001, 49(3): 613-624.
- [57] Clark D E, Vo B N. Convergence Analysis of the Gaussian Mixture PHD Filter[J]. IEEE Transactions on Signal Processing, 2007, 55(4): 1204-1212.
- [58] Mahler R P S, Vo B T, Vo B N. Forward-backward probability hypothesis density smoothing[J]. IEEE Transactions on Aerospace and Electronic Systems, 2012, 48(1): 707-728.
- [59] Yoon J H, Bae S H, Shin V. Joint initialization and tracking of multiple moving objects using Doppler information[J]. IEEE Transactions on Signal Processing, 2011, 59(7): 3447-3452.
- [60] Nannuru S, Coates M, Mahler R. Computationally-tractable approximate PHD and CPHD filters for superpositional sensors[J]. IEEE Journal of Selected Topics in Signal Processing, 2013, 7(3): 213-218.
- [61] 王晓, 韩崇昭, 连峰. 基于有限随机集的目标跟踪方法研究及最新进展[J]. 工程数学学报, 2012, 29(4): 567-578.
- [62] 杨威, 付耀文, 龙建乾等. 基于有限集统计学理论的目标跟踪技术研究综述[J]. 电子学报, 2012, 40(7): 1440-1448.
- [63] 欧阳成, 姬红兵, 张俊根. 一种改进的 CPHD 多目标跟踪算法[J]. 电子与信息学报, 2010, 32(9): 2112-2118.
- [64] Panta K, Vo B, Singh S. Improved probability hypothesis density (PHD) filter for multitarget tracking[C].//Intelligent Sensing and Information Processing, Third International Conference on. IEEE, 2005: 213-218.
- [65] 欧阳成, 姬红兵, 田野. 一种基于模糊聚类的 PHD 航迹维持算法[J]. 电子学报, 2012, 40(6): 1284-1288.
- [66] Vermaak J, Godsill S J, Perez P. Monte Carlo Filtering for Multi-Target Tracking and Data Association[J]. IEEE Transactions on Aerospace and Electronic Systems, 2005, 41(1): 309-332.
- [67] 赵艳丽, 林辉, 赵锋等. 多目标跟踪中的数据关联和航迹管理[J]. 现代雷达, 2007, 29(3): 28-31.
- [68] 井沛良, 刘方. 一种使用修正模糊隶属度的航迹关联方法[J]. 应用科学学报, 2012, 30(2): 181-186.
- [69] 赵欣, 姬红兵, 杨柏胜. 基于随机集的 RBPF 多目标关联跟踪算法[J]. 电子学报, 2011, 39(3): 505-510.
- [70] Frank A, Smyth P, Ihler A. A Graphical Model Representation of the Track-oriented Multiple Hypothesis Tracker[C].//Statistical Signal Processing Workshop (SSP), IEEE. 2012: 768-771.
- [71] Papi F, Battistelli G, Chisci L, et al. Multitarget tracking via joint PHD filtering and multiscan

association[C].//Information Fusion, 12th International Conference on. IEEE, 2009: 1163-1170.

- [72] 刘宗香, 谢维信, 王品. 一种有轨迹标识的利用测量生成新目标密度的 GM-PHD 滤波器[J]. 信号处理, 2011, 27(9): 1281-1285.
- [73] 黄志蓓, 孙树岩, 吴健康. 多元假设检验 GM-PHD 轨迹跟踪[J]. 电子与信息学报, 2010, 32(6): 1289-1294.

致谢

光阴似箭，时光飞逝，转眼间两年半的研究生求学生涯即将进入尾声，在毕业论文完成之际，在此衷心感谢我的导师宋骊平副教授对我的谆谆教导。本文的研究工作是在宋老师的悉心指导和热情关怀下完成的，他严谨细致、实事求是的科学态度，认真勤奋、精益求精的工作作风，诲人不倦的高尚师德以及朴实无华、平易近人的人格魅力深深地感染和激励着我。感谢宋老师在工作、学习、研究、生活等各方面对我的无私指导和帮助，我将终生难忘。在此谨向宋老师致以诚挚的感谢和深深的敬意！

特别要感谢姬红兵教授，姬老师渊博的学识、严谨认真的治学态度、勇于开拓的进取精神、对科研工作的执着追求以及和蔼可亲的为师风范深深的影响着我，他在每周例会上的指导更是让我在科研及做人方面受益匪浅，为我树立了一个为人处事的楷模。姬老师在研究工作中给予了我无私的指导和帮助，使我在学术上、工作上和生活上受益终生，在此向姬老师表示最衷心的感谢和祝福。

感谢课题组的李翠芸副教授、金艳副教授、王磊副教授、李林副教授和刘靳副教授。感谢已经毕业的张文博博士、张永权博士、和基金项目组的刘龙博士、虎小龙博士、樊振华博士、王明杰博士、杨丹博士和郑学弢师兄、张昱师兄、高祺师兄、李翠丽师姐、赵雪刚师兄、曹潇男师兄、江舟师兄、赵会盼师姐、陈雅珍师姐、张艳、严超、廖良雄、程旭阳、林锦鹏、王荣、王顺利等，感谢这两年多的时间里给我的指导、建议和帮助，通过每周例会与大家的交流和沟通，才使我的研究工作有条不紊的展开，工作和科研生活如此的丰富多彩。

感谢实验室的丁祥师兄、赵万明、朱敏、任航、彭营、杨树林、王钢、景策、陶世昌、陈玉炎、梁萌、王宇飞、李潭、李鹏涛、刘远、宋志龙、程慧、刘宇航等同学，与他们共同的工作和学习生活结下的深厚友谊，将是我永远的财富。

感谢好友车转转、吕利、黄翩、以及范笑宇、王海鹰、任文君、王秀梅、刘卫芳、郭亚萍等，是你们在西电的陪伴，让我在研究学习之余多了许多快乐，愿友谊长存。

感谢我的父母，他们在这二十多年来给了我无微不至的照顾和无私的爱，为我付出了无数的心血，一如既往的支持我鼓励我。感谢我的男朋友，一直默默地支持我、包容我、理解我。

最后谨以此文向所有关心、爱护、支持、帮助我的人们表示最诚挚的感谢与最美好的祝愿！

作者简介

1. 基本情况

杜璇，女，陕西兴平人，1989 年 10 月出生，西安电子科技大学电子工程学院信号与信息处理专业 2012 级硕士研究生。

2. 教育背景

2008.08~2012.07 西安电子科技大学电子信息科学与技术专业，获理学学士学位

2012.08~至今 西安电子科技大学电子工程学院信号与信息处理专业，硕士研究生

3. 攻读硕士学位期间的研究成果

3.1 发表的学术论文

3.2 科研情况：

- [1]. 中央高校基本科研业务费资助项目：基于随机集和箱粒子滤波的目标跟踪方法研究 (JB140221)，2013.3~2014.10，作者负责基于随机集的多目标跟踪算法研究及算法仿真工作。
- [2]. 国家自然科学基金：复杂环境下多传感器随机集目标跟踪方法研究(61372003)，2014.1~2017.12，作者负责多目标跟踪算法及航迹数据关联部分，提出不同的改进算法并进行仿真验证。

